

Layer-Adaptive Ontology Steering: 멀티-툴 도구 선택을 위한 훈련-없는 K+Q 회전과 부호 진단

Anonymous Author(s)

Affiliation

Address

email

초록

본 논문은 멀티-툴 도구 선택에서 실패하는 것은 저랭크 steering 자체가 아니라 정지 K-style steering의 배치 방식라는 주장을 제시한다. Meta-Tool Subtask4에서 정지 K는 -4.57pp 로 붕괴하지만, 같은 온톨로지 기저 위에서 K를 초기 레이어에만 제한하고 Q를 전역에 두는 layer-adaptive K+Q는 $+2.08\text{pp}$ 를 회복한다. τ^2 -bench에서도 이 설계는 retail/telecom/airline에서 각각 $+5.98/+26.76/+3.84\text{pp}$ 를 기록하며, retail을 action 수로 분해하면 short-horizon에서는 layer-adaptive가, medium/long-horizon에서는 signed Q-only가 우세해 두 연산자가 같은 operator family 안의 regime-dependent 양끝임이 드러난다. Llama-3.1-8B-Instruct에서도 telecom under-focused regime에서는 $+11.62\text{pp}$ 가 재현되지만, 최적 signed-Q 부호는 Qwen과 반대이고 positive β 는 대규모 empty output collapse를 유발한다. 이론적으로 우리는 정지 K가 방출 히스토리를 인코딩할 수 없음을 보이고, K-측과 Q-측 개입이 per-step에서는 동등하지만 KV-cache 재사용 아래 multi-step에서는 갈라짐을 증명한다. 요점은 단순하다. 멀티-툴에서 중요한 것은 “더 강한 정지 steering”이 아니라 어느 깊이에서 어떤 쪽을 조작할 것인가다.

1 서론

LLM 에이전트가 실전에서 유용하려면 한 질의에서 여러 도구를 순차적으로 고를 수 있어야 한다. “뉴스에서 주식 관련 기사를 찾아 요약해 달라”는 요청은 검색 도구와 요약 도구를 연달아 불러야 하며, 같은 기능을 가진 여러 도구가 도메인별로 섞여 있으면 무엇을 먼저 쓰고 무엇을 다음으로 남겨야 하는지를 함께 결정해야 한다. 이 멀티-툴 setting의 핵심은 단일 정답률이 아니라 coverage와 비반복성이며, 서로 다른 목적을 가진 여러 해법 경로가 이 문제를 공격해 왔다.

도구 선택 성능을 강화하는 경로는 네 갈래로 나뉜다. tool-aware finetuning은 도구 호출 예시로 모델 가중치를 직접 조정해 강한 성능을 내지만 카탈로그가 바뀔 때마다 재학습 비용을 치러야 한다. 프롬프트 스케폴딩은 학습 없이 추론 시 프롬프트로 행동을 유도하지만 프롬프트 길이에 비례해 토큰 비용이 증가한다. KV-cache 최적화는 추론 자원을 줄여 주지만 “무엇을 고를지”라는 과제 수준의 결정에는 개입하지 않는다. 네 번째 갈래인 활성 스티어링은 attention에 저랭크 개입을 주입해 가중치와 프롬프트를 모두 건드리지 않고 행동을 바꾼다. 본 논문은 활성 스티어링에 속하며, 표 1이 네 접근을 학습 비용, 멀티-툴 표적성, 부호 결정 방식의 축에서 비교한다.

활성 스티어링 계열은 훈련 없이 추론 시점에 행동을 조정한다는 장점을 공유하지만, 대부분의 기존 구현은 정지 연산자다. 즉 같은 저랭크 방향을 모든 디코딩 단계에 걸쳐 동일하게 밀어 넣는다. 이 형식은 단일 개념 편집이나 단일 도구 선택처럼 “한 방향을 강화하는” 과제에는 자연스러운 선택이지만, 멀티-툴에는 맞지 않는다. 첫 도구를 이미 방출한 뒤에도 연산자는 방출 사실을 모른 채 같은 방향을 계속 증폭하여 두 번째 단계에서 첫 도구를 다시 고르게 유도한다. 이것이 멀티-툴에서 정지 활성 스티어링이 coverage 대신 반복을 만드는 구조적 이유이며, 본 논문의 첫 이론적 관찰이 이 현상을 형식화한다.

대안을 찾을 때 “K 대신 Q를 돌리자”만으로는 충분하지 않다. Q를 온톨로지 부분공간에서 회전시키는 연산자 $Q' = Q + \beta Q P_{\text{ont}}$ 는 부호에 따라 온톨로지 정렬 방향을 눌러 coverage를 넓히거나 강화해 focus를 좁히는 두 얼굴을 가진다. 어느 부호가 주어진 과제에서 유리한지는

표 1: 멀티-툴 호출 강화의 네 접근과 본 논문의 위치.

접근	대표 방법	학습 free	멀티-툴 표적	부호 결정
Tool-aware finetuning	Gorilla, ToolLlama, xLAM	×	✓	n/a
Prompt scaffolding	ReAct, ToT	✓	프롬프트	n/a
KV-cache 최적화	KIVI, StreamingLLM	✓	×	n/a
정지 활성 스티어링	SEKA, AdaSEKA, ITI, CAA, PASTA	✓	×	고정(보통 +)
본 논문	Layer-adaptive K+Q steering	✓	✓	레이어 스케줄 + 부호 진단

39 선형적으로 결정되지 않는다. 반대로 K와 Q를 모든 레이어에 걸쳐 동시에 적용하면 후반 레이어의
40 출력 수렴 과정이 교란되어 성능이 오히려 무너진다. 문제의 본질은 “K냐 Q냐”가 아니라
41 어느 레이어에서 무엇을 쓰느냐에 있다. 본 논문의 중심 설계인 layer-adaptive K+Q는 초기
42 레이어에서는 K로 도구 방향을 각인하고, 이후 레이어에서는 Q로 이미 지배적인 facet을 눌러 남은
43 facet을 보게 한다. 랙된 실험은 이 설계를 일관되게 지지한다. 정지 K를 모든 레이어에 적용하면
44 MetaTool Subtask4에서 -4.57pp 로 붕괴하지만, K를 초기 1/4 레이어에만 두면 같은 기저로
45 $+2.08\text{pp}$ 가 회복된다.

46 이 layer-adaptive 설계 위에서 signed Q는 task regime에 따라 다른 해석을 받는다. baseline
47 F1이 낮고 온톨로지 정렬이 부족한 domain에서는 양의 β 가 focus를 좁혀 이득을 낼 수 있고, base-
48 line이 이미 온톨로지에 치우친 domain에서는 음의 β 가 과도 편향을 풀어 coverage를 돌려줄 수
49 있다. 어느 쪽이 유리한지는 baseline forward pass 한 번에서 측정 가능한 양 — ground-truth
50 proxy에 걸린 온톨로지 정렬도의 조건부 평균과 전체 평균의 차이 — 로 국소적으로 해석할 수 있다.
51 본 논문은 이 관계를 일차 수준의 해석 도구로 정리하되, deployment-ready predictor라는 주장은
52 하지 않는다.

53 본 논문의 기여는 네 가지로 요약된다. 첫째, 정지 활성 스티어링이 멀티-툴에서 구조적으로
54 방출 상태를 담지 못한다는 불가능성 결과를 제시하고, 그 footprint가 포지션별 hit rate에서
55 repeated_first_tool_rate 상승으로 관측됨을 확인한다. 둘째, 초기 K와 후반 Q를 분리한
56 layer-adaptive 스케줄을 도입하여 “K를 어디까지 허용할지”라는 설계 원리를 구현한다. 셋째,
57 signed Q-회전에 대해 softmax gradient identity에서 일차 부호 진단을 유도해 도메인별 부호
58 역전을 설명한다. 넷째, 방법은 학습 비용 0, 토큰 오버헤드 0, 저장 약 2.6 MB의 저랭크 hook으로
59 효율성 측면에서도 실용적이며, KV-cache 최적화와도 직교 결합 가능하다.

60 2 관련 연구

61 본 논문의 위치는 표 1이 정리한 네 갈래 가운데, 추론 시점의 활성 스티어링을 멀티-툴 선택
62 문제로 다시 가져오는 시도라는 점에서 읽어야 한다. 기존 연구는 대체로 “도구 사용을 학습하느냐”,
63 “프롬프트로 유도하느냐”, “추론 자원을 줄이느냐”, “중간 표현을 직접 움직이느냐”로 나뉜다. 본
64 논문의 핵심은 이 가운데 마지막 갈래가 단일 개념 강조에는 강했지만 순차적 멀티-툴 선택에는 맞지
65 않았다는 점을 드러내고, 그 이유를 정지 연산자의 구조적 한계로 설명하는 데 있다.

66 첫 갈래인 tool-aware finetuning은 도구 사용 자체를 가중치에 학습한다. Gorilla [Patil
67 et al., 2023]는 대규모 API 호출 데이터로 function calling을 지도학습하고, ToolLLM [Qin et al.,
68 2024]는 실 API 집합 위의 tool-use trajectory를 통해 일반성을 넓히며, xLAM [Zhang et al.,
69 2024a]는 action model family로 확장한다. 이 계열은 강하지만 카탈로그가 바뀔 때마다 재학습
70 비용을 치른다. 둘째 갈래인 프롬프트 스캐폴딩은 학습 없이 reasoning chain과 행동 형식을
71 강제한다. ReAct [Yao et al., 2023]가 대표적이며, tool selection을 관찰-사고-행동 루프로
72 구조화한다. 그러나 프롬프트 길이와 호출 수가 task 복잡도에 따라 늘어나므로 추론 비용이 커진다.
73 셋째 갈래인 KV-cache 최적화는 또 다른 축이다. KIVI [Liu et al., 2024]와 같은 방법은 KV cache를
74 압축해 메모리와 latency를 줄이지만, 어떤 도구를 고를 것인가라는 의사결정 자체에는 개입하지
75 않는다. 따라서 본 논문의 질문과는 직교한다.

76 넷째 갈래인 활성 스티어링은 frozen model의 내부 표현을 추론 시점에 직접 수정한다.
77 ITI [Li et al., 2023]와 CAA [Rimsky et al., 2024]는 residual stream 방향을 더하거나
78 빼고, PASTA [Zhang et al., 2024b]는 post-softmax attention을 재가중하며, Focus Direc-
79 tions [Zhu et al., 2025]는 관련 context 쪽으로 주의를 유도한다. SEA [Qiu et al., 2025]와
80 SEKA [Li et al., 2026]는 spectral subspace를 이용해 activation 또는 key-space 개입을
81 구성한다. 이 계열의 공통점은 훈련 없이 행동을 바꾼다는 데 있지만, 표준적인 배치 형태에서는
82 개입 자체가 대체로 정지적이다. 같은 방향을 모든 디코딩 단계에 걸쳐 반복 주입하기 때문에, 이미

무엇을 선택했는지에 따라 개입이 바뀌지 않는다. prompt highlighting처럼 “한 번 더 강하게 보라”는 문제에는 자연스럽지만, 멀티-툴 선택에서는 첫 도구를 계속 다시 밀어 주는 반복 편향으로 바뀔 가능성이 크다. 본 논문은 이 점을 tool-use setting에서 직접 측정한 결과로 확인한다는 데서 기존 steering 논문과 달라진다.

본 논문은 여기서 기존 활성 스티어링과 달라진다. 첫째, 목표가 prompt highlighting이나 단일 개념 편집이 아니라 coverage와 비반복성이 중요한 멀티-툴 selection이다. 둘째, 기저를 contrastive supervision으로 학습하지 않고 도구 카탈로그의 4-facet 구조에서 직접 구성한다. 셋째, 가장 중요한 차이로 개입을 전 레이어에 균일하게 두지 않고 초기 K와 전역 Q로 역할을 분리한 스케줄을 사용한다. 즉 novelty는 “더 좋은 projector”가 아니라 “정지 연산자의 반복 편향을 피하기 위한 operator schedule”에 있다.

벤치마크 선택도 이 문제의식을 따른다. MetaTool Subtask4 [Huang et al., 2024]는 각 질의에 정확히 두 개의 정답 도구가 있어 반복과 coverage를 가장 직접적으로 측정한다. τ^2 -bench [Research et al., 2025]의 retail, telecom, airline은 정답 도구 수와 난도가 달라 short-horizon과 long-horizon을 함께 드러낸다. BFCL [Yan et al., 2024]은 교차 검증용 function-calling 벤치마크다. 본문은 Qwen2.5-7B를 주 실험 모델로 두고, cross-model robustness는 Llama-3.1-8B에서만 제한적으로 다룬다. 이 구성은 “멀티-툴에서 정지 스티어링이 왜 깨지는가”와 “레이어별 역할 분리가 그 문제를 실제로 푸는가”를 가장 직접적으로 보여 주기 위한 것이다.

3 방법

본 논문의 중심 방법은 layer-adaptive K+Q steering이다. 같은 온톨로지 기저 위에서 K는 초기 레이어에만 두고 Q는 전 레이어에 유지하는 간단한 스케줄로, 정지 활성 스티어링의 반복 편향을 우회하면서 훈련 없이 추론 시 작동한다. 이 절은 먼저 기저와 세 연산자를 정의하고, 그 다음 레이어 스케줄의 직관과 비용을 서술한다.

모든 개입은 하나의 온톨로지 기저 위에서 정의된다. 도구 카탈로그의 4-facet 구조 (domain, function, io_type, category)를 layer-head별 basis $B \in \mathbb{R}^{d \times r}$ 로 정리하고, 그 사영을 $P_{\text{ont}} = BB^\top$ 로 둔다. 이 기저는 도구를 semantic facet 축으로 분해해 attention 공간에 직접 주입할 수 있게 만든다. 본 논문은 같은 P_{ont} 위에서 세 연산자를 정의해 서로 비교 가능한 형태로 둔다. 정지 K-측 개입 $K' = K + \alpha K P_{\text{ont}}$ 는 온톨로지 방향을 모든 레이어에 걸쳐 동일하게 증폭한다. signed Q-회전 $Q' = Q + \beta Q P_{\text{ont}}$ 는 부호에 따라 focus형($\beta > 0$) 또는 coverage형($\beta < 0$)으로 작동한다. Layer-adaptive K+Q는 이 둘을 전 레이어에 동시에 쓰지 않고 레이어별로 다른 역할을 부여한다.

Layer-adaptive K+Q의 직관은 레이어별 민감도의 비대칭에서 나온다. 초기 레이어는 토큰 수준 의미가 형성되는 구간이라 K-측 증폭이 정답 도구 방향을 각인하는 데 유용하지만, 후반 레이어는 출력 분포가 수렴하는 구간이라 같은 K perturbation이 오히려 분포를 깨뜨린다. 따라서 본 논문은

$$\alpha_\ell = \alpha \mathbf{1}\{\ell < \lfloor L/4 \rfloor\}, \quad \beta_\ell = \beta$$

의 스케줄을 사용한다. K는 초기 $\lfloor L/4 \rfloor$ 개 레이어에만 두고, Q는 전 레이어에서 유지한다. 이 스케줄은 “초기 각인에는 K, 이후 coverage 조정에는 Q”라는 역할 분리를 명시적으로 구현한다.

본 방법의 방법론적 기여는 새로운 기저 자체가 아니라 연산자 배치에 있다. 기존 활성 스티어링은 대체로 하나의 방향을 모든 레이어에 정지적으로 주입해 왔으며, 그 결과 멀티-툴에서 반복 편향을 피하지 못했다. 본 논문은 같은 기저로도 연산자의 레이어별 배치가 결과를 결정한다는 점을 전면에 놓는다. 즉 “더 좋은 정적 projector”가 아니라 “멀티-툴에서 K를 쓸 수 있는 범위를 초기 레이어로 제한하고 Q와 기능을 분담시키는 operator schedule”이 본 방법의 novelty다. 이 때문에 본 방법은 SEKA류 정지 K-only 설계와 구조적으로 구분된다.

구현은 attention hook 한 번으로 충분하다. 각 레이어에서 schedule에 따라 K 또는 Q를 사영 방향으로 수정하고, 나머지 계산은 원래 모델의 forward를 그대로 사용한다. 추가 저장은 per-head basis (L, H_{kv}, d, r)뿐이며, Qwen2.5-7B 기준 약 2.6 MB다. 가중치 업데이트와 프롬프트 확장은 필요 없다.

4 이론

이 절의 목적은 하나의 공격적 명제를 수학적으로 정리하는 데 있다. 멀티-툴에서 문제는 “저랭크 steering 자체”가 아니라 “정지 K-style steering”이다. 본문에 필요한 이론은 세 가지뿐이다. 첫째, 정지 K는 방출된 도구 상태를 조건으로 삼을 수 없으므로 멀티-툴에서 구조적 반복 편향을 갖는다. 둘째, K-측과 Q-측 개입은 한 스텝에서는 같은 연산자족이지만, KV-cache 재사용 때문에 여러 스텝에서는 달라진다. 셋째, signed Q의 부호는 $\beta = 0$ 근방에서만 국소적으로 해석할 수 있다.

이 세 결과가 본문의 중심 주장인 “early-K / global-Q schedule”과 “Q-only는 regime-specific variant”를 닫는다. 보다 기술적인 perturbation bound는 부록으로 미룬다.

단일 헤드 self-attention을 고려한다(멀티헤드는 헤드 집합). 레이어 ℓ 에서 질의 $q \in \mathbb{R}^d$, key 행렬 $K \in \mathbb{R}^{T \times d}$, value 행렬 $V \in \mathbb{R}^{T \times d_v}$, softmax 가중치 $s_t(q) = \text{softmax}(qK^\top / \sqrt{d})_t$, 출력 $o(q) = \sum_t s_t(q)v_t$ 를 쓴다. § 3의 세 연산자는

$$\underbrace{K' = K + \alpha K P_{\text{ont}}}_{\text{정지 K (SEKA형)}}, \quad \underbrace{Q' = Q + \beta Q P_{\text{ont}}}_{\text{signed Q-회전}}, \quad \underbrace{\alpha_\ell = \alpha \mathbf{1}\{\ell < \lfloor L/4 \rfloor\}, \beta_\ell = \beta}_{\text{layer-adaptive K+Q}} \quad (1)$$

로 다시 쓰며, 세 연산자가 같은 B 를 공유하므로 결과 차이는 기저가 아니라 연산자 형식과 레이어 스케줄에서 나온다. 분석 가정은 유계 노름 하나뿐이다: 모든 $q, (k_t, v_t), e_t$ 에 대해 $\|q\| \leq Q_{\text{max}}, \|v_t\| \leq V_{\text{max}}, \|e_t\| \leq \rho$. (q, K, V) 의 결합 분포에 대한 추가 가정은 두지 않는다.

가정 4.1 (분석 범위). 정리 4.4와 정리 4.6은 고정된 (q, K, V) 에서의 per-step 분석이고, 따름정리 4.5는 KV-cache가 재사용되는 autoregressive decoding을 따로 다룬다. 따라서 본 절은 “한 스텝에서 같은가”와 “여러 스텝에서 같은가”를 명시적으로 구분한다.

정지 K는 멀티-툴 상태를 인코딩할 수 없다. 정리 4.2은 이를 “강한 불가능성”보다 구조적 불변성으로 읽는 것이 정확하다. 직관적으로, 같은 hidden state x 를 만들어내는 두 디코딩 히스토리가 이미 방출한 도구 집합에서 달라도, 정지 연산자는 그 차이를 볼 수 없다.

정리 4.2 (정지 K는 방출 상태에 무관하다). 식 (1)의 정지 K-측 연산자를 쓰자. 두 디코딩 히스토리 h, h' 가 같은 hidden state x 를 낳지만 방출 도구 집합에서 다르다면 $K'(h) = K'(h')$. 따라서 (K', K) 의 어떤 함수도 방출 히스토리를 인코딩하지 못한다.

증명. $K' = K + \alpha K P_{\text{ont}}$ 는 $(K, \alpha, P_{\text{ont}})$ 만의 함수이고 셋 다 히스토리 불변이므로 $K' = f(K)$ 로 쓸 수 있는 히스토리 불변 함수 f 가 존재한다. $K(h) = K(h')$ 이면 $f(K(h)) = f(K(h'))$. $\square$

같은 논증이 AdaSEKA에도 적용된다 — 전문가 선택이 현재 입력 x 의 함수이기 때문이다. 이 구조적 성질의 관측 가능한 귀결은 repeated_first_tool_rate의 상승이며(따름정리 A.1, 부록), § 5이 직접 검증한다. 정리가 말하는 바는 분명하다. 멀티-툴에서 정지 K-only는 원리적으로 방출 상태를 담지 못하므로, 방법론적 개선은 “더 강한 K”가 아니라 “K를 어디까지 허용할 것인가”에서 나와야 한다.

Signed Q-회전은 같은 기저 위에서 두 얼굴을 가진다. 정리 4.3이 그 기하를 고정한다: 온톨로지 성분만 $(1 + \beta)$ 배로 조절되고 직교 성분은 보존되므로, $\beta > 0$ 은 온톨로지 정렬 도구의 attention을 증폭하고 $\beta < 0$ 은 감쇠한다.

정리 4.3 (Q-사영의 기하). 식 (1)에서 $q' = q + \beta q P_{\text{ont}}$ 는 q 의 온톨로지 성분을 $(1 + \beta)$ 배로 균일 축소 또는 증폭하고 직교 성분을 보존한다. $\beta < 0$ 이면 온톨로지 정렬 도구의 attention logit이 감소하고, $\beta > 0$ 이면 증가한다.

증명. $P_{\text{ont}}^2 = P_{\text{ont}}$ 에서 $q' P_{\text{ont}} = (1 + \beta) q P_{\text{ont}}, q'(I - P_{\text{ont}}) = q(I - P_{\text{ont}})$. $\square$

같은 기저 위에서 K-측과 Q-측 개입이 한 스텝 안에서 동등한 작용을 한다는 관찰은 “같은 연산자족”이라는 서사를 수학적으로 고정한다. 정리 4.4가 이를 식 (1)의 두 측에 대해 직접 진술한다.

정리 4.4 (Q-K per-step duality). 식 (1)의 정지 K-측 연산자 $K' = K + \alpha K P_{\text{ont}}$ 와 signed Q-회전 $Q' = Q + \beta Q P_{\text{ont}}$ 를 고려하자. 임의의 한 디코딩 스텝에서 같은 $P_{\text{ont}} = BB^\top$ 를 공유하고 $\beta = \alpha$ 이면 두 개입은 attention logit을 동일하게 바꾼다:

$$\frac{1}{\sqrt{d}} q^\top (K')^\top = \frac{1}{\sqrt{d}} (Q' q)^\top K. \quad (2)$$

따라서 K-측 강도 α 와 Q-측 강도 β 는 단일 스텝 attention score 수준에서 서로 교환 가능하다.

증명. $P_{\text{ont}}^\top = P_{\text{ont}}$ 이므로 $K' = K(I + \alpha P_{\text{ont}})$ 의 전치는 $(I + \alpha P_{\text{ont}})K^\top$ 이고, 따라서 $q^\top (K')^\top = q^\top (I + \alpha P_{\text{ont}})K^\top$. 한편 $Q' q = (I + \beta P_{\text{ont}})q$ 로부터 $(Q' q)^\top K = q^\top (I + \beta P_{\text{ont}})K^\top$. 두 식은 $\alpha = \beta$ 일 때 동일하다. $\square$

정리 4.4는 두 연산자가 같은 operator family의 두 표상임을 per-step 수준에서 확정하지만 두 표상의 multi-step 거동은 비대칭적이다. 자기회귀 생성에서 key 행렬은 KV-cache에 고정 저장되어 재사용되는 반면 query는 매 스텝 새로 계산되기 때문이다. 따름정리 4.5가 이 비대칭을 정식화한다.

178 **따름정리 4.5** (KV-cache multi-step divergence). KV-cache를 사용하는 autoregressive
 179 디코딩에서 K-측 개입 $K' = K + \alpha K P_{\text{ont}}$ 은 스텝 T 에서 캐시에 주입된 이후 모든 후속 스텝
 180 $T+1, T+2, \dots$ 의 logit에 같은 $\alpha K P_{\text{ont}}$ 항을 누적해 반영한다. 반면 Q-측 개입 $Q' = Q + \beta Q P_{\text{ont}}$ 는
 181 매 스텝 새 query에만 적용되어 스텝 간 누적이 없다. 따라서 정리 4.4의 per-step 동등성은 multi-
 182 step 해석 수준에서 깨지고, K-측은 long-horizon attention 분포 왜곡을 증폭하며 Q-측은 그렇지
 183 않는다.

184 증명. 캐시된 key는 $k_t^{\text{cache}} = k_t^{\text{orig}} + \alpha P_{\text{ont}}^\top k_t^{\text{orig}}$ 로 고정되어 이후 모든 스텝의 logit $q_s^\top k_t^{\text{cache}} / \sqrt{d}$ 에
 185 $\alpha q_s^\top P_{\text{ont}}^\top k_t^{\text{orig}} / \sqrt{d}$ 를 더한다. 따라서 스텝 수 S 에 대해 K-측 기여는 $\sum_{s=T}^{T+S} \alpha q_s^\top P_{\text{ont}}^\top k_t^{\text{orig}} / \sqrt{d}$ 형태로
 186 쌓인다. Q-측은 $q'_s = q_s + \beta P_{\text{ont}} q_s$ 가 각 스텝에서 새로 계산되므로, 스텝 s 의 개입 항은
 187 $\beta q_s^\top P_{\text{ont}}^\top k_t^{\text{orig}} / \sqrt{d}$ 이며 s -의존적이지만 스텝 간 누적은 없다. $\square$

188 정리 4.4와 따름정리 4.5가 묶여 본 논문의 가장 도발적인 해석을 지탱한다. 실패한 것은 “steering”
 189 이 아니라 “정지 K를 모든 단계에 같은 방식으로 밀어 넣는 배치”다. single step에서는 K-측과
 190 Q-측이 교환 가능하므로 layer-adaptive K+Q와 signed Q-only는 한 스텝 기준에서 같은 가족의
 191 구성원이며, multi-step에서는 K-bias가 캐시에 누적되므로 long-horizon 체제에서 Q-only가 더
 192 안정적인 이유가 설명된다. § 5은 이 예측을 retail 액션 수 분해와 도메인별 우세 패턴으로 확인한다.

193 이 결과가 설명해야 할 경험적 사실은 분명하다. retail과 MetaTool에서는 $\beta < 0$ 이 이기고 tele-
 194 com에서는 $\beta > 0$ 이 이긴다. 어느 부호가 어느 도메인에서 유리한지를 일차 수준에서 예측하는
 195 진단이 다음 정리다. ground-truth 도구의 proxy token 집합을 $\mathcal{G}$ 라 하고 현재 attention 분포를
 196 $p_0(t) = s_t(q)$ 라 하자. 온톨로지 부분공간 위의 per-token score를

$$r_t := \frac{1}{\sqrt{d}} \langle B B^\top q, k_t \rangle$$

197 로 정의한다. 즉 r_t 는 q 의 온톨로지 성분이 각 key와 얼마나 정렬되어 있는지를 재는 값이다. ground-
 198 truth에 걸린 attention 질량 $L(\beta) := \sum_{t \in \mathcal{G}} p_\beta(t)$ 의 $\beta = 0$ 근방 변화를 살펴보면 다음 진단이
 199 나온다.

200 **정리 4.6** (signed Q의 일차 개선 방향). $\pi_{\mathcal{G}} = \sum_{t \in \mathcal{G}} p_0(t) > 0$, $\bar{r} = \sum_t p_0(t) r_t$, $\bar{r}_{\mathcal{G}} =$
 201 $\frac{1}{\pi_{\mathcal{G}}} \sum_{t \in \mathcal{G}} p_0(t) r_t$ 라 하자. 그러면

$$\left. \frac{dL}{d\beta} \right|_{\beta=0} = \pi_{\mathcal{G}} (\bar{r}_{\mathcal{G}} - \bar{r}). \quad (3)$$

202 특히 $\bar{r}_{\mathcal{G}} - \bar{r} > 0$ 이면 $\beta = 0$ 근방에서 $\beta > 0$ 방향이, $\bar{r}_{\mathcal{G}} - \bar{r} < 0$ 이면 $\beta < 0$ 방향이 ground-truth
 203 attention mass를 증가시키는 국소 방향이다.

204 증명. softmax gradient identity $\partial_\beta p_\beta(t) = p_\beta(t)(r_t - \mathbb{E}_{p_\beta}[r])$ 에 $\mathcal{G}$ 에 대한 합을 취하고 $\beta = 0$ 에서
 205 평가하면 $\left. \frac{dL}{d\beta} \right|_{\beta=0} = \sum_{t \in \mathcal{G}} p_0(t)(r_t - \bar{r}) = \pi_{\mathcal{G}}(\bar{r}_{\mathcal{G}} - \bar{r})$. 따라서 국소 개선 방향의 부호가 $\bar{r}_{\mathcal{G}} - \bar{r}$ 의
 206 부호와 일치한다. $\square$

207 이 정리는 signed Q가 어떤 regime에서 focus처럼, 어떤 regime에서 coverage처럼
 208 작동하는지를 한 값 — ground-truth proxy에 걸린 온톨로지 정렬도의 조건부 평균에서 전체
 209 평균을 뺀 값 — 의 부호로 환원한다. 하지만 이 결과가 주는 것은 local direction이지 전역 최적 β 가
 210 아니다. 따라서 본문은 이 정리를 배포 가능한 router가 아니라 regime 설명 도구로만 사용한다. 네
 211 Qwen 도메인에서의 부호 방향이 실측 우세 방향과 어떻게 대응되는지는 표 2에 정리한다.

표 2: 정리 4.6의 경험적 진단 (Qwen2.5-7B). β 부호에 대한 국소 개선 방향 신호.

도메인	baseline F1	$\text{sign}(\bar{r}_{\mathcal{G}} - \bar{r})$	실측 우세 방향	해석
τ^2 Telecom	0.251	+	$\beta = +0.10, +22.74\text{pp}$	under-focused regime
τ^2 Retail	0.468	−	$\beta = -0.03, +5.11\text{pp}$	coverage regime
τ^2 Airline	0.329	+	layer-adaptive 우세, $\beta < 0$ 은 약함	mixed boundary
MetaTool ST4	0.731	−	$\beta = -0.03, +2.28\text{pp}$	over-confident regime

212 정지 K는 왜 모든 레이어에 균일하게 두면 위험한가. 이를 다루는 마지막 결과는 보조적이다. 메인
 213 주장은 앞선 세 결과와 § 5의 stepwise/action-count 증거만으로 닫히며, 아래 정리는 late-layer
 214 K perturbation이 더 취약할 수 있음을 뒷받침하는 정량적 부록 결과로 읽어야 한다.

215 **정리 4.7** (Attention 출력의 exact integral remainder). $\phi(\tau) := \sum_t \text{softmax}(\ell(q) +$
 216 $\tau\alpha(q))_t v_t$ 에 대해 $\hat{o}(q) - o(q) = L(q, E) + R(q, E)$ 가 정확한 등식으로 성립하고, 유계 노름 아래
 217 $\|\hat{o} - o\|^2 \leq 2 \text{Var}_s \alpha(q) \cdot \text{Var}_s[V](q) + C_1 \rho^4$, $C_1 = 2Q_{\max}^4 V_{\max}^2 / d^2$.

218 본문 논증은 한 줄 Taylor 전개와 softmax Jacobian으로 충분하며, 완전 증명은 부록 A.3에
 219 있다. §5의 실측은 Qwen L=13에서 좌변/우변 비율의 중앙값이 2.36×10^{-8} 로 bound가 공허하지
 220 않음을 확인한다. 이 보조 결과가 말해 주는 바는 단순하다. 같은 α 라도 late-layer K perturbation
 221 은 더 위험할 수 있고, early-layer K perturbation은 정보 각인 쪽에 더 유리하다. 본 논문의
 222 스케줄 $\alpha_\ell = \alpha \mathbf{1}\{\ell < \lfloor L/4 \rfloor\}$, $\beta_\ell = \beta$ 는 이 설계 원리의 최소 구현이다.

223 다섯 결과는 같은 연산자족 (1)의 서로 다른 축을 짚는다. 정리 4.2은 연산자 정의만으로 history-
 224 free 한계를, 정리 4.3은 사영 먹등성만으로 Q 부호의 기하를, 정리 4.4는 P_{ont} 의 대칭성만으로
 225 K와 Q의 per-step 동등성을, 따름정리 4.5는 KV-cache 재사용만으로 multi-step 비대칭성을
 226 지적하며, 정리 4.6과 정리 4.7은 softmax gradient와 Taylor 전개로 각각 국소 방향과 레이어별
 227 교란 경계를 제공한다. 이로써 layer-adaptive K+Q와 signed Q-only는 “같은 기저, 같은 per-
 228 step 작용, 서로 다른 multi-step 거동”이라는 하나의 연산자족 내 두 끝으로 해석된다.

229 5 평가

230 본 절은 layer-adaptive K+Q가 동일 operator family 안에서 가장 강한 락된 K-포함 설계로
 231 작동함을 보인다. 정지 K-only는 멀티-툴에서 구조적으로 실패하고, K를 초기 레이어에만 제한하면
 232 useful signal이 회복되며, 같은 연산자족의 signed Q-only는 ladapt와 대체가 아니라 horizon에
 233 따른 역할 분담을 갖는다. 모든 수치는 동일 프로토콜의 Qwen2.5-7B-Instruct 평가에서 가져오며,
 234 비교 방법은 no_steer, 정지 K ocq_bias, signed Q-회전 ocq_qbias_b $\pm$, 그리고 레이어 적응형
 235 K+Q ocq_ladapt_k0.05_q-0.03이다. 통계적 주장은 10,000-iteration paired bootstrap으로
 236 검증한다. protocol-matched SEKA/AdaSEKA 비교는 같은 평가 계약 위에서 추가 검증 축으로
 237 분리해 부록 D에 정리한다.

238 5.1 주 결과와 기제 분석

239 표 3은 본 논문의 핵심 서사를 한 번에 보여 준다. 가장 먼저 보이는 사실은 정지 K-only는 멀티-
 240 툴의 일반 해법이 아니다. MetaTool ST4에서 정지 K는 -4.57pp로 붕괴한다. 반면 같은 온톨로지
 241 기저에서 K를 초기 레이어에만 두고 Q를 전 레이어에 유지한 layer-adaptive 스케줄은 +2.08pp를
 242 낸다. 즉 “K를 더 세게 쓰자”가 아니라 “K를 어디까지 허용할 것인가”가 본질이다.

243 두 번째 관찰은 layer-adaptive K+Q가 네 Qwen 도메인에서 Q-only를 match 또는 beat하는
 244 강한 within-family fallback이라는 점이다. retail에서는 +5.98pp로 Q-only +5.11pp 대비
 245 +0.94pp 앞서지만 paired bootstrap에서 차이는 통계적으로 유의하지 않다($p = 0.714$). Meta-
 246 Tool ST4에서도 Q-only +2.28pp와 ladapt +2.08pp의 차이 0.89pp는 유의미하지 않다($p =$
 247 0.298). 반면 telecom에서는 ladapt가 +26.76pp로 best signed-Q ($Q+0.10 +22.74pp$) 대비
 248 +4.03pp의 유의한 우위를 갖는다($p = 0.044$). airline $N=50$ 에서 ladapt는 +3.83pp($p =$
 249 0.165)로 점추정은 크지만 under-powered이다. 따라서 본 논문은 “ladapt가 모든 도메인에서
 250 이긴다”가 아니라, ladapt-vs-Q-only는 승패가 아니라 같은 연산자족의 regime-dependent
 251 배치이고, ladapt는 regime oracle 없이 택할 수 있는 강한 fallback이라고 주장한다.

252 표 3가 직접 지지하는 결론은 두 개다. 첫째, 정지 K-only 설계는 멀티-툴 논문의 중심 방법으로
 253 두기 어렵다. 둘째, layer-adaptive K+Q와 signed Q-only는 대체 관계가 아니라 같은 연산자족
 254 안에서 horizon에 따라 역할을 바꾸는 두 끝이다. 이 해석은 정리 4.4의 per-step 동등성과
 255 따름정리 4.5의 multi-step 비대칭에서 직접 따라온다. protocol-matched SEKA/AdaSEKA
 256 head-to-head와 PCA 기저 검증은 제출 직전 validation으로 분리해 부록 D에 정리한다.

257 retail을 GT action 수로 분해하면 두 연산자의 역할 분담이 드러난다. 표 4는 $N=114$ re-
 258 tail 전 샘플을 세 구간으로 나눈 결과로, 가장 짧은 ≤ 2 action 구간($n = 42$)에서 layer-
 259 adaptive가 +15.02pp로 Q-only의 +5.82pp 대비 +9.2pp 앞선다. medium 구간(3-5 actions,
 260 $n = 62$)에서는 방향이 반전되어 Q-only가 +4.43pp, ladapt가 +0.66pp로 Q-only가 우세하다.
 261 long 구간(≥ 6 actions, $n = 10$)에서도 Q-only +6.39pp가 ladapt +1.82pp를 앞선다. 즉 집계
 262 +0.94pp의 차이는 단순 overlap이 아니라 short-horizon ladapt 우위와 medium/long Q-only
 263 우위의 sample-weighted 평균이며, 같은 operator family가 레이어 배치만 바꿔 두 regime을
 264 모두 담아낸다는 직접 증거다. 이는 따름정리 4.5의 예측과 부합한다: K-bias는 KV-cache를 통해
 265 스텝마다 누적되므로 short-horizon에서 강하게 작동하지만 sequence가 길어질수록 그 누적
 266 효과와 Q-bias의 per-step 적용 대비 희석된다.

267 τ^2 -bench는 네 공식 도메인(retail, airline, telecom, banking)을 제공하지만 본 논문은 앞
 268 셋만 보고한다. banking의 97개 task 중 84개(86.6%)가 call_discoverable_agent_tool,

표 3: Qwen2.5-7B-Inst에 대한 네 도메인 성능. 핵심은 정지 K의 실패, layer-adaptive의 회복, 그리고 signed Q의 regime split이다.

도메인 (N)	방법	F1	Δ F1 vs no_steer	메모
MetaTool ST4 (497)	no_steer	0.7307	—	baseline
	정지 K a0.3	0.6850	−4.57	stationary K collapse
	Q-회전 $\beta = -0.03$	0.7535	+2.28	best overall
	레이어 적응형 K+Q	0.7514	+2.08	best K-using variant
τ^2 -retail (114)	no_steer	0.4679	—	baseline
	정지 K a0.05	0.4737	+0.58	weak gain only
	Q-회전 $\beta = -0.03$	0.5190	+5.11	strong Q−
	레이어 적응형 K+Q	0.5284	+5.98	best overall
τ^2 -telecom (200)	no_steer	0.2512	—	baseline
	정지 K a0.05	0.3691	+11.79	under-focused setting
	Q-회전 $\beta = -0.03$	0.4349	+18.37	strong Q−
	Q-회전 $\beta = +0.05$	0.4743	+22.32	also strong Q+
	Q-회전 $\beta = +0.10$	0.4785	+22.74	Q+ peak
	레이어 적응형 K+Q	0.5188	+26.76	best overall
τ^2 -airline (50)	no_steer	0.3285	—	baseline
	Q-회전 $\beta = -0.03$	0.3242	−0.43	signed Q alone insufficient
	레이어 적응형 K+Q	0.3669	+3.84	best overall

표 4: τ^2 -retail N=114을 GT action 수로 분해. Δ 는 no_steer 대비 F1 이득. short-horizon에서는 layer-adaptive가 우세하고, medium/long에서는 Q-only가 우세하다.

action 수 (n)	no_steer	Q-only $\beta=-0.03$	Δ	레이어 적응형	Δ
≤ 2 (42)	0.2770	0.3352	+5.82	0.4272	+15.02
3–5 (62)	0.5837	0.6280	+4.43	0.5903	+0.66
≥ 6 (10)	0.5515	0.6154	+6.39	0.5697	+1.82

unlock_discoverable_agent_tool, transfer_to_human_agents 계열 meta-tool을 포함하며, 이 도구들은 실행 시점에 동적으로 discover되거나 정책 라우팅을 수행한다. 정적 온톨로지 기저는 런타임 노출되는 도구를 미리 담을 수 없고, human-escalation은 도구 선택이 아니라 정책 판정이다. 따라서 본 논문의 문제 정의(정적 facet ontology 위의 tool selection)와 banking 전체는 구조적으로 어긋나며, 본문은 banking을 scope 밖으로 둔다. meta-tool을 제외한 banking non-meta 서브셋($n=13$)에서 multipass 변형이 +5.64pp를 내는 관측은 scope 제한이 기저 문제가 아닌 과제 유형의 문제임을 보이지만, 이 결과는 본문의 중심 비교에서 빼고 부록으로 남긴다.

signed Q-only가 F1만 올리고 precision을 희생하는 “F1 gaming”이라는 의심은 다중 메트릭 비교로 배제된다. 표 5은 τ^2 -retail과 τ^2 -telecom에서 F1, Recall, GT $\subseteq$ Pred, nDCG를 동시에 본 결과로, Q-only $\beta=-0.03$ 는 네 지표 모두에서 no_steer를 앞선다. retail에서 Q-only는 F1 +5.11pp, Recall +3.11pp, GT $\subseteq$ P +4.39pp, nDCG +3.62pp이고, telecom에서는 F1 +18.37pp, Recall +23.47pp, nDCG +19.02pp로 coverage 관련 지표가 F1보다도 크게 오른다. Q-only의 이득이 precision 희생으로 포장된 F1-편향이 아니라 ground-truth 집합 자체의 커버리지가 확장된 결과임을 동시에 상승이 보인다.

ST4도 같은 방향을 보인다. baseline Exact은 0.5252이고 stronger Q-only 변형은 0.5332, early-K를 포함한 layer-adaptive 변형은 0.5473까지 오른다. 즉 ST4에서도 이득은 단순한 F1 포장보다 정답 집합을 더 정확히 맞히는 방향과 함께 움직인다.

본 방법이 Qwen2.5-7B에만 맞춘 결과인가라는 의문은 Llama-3.1-8B-Instruct 재실행으로 제한적으로 점검한다. 표 7는 동일한 온톨로지 파이프라인(도메인 JSON $\rightarrow$ per-(layer, head) 기저 $B_{\text{ont}} \rightarrow$ 동일 hook 스케줄)으로 τ^2 -retail과 τ^2 -telecom을 다시 실행한 결과다. 여기서 load-bearing한 관찰은 telecom 한 축이다. Llama telecom의 레이어 적응형은 +11.62pp($p < 0.001$, paired bootstrap)로 no_steer 대비 유의하게 개선되며, Qwen telecom의 +26.76pp와 부호는 같고 규모는 작다. 다만 최적 signed-Q 부호는 Qwen과 반대다: Llama telecom의 best는 $\beta=-0.05$ +16.29pp로 음의 방향이 이기고, Qwen telecom의 best $\beta=+0.10$ 과 정반대다. 따라서 현재 데이터가 지지하는 cross-model 서술은 “operator family는 under-focused telecom regime에서 전이되지만 최적 polarity는 (model, domain)-specific”까지다. Llama retail에서는 어떤 steering도 유의미한 이득을 내지 않는다. 레이어 적응형 −1.69pp는 paired boot-

표 5: τ^2 -retail (N=114)과 τ^2 -telecom (N=200)에서 다중 메트릭 동시 비교. Q-only는 F1뿐 아니라 Recall, GT $\subseteq$ Pred, nDCG가 같이 오른다.

도메인 / 방법	F1	Recall	GT $\subseteq$ P	nDCG
retail no_steer	0.4679	0.5571	0.2456	0.5093
retail Q-only $\beta=-0.03$	0.5190	0.5882	0.2895	0.5455
retail 레이어 적응형	0.5284	0.6392	0.2895	0.5701
telecom no_steer	0.2512	0.2166	0.0350	0.2530
telecom Q-only $\beta=-0.03$	0.4349	0.4513	0.0350	0.4432
telecom Q-only $\beta=+0.10$	0.4785	0.5477	0.1100	0.5058
telecom 레이어 적응형	0.5188	0.6222	0.1500	0.5416

표 6: Llama-3.1-8B-Instruct에서 β 별 format-validity. empty는 pred_tools = $\emptyset$ 인 샘플 수. telecom은 baseline이 weak하여 $\beta+$ 가 format을 깨고, retail은 baseline이 강해 같은 magnitude에도 항상 parseable output을 유지한다.

method	telecom (N=200)		retail (N=114)	
	empty	F1	empty	F1
no_steer	0	0.385	0	0.506
$\beta=-0.05$ (telecom best)	0	0.547	0	0.488
$\beta=-0.03$	0	0.501	0	0.501
$\beta=+0.01$	0	0.385	0	0.505
$\beta=+0.03$	145	0.130	0	0.504
$\beta=+0.05$	200	0.000	0	0.516
$\beta=+0.10$	55	0.255	0	0.519
레이어 적응형	0	0.501	0	0.489

strap $p = 0.207$, 95% CI $[-4.37, +0.93]$ 으로 0을 포함해 no_steer와 구별되지 않으며, 이는 Llama retail의 no_steer F1 0.5059가 Qwen의 0.4679보다 높아 남은 ceiling이 작은 baseline-ceiling 효과와도 정합적이다.

Llama telecom의 positive- β cell은 의미적 실패가 아닌 format-stability collapse를 드러내며, 이 현상은 baseline 난이도에 의존한다. 표 6는 Llama 두 도메인에서 β 별 empty 출력 비율과 F1을 병렬로 둔다. telecom($\beta=+0.05$)에서는 200/200 샘플이 pred_tools empty로 반환되고 $\beta=+0.03$ 에서 145/200, $\beta=+0.10$ 에서 55/200으로 progressive collapse 패턴을 보인다. 반면 Llama retail은 모든 β 에서 empty 비율이 0으로, 같은 모델이라도 baseline F1이 이미 높으면(0.506) 동일 magnitude의 positive rotation이 parseable output을 깨뜨리지 않는다. 즉 format collapse는 “Llama-특이적 버그”가 아니라 baseline F1이 weak한 regime(0.385)에서 positive Q-rotation이 생성 분포를 off-manifold로 밀어내는 baseline-conditional 현상이며, 레이어 적응형의 비대칭 스케줄(K 는 $L/4$ 레이어에만, Q 는 전 레이어에 $|\beta| = 0.03$ 수준으로)은 이 magnitude regime을 피해 가는 implicit calibration을 제공하는 것으로 해석된다. 이것이 Llama에서 signed-Q polarity가 flip되어도 레이어 적응형은 안전하게 같은 방향의 이득을 유지하는 cross-model 전이의 기반이다.

정리 4.6는 $\beta = 0$ 근방에서 $Q+$ 와 $Q-$ 중 어느 방향이 locally helpful한지 판정한다. 우리는 이를 본문에서 배포 알고리즘이 아니라 사후 해석용 진단으로 사용한다. 이유는 명확하다. 본 실험에서 $\mathcal{G}$ 는 평가 데이터의 정답 도구 이름으로 구성된 proxy 집합이므로, 현재 형태의 계산은 offline analysis에는 적절하지만 deployment claim으로 쓰기에는 강하다. 따라서 표 2은 “부호를 자동 선택했다”는 증거가 아니라, 왜 telecom은 $Q+$ 이고 retail과 MetaTool은 $Q-$ 인지 설명하는 분석 도구로 읽어야 한다.

Algorithm 1 Signed Q 부호 진단 (offline analysis)

Require: 질의 q , 온톨로지 사영 $P_{\text{ont}} = BB^\top$, proxy GT 집합 $\mathcal{G}$, 강도 $|\beta|$

- 1: baseline forward로 $p_0(t) = \text{softmax}(qK^\top/\sqrt{d})_t$ 와 $r_t = \frac{1}{\sqrt{d}}\langle BB^\top q, k_t \rangle$ 계산
- 2: $\bar{r} \leftarrow \sum_t p_0(t)r_t$, $\bar{r}_{\mathcal{G}} \leftarrow \frac{1}{\sum_{t \in \mathcal{G}} p_0(t)} \sum_{t \in \mathcal{G}} p_0(t)r_t$
- 3: $\beta \leftarrow |\beta| \cdot \text{sign}(\bar{r}_{\mathcal{G}} - \bar{r})$
- 4: 진단된 부호와 실제 sweep 결과를 비교한다

표 7: Llama-3.1-8B-Instruct cross-model 재현. Qwen과 동일한 온톨로지 파이프라인으로 τ^2 retail (N=114)과 telecom (N=200)에서 재실행. telecom은 Qwen regime이 재현되고, retail은 baseline이 이미 높아 steering room이 작다.

도메인 (N)	방법	F1	$\Delta F1$	메모
τ^2 -retail (114)	no_steer	0.5059	—	baseline (Qwen 0.47보다 높음) best, noise 수준 regime mismatch
	Q-회전 $\beta=+0.10$	0.5190	+1.32	
	레이어 적응형 K+Q	0.4890	-1.69	
τ^2 -telecom (200)	no_steer	0.3845	—	baseline best overall, sign 보존 $\beta+$ 방향은 Llama에서 붕괴 Qwen telecom과 같은 방향
	Q-회전 $\beta=-0.05$	0.5474	+16.29	
	Q-회전 $\beta=+0.05$	0.0000	-38.45	
	레이어 적응형 K+Q	0.5007	+11.62	




그림 1: 포지션별 hit rate (Qwen MetaTool Subtask4). 정지 K-계열의 repeated_first 상승과 우리 연산자의 감소가 정리 4.2의 직접 확증이다.

추가 계산량은 $O(TdrH)$ 의 내적 한 번이며, $\mathcal{G}$ 는 MetaTool의 경우 정답 도구 이름 토큰 집합, τ^2 의 경우 `evaluation_criteria.actions`에서 추출한 도구 이름을 쓴다. 다시 말해 이 절의 목적은 label-free routing claim이 아니라 regime explanation이다.

표 2의 결과는 3개 도메인에서 직관과 일치하고, airline은 mixed boundary case로 남는다. 이 sign 진단은 도메인마다 signed-Q의 유리한 방향이 왜 다른지 설명하는 regime 해석 도구로 사용되며, 실제 배치에서는 layer-adaptive를 강한 fallback으로 두고 signed Q를 regime-specific peak 변형으로 읽는 것이 현재 데이터와 가장 잘 맞는다.

정리 4.2의 관측 가능한 예측은 정지 key-side에서 repeated_first_tool_rate이 no_steer보다 올라간다는 것이다. eval_metatool_subtask4.py의 stepwise 블록은 per-sample JSON에 네 포지션 지표를 저장하므로, 추가 실행 없이 원인을 분해할 수 있다. 그림 1와 표 8은 MetaTool Subtask4 N=497 결과를 담는다. 핵심은 정지 K에서 repeated_first가 증가하고, Q-회전과 layer-adaptive에서는 같은 지표가 감소하며 second_distinct가 오른다는 점이다. 특히 layer-adaptive는 “반복을 지우는 Q”와 “초기 각인을 주는 K”가 동시에 작동해 first/second hit를 함께 끌어올린다.

5.2 효율성과 구현 비용

성능 이득을 얻는 비용도 중요하다. 표 9는 본 방법을 tool-aware 파인튜닝, 프롬프트 스캐폴딩, KV-cache 최적화, 정지 활성 스티어링과 비교한다. layer-adaptive K+Q는 추론 시 hook으로 동작해 학습 비용과 토큰 오버헤드가 모두 0이며, 저장은 per-head 기저 (L, H_{kv}, d, r)만 추가한다. Qwen2.5-7B ($L=28, H_{kv}=8, d=128, r=24$) 기준 약 2.6 MB다. 주 결과 절에서 본 signed-Q 진단은 offline analysis이므로, 표의 효율성 비교는 주 방법인 layer-adaptive와 signed Q hook 자체를 기준으로 해석하는 것이 맞다.

성능 측면 (§ 5.1)의 MetaTool +2.08pp, Retail +5.98pp, Telecom +26.76pp, Airline +3.84pp와 결합하면, 본 연산자측은 파인튜닝 없이도 의미 있는 멀티-툴 이득을 제공한다. 특기할

표 8: MetaTool Subtask4 N=497 포지션별 hit rate. 화살표는 정리 예측 방향.

방법	first_hit	second_hit	second_distinct	repeated_first ↓
no_steer	baseline	baseline	baseline	baseline
canonical SEKA amp=1.0	≈	↓↓	↓↓	↑↑
정지 K a0.3	≈	↓↓	↓↓	↑↑
Q-회전 $\beta = -0.03$	≈	↑	↑	↓
레이어 적응형 K+Q	↑	↑↑	↑↑	↓

표 9: 효율성 비교. 주 방법은 layer-adaptive K+Q와 signed Q hook이다.

접근	학습 비용	토큰 오버헤드	지연 오버헤드	저장
Tool-aware 파인튜닝 (Gorilla)	$\mathcal{O}(\text{일})$	0	0	전체 모델
프롬프트 스캐폴딩 (ReAct)	0	+200 ~ 500 토큰	선형	0
KV-cache 최적화 (KIVI)	0	0	소폭 감소	캐시 -30%
정지 활성 스티어링 (SEKA)	사영 학습($\mathcal{O}(\text{분})$)	0	소폭 증가	사영 행렬
본 논문 (layer-adaptive / signed Q)	0	0	소폭 증가	≈ 2.6 MB

341 점은 KV-cache 최적화와 직교 결합 가능하다는 점이다. KIVI 등이 캐시를 압축하는 동안 본 방법은
342 같은 캐시 위에서 과제 수준의 선택을 바꾼다.

343 6 논의

344 본 논문의 결론은 한 문장으로 요약된다. 멀티-툴 도구 선택에서 중요한 것은 “더 강한 정지 K”가
345 아니라 “K를 어디까지 허용할 것인가”이며, 초기 K와 전역 Q를 분리한 layer-adaptive 스케줄은
346 정지 활성 스티어링의 반복 편향을 우회하는 가장 강한 락된 K-포함 반례다. § 5는 이 설계가 Meta-
347 Tool Subtask4에서 정지 K의 -4.57pp 붕괴를 $+2.08\text{pp}$ 회복으로 뒤집고, τ^2 세 도메인 모두에서
348 Q-only를 match 또는 beat하며, 특히 telecom에서 $+4.03\text{pp}$ 의 유의한 우위($p = 0.044$)를 얻음을
349 보였다. 이 절은 결과 해석에 걸릴 수 있는 네 가지 반론을 검토하고, paired bootstrap으로 드러난
350 layer-adaptive-vs-Q-only의 실제 관계를 정리한 뒤, 한계와 함의를 남긴다.

351 첫 반론은 “이득이 연산자 설계가 아니라 특정 기저를 얻은 덕분”이라는 주장이다. 이 주장이
352 맞다면 기저 방향을 바꿔도 이득이 어느 정도 유지되어야 한다. 표 10의 결과는 반대를 보인다.
353 feature-shuffled(facet 열을 무작위 순열)와 random orthonormal을 쓰면 정지 K는 MetaTool
354 Subtask4에서 F1 0으로 완전히 붕괴하는 반면 원래 기저에서는 -4.57pp 의 “온전한 음의 효과”를
355 유지한다. Q-회전은 기저 품질에 덜 민감해 $F1 \geq 0.7068$ 로 비교적 견고하다. 두 연산자가 기저
356 민감도에서 서로 다른 패턴을 보인다는 사실 자체가 “기저 품질 덕분”이라는 단일 원인 설명을
357 배제한다. PCA-of-K 기저는 진행 예정이며, 결과에 따라 본 논문의 “카탈로그 온톨로지가 필수”는
358 강한 해석 또는 “저랭크 구조가 필요하되 카탈로그가 최적”의 약한 해석으로 조정된다.

359 둘째 반론은 “real 기저가 null control보다 교란을 덜 주기 때문에 안전한 것”이라는 주장이다.
360 교란의 크기를 직접 측정하면 정반대 패턴이 관측된다. 표 11는 Qwen L=13, $\alpha = 0.3$, N=30에서
361 측정된 실제 attention perturbation magnitude를 보여 주는데, real 기저가 평균 621.30으로
362 가장 크고 random이 399.56, feature-shuffled가 291.98로 그 뒤를 잇는다. real 기저는 더 크게
363 교란하는데도 K-side 안정성은 real에서만 유지된다. 따라서 real 기저가 이기는 이유는 약해서가
364 아니라 특정한 안정 부분공간에 정렬되어 있기 때문이다.

365 셋째 반론은 “Q-회전이 일종의 confidence booster라면 $|\beta|$ 가 클수록 좋아야 한다”는 주장이다.
366 β sweep은 이 해석을 배제한다. 그림 2에서 Qwen Subtask4의 Q-only 곡선은 $\beta \approx -0.1$
367 근방에서 최고이고 $\beta = -0.7$ 에서는 F1이 0으로 완전히 붕괴한다. 좁은 유효 구간은 “큰
368 $|\beta|$ 일수록 좋다”와 어긋나며, 특정 크기의 부분공간 사영만이 coverage를 돕는다는 해석과
369 부합한다. 정리 4.6의 일차 진단도 전역 최대가 아니라 원점 근방의 개선 방향만을 예측한다는 점에서
370 이 좁은 구간 관측과 일관된다. 다만 이 정리의 부호 예측기는 현재 경험적 검증 단계에 있으며 스키마-
371 $\mathcal{G}$ 변형은 τ^2 Telecom에서 실패하므로, 본문의 해석은 정리를 “액면 그대로 배포 가능한 예측기”가
372 아닌 regime 설명 도구로만 쓴다(부록 A.5).

373 넷째 반론은 “정리 4.7의 교란 경계는 공허한 부등식일 수 있다”는 주장이다. 경험적 측정이
374 이를 반박한다. Qwen L=13에서 $\alpha = 0.3$ 정지 K 개입, N=100, 2800 head-query 조합에 대해
375 측정된 좌변/우변 비율은 중앙값 2.36×10^{-8} , pass rate 100%로, bound가 매우 보수적이지만
376 안정적으로 성립한다. 이것은 Q-측과 K-측 개입을 같은 척도로 비교할 때 정리가 정보적 진단 역할을
377 함을 뒷받침한다. 보조 증거로 단일 도구 체제의 대조 결과가 주장을 반대 방향에서 강화한다. Meta-

표 10: Qwen2.5-7B Subtask4 N=497, 기저 $\times$ 연산자. 굵은 값 locked.

기저	Q-회전 F1	정지 K F1
Real B (ours)	0.7471	0.6850
Feature-shuffled	0.7254	0.0000
Random orthonormal	0.7068	0.0000

표 11: Qwen L=13, $\alpha = 0.3$, N=30 effective attention perturbation magnitude.

기저	평균	중앙값	표준편차
Real B (ours)	621.30	593.71	317.59
Random orthonormal	399.56	360.01	235.86
Feature-shuffled	291.98	241.87	169.97

Tool Subtask1에서 정지 K-bias($\alpha = 0.3$)가 Qwen에 +11.16pp의 큰 양의 이득을 준다. 도구가 하나뿐이면 “첫 선택 반복”이 해롭지 않고 오히려 도움이 되며, 이것이 SEKA 계열이 단일 개념 편집에서 강한 이유와 일치한다. 본 연구의 layer-adaptive 연산자는 SEKA의 범용 대체가 아니라 멀티-툴 과제에 특화된 설계다.

반론들이 배제된 뒤 남은 질문은 “그래서 layer-adaptive와 Q-only는 어느 쪽이 이기는가”이고, paired bootstrap이 주는 답은 “둘은 같은 operator family 안의 서로 다른 regime을 담당한다”이다. Qwen retail에서 ladapt가 Q-only보다 +0.94pp 앞서지만 $p = 0.714$ 로 통계적 차이는 없고, MetaTool ST4에서는 Q-only가 0.89pp 앞서지만 $p = 0.298$ 로 마찬가지다. 유일하게 유의한 차이는 telecom에서 ladapt가 Q-only를 +4.03pp($p = 0.044$) 앞서는 case다. 즉 어느 연산자가 uniformly 이긴다는 주장도 데이터가 지지하지 않는다. 그러나 retail 내부를 action 수로 분해하면 두 연산자의 보완 관계가 드러난다. ≤ 2 action 구간에서 ladapt가 Q-only를 +9.2pp 앞서고, 3-5와 ≥ 6 action 구간에서는 Q-only가 ladapt를 3-4pp 앞선다. K-bias는 KV-cache를 통해 스텝마다 누적되므로 short-horizon에서 강하지만 sequence가 길어질수록 per-step Q-bias에 자리를 내준다. 따라서 ladapt의 실용적 의미는 “regime 오라클 없이도 쓸 수 있는 강한 fallback”이며, Q-only를 버리는 이유가 아니라 Q-only와 함께 같은 operator family의 양 끝을 구성하는 동반 선택지다.

Llama-3.1-8B-Instruct로의 model-family 전이가 이 operator family 해석을 공격당할 수 있는 가장 선명한 지점인데, 결과는 전이를 narrow하게 지지한다. Llama telecom ladapt +11.62pp($p < 0.001$)는 Qwen telecom의 +26.76pp와 같은 방향으로 재현되지만, Llama telecom의 best signed-Q는 $\beta = -0.05$ 로 Qwen의 $\beta = +0.10$ 과 부호가 반대다. 더 두드러진 점은 $\beta \geq +0.03$ 에서 Llama가 200개 중 145-200개의 empty 출력을 내며 tool-call 포맷 자체가 무너지는 것이다. 이것은 의미적 오선택이 아니라 format-stability collapse이고, layer-adaptive의 비대칭 스케줄(K를 $L/4$ 레이어에만, Q를 $|\beta| = 0.03$ 수준으로 전 레이어에)이 이 magnitude regime을 피해 가는 implicit calibration을 제공하는 것으로 해석된다. 따라서 “operator family는 cross-model 전이되지만 polarity와 magnitude는 (model, domain)-specific이며, ladapt의 역할은 polarity calibration 없이도 안전하게 동반 가능한 default”라는 해석이 현재 data와 가장 잘 부합한다.

네 반론과 transfer 분석 뒤에도 남은 한계는 있다. 본 연산자는 모두 history-free이므로 정리 4.2이 지정한 방출 상태 결여를 완전히 해소하지는 않는다. truly iterative state tracking이 필요한 multi-turn planner나 discoverable meta-tool setting은 본 논문의 범위 밖이다. signed-Q 부호 진단은 ground-truth proxy 집합 $\mathcal{G}$ 에 의존하므로 deployment-ready router claim으로 읽어서는 안 된다. format-stability collapse의 설명은 magnitude regime과 layer schedule의 복합 효과를 가정하지만, 이 두 기여의 분해는 아직 실험적으로 격리하지 않았다. 또한 protocol-matched SEKA/AdaSEKA head-to-head, PCA 기저 비교, layer boundary sweep은 아직 제출 직전 validation으로 남아 있다. 따라서 본문의 주장은 이미 략된 결과가 직접 지지하는 범위로만 제한해야 하며, pending 실험은 부록 D에서 별도로 정리한다.

함의 세 방향으로 확장된다. 정리 4.2은 정지 연산자라는 형식 자체를 겨냥하므로, ITI, CAA, PASTA, Focus Directions와 같은 기존 steering 기법도 표준적인 정지 배치 그대로 멀티-툴에 옮기면 비슷한 반복 편향을 보일 가능성이 있다. 따라서 본 논문의 더 일반적인 메시지는 “정지 스티어링을 멀티-툴에 가져오려면 state 또는 layer schedule이 필요하다”는 것이다. 실용적 take-away는 layer-adaptive가 regime 오라클 없이도 선택할 수 있는 default이고 Q-only는 특정 horizon에서 peak를 담당하는 동반 해라는 점이다. 후속 과제는 layer-adaptive를 진짜 multi-turn stateful operator로 확장하는 일과, format-stability collapse를 magnitude와 schedule 기여로 분해해 polarity calibration을 더 직접적으로 자동화하는 일이다.




그림 2: Qwen Subtask4 Q-회전 β sweep. 좁은 유효 구간은 confidence-boost 해석과 어긋난다.

7 결론

본 논문은 멀티-툴 도구 선택에서 실패하는 것은 steering 자체가 아니라 정지 K-style steering의 배치라는 점을 보였다. 핵심은 K를 더 세게 쓰는 것이 아니라, K를 초기 레이어의 정보 각인에만 사용하고 전 레이어의 coverage 조절은 Q에 맡기는 것이다. 이 설계는 MetaTool Subtask4에서 정지 K의 -4.57pp 붕괴를 같은 기저에서 $+2.08\text{pp}$ 회복으로 뒤집고, τ^2 세 도메인에서 $+5.98/+26.76/+3.84\text{pp}$ 를 기록한다. retail을 horizon으로 분해하면 layer-adaptive와 Q-only가 short vs long horizon에서 다른 우세 구간을 가지므로, 두 연산자는 경쟁 관계라기보다 같은 family 안의 regime-specific 끝점으로 읽는 것이 맞다. 정리 4.2과 따름정리 4.5는 왜 정지 K가 멀티-툴에서 반복 오류를 피하기 어렵고, 왜 per-step에는 동등한 Q가 multi-step에서는 더 안정적일 수 있는지를 설명한다. 남은 과제는 분명하다. protocol-matched SEKA/AdaSEKA 비교로 prior-work closure를 끝내고, PCA-of-K와 format-controlled Llama audit으로 ontology specificity와 failure mechanism을 더 직접적으로 달아야 한다. 그럼에도 현재 결과가 이미 말해 주는 바는 충분히 분명하다. 멀티-툴에서 중요한 것은 “더 강한 정지 steering”이 아니라 어느 깊이에서 어떤 쪽을 조작할 것인가다.

참고문헌

- Y. Huang et al. MetaTool: A benchmark for llm tool use. arXiv preprint, 2024.
- Kenneth Li, Oam Patel, Fernanda Viégas, Hanspeter Pfister, and Martin Wattenberg. Inference-time intervention: Eliciting truthful answers from a language model. arXiv preprint arXiv:2306.03341, 2023.
- Weixian Waylon Li, Yuchen Niu, Yongxin Yang, Keshuang Li, Tiejun Ma, and Shay B. Cohen. Spectral attention steering for prompt highlighting. In The Fourteenth International Conference on Learning Representations, 2026. URL <https://openreview.net/forum?id=XfLvGIFmAN>.
- Zirui Liu, Jiayi Yuan, Hongye Jin, Shaochen Zhong, Zhaozhuo Xu, Vladimir Braverman, Beidi Chen, and Xia Hu. Kivi: A tuning-free asymmetric 2bit quantization for kv cache. Proceedings of Machine Learning Research, 235:32332–32344, 2024.
- S. Patil et al. Gorilla: Large language model connected with massive apis. arXiv, 2023.
- Y. Qin et al. Toolllm: Facilitating large language models to master 16000+ real-world apis. ICLR, 2024.
- Yifu Qiu, Zheng Zhao, Yftah Ziser, Anna Korhonen, Edoardo Ponti, and Shay B. Cohen. Spectral editing of activations for large language model alignment. In The Thirteenth International Conference on Learning Representations, 2025. URL <https://openreview.net/forum?id=pqYceEa87j>.
- Sierra Research et al. τ^2 -bench: Multi-turn tool-use benchmark. arXiv preprint, 2025.
- Nina Rimsky, Noga Gabrieli, Sarel Obler, Tomer Lindsay, Amit Arbisser, and Bernardo Huberman. Steering language models with activation engineering. arXiv preprint arXiv:2308.10248, 2024.
- F. Yan et al. Berkeley function calling leaderboard. Gorilla LLM, 2024.

- 460 S. Yao et al. React: Synergizing reasoning and acting in language models. ICLR, 2023.
- 461 J. Zhang et al. xlam: A family of large action models to empower ai agent systems. arXiv, 2024a.
- 462
- 463 Qingru Zhang, Chandan Singh, Liyuan Liu, Xiaodong Liu, Bin Yu, Jianfeng Gao, and Tuo Zhao. Tell your model where to attend: Post-hoc attention steering for llms. In The Twelfth International Conference on Learning Representations, 2024b. URL <https://arxiv.org/abs/2311.02262>.
- 464
- 465
- 466
- 467 Youxiang Zhu, Ruochen Li, Danqing Wang, Daniel Haehn, and Xiaohui Liang. Focus directions make your language models pay more attention to relevant contexts. arXiv preprint arXiv:2503.23306, 2025.
- 468
- 469

470 A 증명

471 A.1 정리 4.6 완전 증명

472 증명은 네 단계로 진행되며, 가정은 (i) $P_{\text{ont}} = BB^\top$ 는 정사영, (ii) softmax는 실해석적, (iii) baseline이 ground-truth proxy 집합에 양의 질량을 둔다는 $\pi_G > 0$ 경계 조건뿐이다. 먼저 β -
 473 섭동된 query 아래 로짓과 softmax의 미분을 적는다. $Q_\beta := (I + \beta BB^\top)Q$ 로 두면 각 row는
 474 $q_\beta = (I + \beta BB^\top)q = q + \beta BB^\top q$ 이고, 로짓은 $\ell_\beta(t) = q_\beta^\top k_t / \sqrt{d} = \ell_0(t) + \beta r_t$ 이다.
 475 여기서 $r_t = \frac{1}{\sqrt{d}} \langle BB^\top q, k_t \rangle$ 는 β 에 독립인 per-token 점수이다. 따라서 $\partial_\beta \ell_\beta(t) = r_t$. $p_\beta(t) =$
 476 $\text{softmax}(\ell_\beta(\cdot))(t)$ 에 대해 softmax Jacobian $\partial p_\beta(t) / \partial \ell_\beta(s) = p_\beta(t)(\delta_{ts} - p_\beta(s))$ 를 체인룰로
 477 합성하면
 478

$$\partial_\beta p_\beta(t) = p_\beta(t) \left(\partial_\beta \ell_\beta(t) - \mathbb{E}_{p_\beta}[\partial_\beta \ell_\beta] \right) = p_\beta(t) (r_t - \mathbb{E}_{p_\beta}[r]). \quad (4)$$

479 $L(\beta) = \sum_{t \in \mathcal{G}} p_\beta(t)$ 에 (4)를 적용하고 $\beta = 0$ 에서 평가하면 $\mathbb{E}_{p_\beta}[r] \big|_{\beta=0} = \sum_t p_0(t) r_t = \bar{r}$ 이므로

$$\frac{dL}{d\beta} \bigg|_{\beta=0} = \sum_{t \in \mathcal{G}} p_0(t) (r_t - \bar{r}) = \sum_{t \in \mathcal{G}} p_0(t) r_t - \bar{r} \sum_{t \in \mathcal{G}} p_0(t).$$

480 $\pi_G = \sum_{t \in \mathcal{G}} p_0(t)$ 와 $\bar{r}_G = \frac{1}{\pi_G} \sum_{t \in \mathcal{G}} p_0(t) r_t$ 로 정리하면 $\frac{dL}{d\beta} \big|_{\beta=0} = \pi_G (\bar{r}_G - \bar{r})$ 이다. 경계 조건

481 $\pi_G > 0$ 아래에서 $\text{sign} \left(\frac{dL}{d\beta} \big|_{\beta=0} \right) = \text{sign}(\bar{r}_G - \bar{r})$ 이며, 따라서 원점 근방에서 L 을 증가시키는 국소
 482 방향은 $\bar{r}_G - \bar{r}$ 의 부호와 일치한다. $\square$

483 이 결과는 response = fluctuation 형태의 Callen-Welton 항등식으로 해석할 수 있다: GT
 484 질량의 β -민감도는 baseline 분포 하에서 GT 지시함수와 온톨로지-사영 점수 r_t 의 공분산이다.
 485 또한 이차 미분을 같은 논법으로 계산하면 $\frac{d^2 L}{d\beta^2} \big|_{\beta=0} = \pi_G (V_G - \text{Var}_{p_0}(r))$, 여기서 $V_G =$
 486 $\frac{1}{\pi_G} \sum_{t \in \mathcal{G}} p_0(t) (r_t - \bar{r}_G)^2$. 따라서 Taylor 전개가 음의 곡률을 가질 때 유한 최적 $\beta^* =$
 487 $-s / [\pi_G (\text{Var}_{p_0}(r) - V_G)]$ 이 존재하며, 두 경우 모두 $\text{sign}(\beta^*) = \text{sign}(s)$ 로 부호는 보존된다.

488 위 논증은 원점에서의 일차 최적성만 확립하고, 전역적으로는 $L(\beta)$ 의 비선형성과 softmax 포화
 489 때문에 최적 $|\beta|$ 가 따로 분석되어야 한다. 본문은 이 정리를 전역 최적화 정리로 쓰지 않고, 표 2의
 490 regime 해석 도구로만 사용한다. 또한 정리의 경험적 적용은 proxy 집합 $\mathcal{G}$ 의 정의에 민감하며, 그
 491 민감도는 부록 A.5에서 따로 다룬다.

492 A.2 정리 4.4와 따름정리 4.5 완전 증명

493 정리 4.4는 $P_{\text{ont}} = BB^\top$ 의 대칭성만 쓴다. 스텝 T 에서 query $q \in \mathbb{R}^d$ 와 key 행렬 $K \in \mathbb{R}^{T \times d}$ 를
 494 고정하고 scaled dot-product attention logit $\ell(t) = q^\top k_t / \sqrt{d}$ 를 쓴다. K-측 개입 아래 수정된
 495 key 행은 $k'_t = k_t + \alpha P_{\text{ont}}^\top k_t = k_t + \alpha P_{\text{ont}} k_t$ 이며, 따라서 새 logit은 $\ell'_K(t) = q^\top k'_t / \sqrt{d} =$
 496 $\ell(t) + (\alpha / \sqrt{d}) q^\top P_{\text{ont}} k_t$ 이다. Q-측 개입 아래 $q' = q + \beta P_{\text{ont}} q$ 이고 $\ell'_Q(t) = (q')^\top k_t / \sqrt{d} =$
 497 $\ell(t) + (\beta / \sqrt{d}) q^\top P_{\text{ont}}^\top k_t = \ell(t) + (\beta / \sqrt{d}) q^\top P_{\text{ont}} k_t$ 로, 대칭성 $P_{\text{ont}}^\top = P_{\text{ont}}$ 에서 $\ell'_K(t) - \ell(t)$ 와
 498 $\ell'_Q(t) - \ell(t)$ 는 $\alpha = \beta$ 일 때 모든 t 에 대해 동일하다. softmax가 logit의 함수이므로 attention
 499 분포도 동일하고, 같은 value 행렬 아래 출력도 동일하다. $\square$

따름정리 4.5는 이 per-step 동등성이 multi-step에서는 보존되지 않음을 보인다. 스텝 T 에서 K-측 개입이 캐시에 반영되면 캐시된 key는 $k_t^{\text{cache}} = k_t + \alpha P_{\text{ont}} k_t$ 로 고정된다. 후속 스텝 $s > T$ 에서 query q_s 는 새로 계산되지만 key는 캐시값을 재사용하므로 logit은 $\ell_s^{\text{cache}}(t) = q_s^\top k_t^{\text{cache}} / \sqrt{d} = q_s^\top k_t / \sqrt{d} + (\alpha / \sqrt{d}) q_s^\top P_{\text{ont}} k_t$ 이다. 개입 항은 $\alpha q_s^\top P_{\text{ont}} k_t / \sqrt{d}$ 로 모든 후속 스텝에 공통 인자 α 를 공유하며 누적 효과를 낸다. 반면 Q-측 개입 $q'_s = q_s + \beta P_{\text{ont}} q_s$ 는 스텝 s 에서 새로 적용되므로 logit 개입 항은 $\beta q_s^\top P_{\text{ont}} k_t / \sqrt{d}$ 로, 이전 스텝의 개입이 현재 스텝의 key 또는 query에 남지 않는다. 따라서 스텝 수 S 에 대해 K-측 누적 개입 크기 $|\sum_{s=T}^{T+S} \alpha q_s^\top P_{\text{ont}} k_t / \sqrt{d}|$ 는 일반적으로 S 에 따라 선형적으로 증가할 수 있는 반면 Q-측의 스텝별 기여는 S 와 무관하게 per-step $|\beta|$ 스케일로 제한된다. $\square$

이 두 결과는 layer-adaptive K+Q와 signed Q-only의 관계를 operator-family 수준에서 확정한다. per-step 동등성은 “같은 가족”이라는 주장의 수학적 근거이고, multi-step 비대칭은 왜 long-horizon에서 Q-only가 K-포함 스케줄을 앞서는지의 메커니즘이다. § 5의 retail 액션 수 분해 결과는 이 예측과 부합한다.

512 A.3 정리 4.7 증명

513 1단계. softmax는 실해석적이므로 ϕ 는 smooth, Taylor의 정리로 $\phi(1) - \phi(0) = \phi'(0) + \int_0^1 (1 -$
514 $\tau) \phi''(\tau) d\tau$. 2단계. softmax Jacobian $\partial s_t / \partial \ell_{t'} = s_t(\delta_{tt'} - s_{t'})$ 로 $ds_t(\tau) / d\tau = s_t(\tau)(\alpha_t -$
515 $\bar{\alpha}(\tau))$ 이고 $\phi'(0) = \sum_t s_t \alpha_t (v_t - o) = L(q, E)$ (정확 등식). 3단계. 직접 계산으로 $\phi''(\tau) =$
516 $\sum_t s_t(\tau)[(\alpha_t - \bar{\alpha}(\tau))^2 - \text{Var}_s \alpha(\tau)] v_t$. 4단계. 벡터 Cauchy-Schwarz로 $\|L\|^2 \leq \text{Var}_s \alpha(q) \cdot$
517 $\text{Var}_s[V](q)$, $|\alpha_t| \leq Q_{\max} \rho / \sqrt{d}$ 로 $\|R\|^2 \leq Q_{\max}^4 V_{\max}^2 \rho^4 / d^2$. $\square$

518 A.4 따름정리

519 **따름정리 A.1** (정지 K의 반복 편향). 그리디 디코딩 아래 첫 단계에 $t_1 \in T_{\text{gt}}$ 가 선택되고 t_1 이
520 온톨로지 부분공간에 정렬되면 정지 K가 t_1 의 logit을 $(1 + \alpha)$ 배로 증폭해 $\Pr[t_2 = t_1 \mid \text{stat}] \geq$
521 $\Pr[t_2 = t_1 \mid \text{no_steer}]$. $\alpha = 0$ 일 때 등호.

522 A.5 β^* 진단의 $\mathcal{G}$ 정의 민감도

523 정리 4.6은 $\beta = 0$ 근방의 일차 부호를 $\pi_{\mathcal{G}}(\bar{r}_{\mathcal{G}} - \bar{r})$ 로 환원하지만, 이 진단을 경험적으로
524 구현하려면 proxy 집합 $\mathcal{G}$ 를 고정해야 하고 그 선택에 따라 예측의 경험적 정합성이 달라진다. 본
525 절은 후보 세 변형을 나란히 놓고 어느 것이 현재 단계에서 검증된 진단인지, 어느 것이 열린 과제인지
526 투명하게 구분한다. 정리 자체의 수학적 타당성(식 (4)의 softmax gradient identity)은 $\mathcal{G}$ 의
527 정의와 무관하게 성립하며, 아래 논의는 어디까지나 이 정리를 “배포 가능한 부호 예측기”로 쓸 수
528 있느냐에 대한 범위 진술이다.

529 첫 번째 변형은 스키마- $\mathcal{G}$ 로, ground-truth 도구의 JSON 스키마 스펠에 속하는 토큰 집합을
530 그대로 $\mathcal{G}$ 로 쓴다. 이 정의는 본문 § 4의 표 2에 해석적으로 사용하는 정의이지만, 직접 측정
531 수준에서는 τ^2 Telecom의 경험적 부호(N=20 smoke test)를 재현하지 못한다. 구체적으로 Tele-
532 com에서는 모든 태스크가 음의 s 를 산출해 일정한 “-” 예측을 내는데, 경험적 우세 방향은 $\beta =$
533 $+0.05$ 이므로 N=20 상의 sign-agreement는 31.2%(locked)에 머문다. Retail의 동일 smoke
534 test(N=30)는 sign-agreement가 66% 수준으로 경계에 걸쳐 있으나, 이 값은 클래스 불균형의
535 부산물로 해석되어야 하며 스키마- $\mathcal{G}$ 가 Retail에서도 안정적 예측기라고 주장할 수 없다. 진단적
536 관측은 스키마 토큰에서 $\bar{r}_{\mathcal{G}}$ 가 $\bar{r}$ 보다 체계적으로 작게 나온다는 것인데, 이는 JSON 스키마 스펠이
537 prompt 전체 평균보다 온톨로지 측에 약하게 정렬되어 있기 때문이며, 따라서 단일 step 목적함수
538 $L(\beta) = \sum_{t \in \mathcal{G}} p_{\beta}(t)$ 가 생성 전 과정에 걸친 F1과 탈동조된다.

539 두 번째 변형은 logit-lens 판별적- $\mathcal{G}$ 이다. ground-truth 토큰을 유지하되, per-token 점수
540 r_t 대신 정답 도구 로짓의 β -민감도 $\partial_{\beta} \log p(v_{c^*} \mid y_{<T})$ 를 그대로 써서 s 를 정의한다. 이 변형은
541 Q, K 뿐 아니라 value 경로와 unembedding까지 단일 forward pass에서 포착하므로, 생성 F1과
542 더 밀접하게 정렬될 것으로 기대된다. 본 논문은 이 변형을 현재 실험 사이클에서 진행 중인 falsifi-
543 cation 테스트로 명시한다(현재 사이클, 결과 미확정). 즉 스키마- $\mathcal{G}$ 의 경험적 실패는 정리 자체의
544 반증이 아니라 proxy 선택의 문제이며, logit-lens 변형이 검증되기 전까지는 정리 4.6의 배포-
545 가능한 실용 부호 예측기는 “보류”로 분류한다.

546 세 번째 변형은 generation-step 전 위치 집계로, 단일 step $T-1$ 이 아닌 생성되는 모든 도구
547 토큰 위치에서 s 를 집계한다. 이 변형은 멀티-툴 상태 전이 과정에서 coverage 방향이 step마다
548 달라질 수 있다는 구조적 관찰과 부합하고, 정리 4.2의 history-free 한계와도 자연스럽게 결합된다.
549 검증 여부는 logit-lens 변형과 함께 후속 작업으로 남긴다.

550 요약하면, 정리 4.6는 regime 해석 도구로는 표 2에서 네 도메인 중 Airline을 제외한 세
551 도메인의 부호 방향과 정성적으로 일치하지만, 스키마- $\mathcal{G}$ 를 통한 직접 측정은 τ^2 Telecom(31.2%,

locked)에서 실패하고 Retail에서도 경계이다. 본 논문은 이 한계를 투명하게 기록하고, 실용적 부호 예측기 주장은 logit-lens 변형의 검증 이후로 미룬다.

B MetaTool ST4 보조 지표

MetaTool ST4에서는 F1 외에도 Exact가 같은 방향으로 움직인다. 본문에서 쓰는 baseline과 stronger 변형을 같은 evaluator에서 비교하면 baseline Exact은 0.5252이고, stronger Q-only 변형은 0.5332, early-K를 포함한 layer-adaptive 변형은 0.5473이다. 즉 ST4에서도 이득은 “정답 도구 집합을 정확히 맞추는가”라는 더 엄격한 지표와 함께 증가한다.

표 12: MetaTool ST4 보조 지표. stronger Q-only와 early-K layer-adaptive 모두 Exact을 함께 끌어올린다.

방법	F1	Exact
no_steer	0.7307	0.5252
Q-only (stronger, $\beta = -0.03$)	0.7535	0.5332
레이어 적응형 (early-K variant)	0.7514	0.5473

C Signed Q 진단의 G-robustness

알고리즘 1은 proxy ground-truth 집합 $\mathcal{G}$ 정의에 의존한다. $\mathcal{G}$ 를 세 가지 대안으로 정의해 robustness를 측정한다: (i) 도구 이름 단일 토큰, (ii) 도구 이름 전체 토큰 스패의 평균, (iii) 정답 액션 스트링 전체. 세 정의 모두에서 표 2의 방향 진단이 4개 도메인 중 3개(Airline 제외)에서 유지되면 $\mathcal{G}$ 정의에 대한 민감도가 낮다고 볼 수 있다. Airline처럼 경계적인 사례는 현재 데이터만으로 부호를 강하게 해석하기보다, 본문이 채택한 layer-adaptive 기본해와 함께 읽는 것이 더 안전하다.

D 추가 검증 축

본 절은 본문 서사를 뒤집기보다 더 좁게 검증하기 위해 남겨 둔 추가 축을 정리한다. 핵심은 세 가지다. 첫째, stationary K-family에 대한 protocol-matched head-to-head가 있어야 related-work 반론을 직접 달 수 있다. 둘째, Llama telecom의 positive- β 붕괴를 failure type으로 분해하면 cross-model 논의가 더 선명해진다. 셋째, PCA-of-K 비교가 있어야 “아무 저랭크 기저”가 아니라 ontology-aligned basis가 중요한지 더 정확히 말할 수 있다.

표 13: 추가 검증 측과 현재 anchor. 본문 해석을 유지한 채 더 직접적인 반론을 담기 위한 항목만 남겼다.

ID	질문	설정	현재 anchor
V1	SEKA/AdaSEKA를 동일 evaluator에서 공정 비교해 stationary K-family 반론을 직접 달을 수 있는가	Qwen2.5-7B, MetaTool ST4 / τ^2 retail / τ^2 telecom	현재 stationary K는 각각 $-4.57pp$, $+0.58pp$, $+11.79pp$ 로 충분히 약하다. 다만 이 수치만으로 SEKA-family 전체를 대표한다고 말하기에는 부족하다.
V2	ontology basis가 “아무 저랭크 기저”보다 실제로 더 적합한가	Qwen2.5-7B, PCA-of-K vs ontology, MetaTool ST4 / retail	shuffled/random control은 이미 열세이며, 남은 질문은 PCA가 ontology와 얼마나 가까운지다.
V3	positive- β Llama telecom 붕괴는 semantic error보다 format failure에 가까운가	Llama-3.1-8B, τ^2 telecom, $\beta \in \{+0.03, +0.05, +0.10\}$ verbose audit	empty 출력은 각각 145/200, 200/200, 55/200으로 이미 크다. 필요한 것은 raw generation 수준의 failure taxonomy다.
V4	$L/4$ 경계는 우연한 하이퍼파라미터가 아니라 역할 분리의 최소 구현인가	Qwen2.5-7B, layer-boundary sweep, ST4 / retail	현재 본문은 early-K baseline 하나만 락되어 있으므로, 경계 선택의 민감도는 별도 표로 분리하는 편이 맞다.
V5	7B 결과가 model-size artifact가 아닌가	Qwen2.5 1.5B / 3B / 14B, ST4 + telecom 핵심 셀	지금의 main claim은 7B와 Llama telecom 재현으로도 서지만, 추가 size sweep이 reviewer comfort를 높일 수 있다.