

온톨로지 부분공간 위의 회전 기반 스티어링: 멀티-툴 도구 선택을 위한 훈련-없는 Q-커버리지와 레이어 적응형 K+Q

Anonymous Author(s)

Affiliation

Address

email

초록

멀티-툴 도구 호출을 강화하는 기존 네 가지 접근 — tool-aware 파인튜닝, 프롬프트 스캐폴딩, KV-cache 최적화, 활성 스티어링 — 은 각각 학습 비용과 과제 수준 표적화 사이의 서로 다른 trade-off를 가진다. 본 논문은 네 번째 접근에 속하는 훈련-없는 회전 기반 스티어링을 제시한다. 방법은 도구 카탈로그에서 직접 유도한 per-head 온톨로지 부분공간 P_{ont} 위에서 두 개의 history-free 연산자로 구성된다. 첫 번째는 질의를 이 부분공간에서 축소하는 Q-커버리지 $Q' = Q + \beta QP_{\text{ont}}$ ($\beta < 0$), 두 번째는 초기 $\lfloor L/4 \rfloor$ 레이어에만 K-측 회전을 더하고 전 레이어에 Q-커버리지를 적용하는 레이어 적응형 K+Q이다. 두 연산자는 가장 가까운 선행 방법인 SEKA와 AdaSEKA가 공유하는 정지 key-side 증폭 형식과 달리, 현재 부분공간에서 이미 지배적인 방향으로 덜 이동하도록 attention을 회전시킨다. 이 설계 차이가 멀티-툴에 왜 중요한지는 정지 형식이 방출된 도구 상태를 구조적으로 담을 수 없다는 명제로 정리되며(정리 3.1), 그 구조적 귀결이 데이터의 `repeated_first_tool_rate` 상승이라는 관측 가능한 예측으로 이어진다. 두 개의 중심 주장은 다음과 같다. 먼저 도구 선택 성능 측면에서, Qwen2.5-7B-Instruct에 대해 MetaTool Subtask4와 τ^2 -bench retail에서 동일한 프롬프트/스코어/디코딩 프로토콜 아래 본 연산자는 SEKA와 AdaSEKA 대비 일관된 이득을 보이고, 이 이득은 집계 F1이 아니라 포지셔널 분해에서 분명히 해석된다 (§ 4). 다음으로 효율성 측면에서, 본 방법은 가중치 학습이나 프롬프트 확장 없이 추론 시 저랭크 hook으로만 작동하므로 tool-aware 파인튜닝 대비 학습 비용이 0이고, 프롬프트 스캐폴딩 대비 토큰 오버헤드가 0이며, KV-cache 최적화 계열과 달리 과제 수준의 선택 개선을 제공한다 (§ 5). 카탈로그 온톨로지 기저를 feature-shuffled, random, PCA-of-K 세 대안으로 교체하면 효과가 사라져, 이득이 기저 품질이 아니라 연산자 설계 자체에서 옴을 분리한다.

1 서론

LLM 에이전트가 실전에서 유용하려면 한 질의에 여러 도구를 순차적으로 호출할 수 있어야 한다. “뉴스에서 주식 기사 찾아 요약해줘”라는 요청 하나에 NewsTool과 ResearchHelper를 순서대로 부르지 못하면, single-call 벤치마크에서의 높은 점수는 실전 가치와 연결되지 않는다. 이 멀티-툴 능력을 강화하는 길은 지금까지 네 방향으로 나뉘어 왔고, 각각 서로 다른 비용-표적 trade-off를 가진다.

대량의 도구 호출 예시로 모델을 직접 finetuning하는 방법(Gorilla [Patil et al., 2023], ToolLlama [Qin et al., 2024], xLAM [Zhang et al., 2024a])은 성능은 강하지만 가중치 수정이 필요해 카탈로그가 바뀔 때마다 재학습 비용을 치러야 한다. 프롬프트 스캐폴딩(ReAct [Yao et al., 2023] 등)은 학습이 필요 없는 대신 프롬프트 길이에 따라 비용이 선형 증가하고 도구 수가 늘면 빠르게 열화된다. 도구 스키마를 효율적으로 캐시하는 KV 최적화 계열(KIVI [Liu et al., 2024b] 등)은 추론 시간을 줄이는 데 집중하여 “무엇을 고를지”라는 과제 수준의 결정에는 직접 개입하지 않는다. 네 번째 방향이 본 논문이 속하는 활성 스티어링이다. 추론 시 attention에 저랭크 개입을 주입하여

표 1: 멀티-툴 호출을 개선하는 네 가지 접근과 본 논문의 위치. 학습 비용, 과제 수준 제어 여부, 방출 상태 표현 여부, 추론 오버헤드의 네 축에서 비교한다.

접근	대표 방법	학습 free	멀티-툴 표적	방출 상태
Tool-aware finetuning	Gorilla, ToolLlama, xLAM	×	✓	✓
Prompt scaffolding	ReAct, ToT	✓	✓ (프롬프트)	프롬프트
KV cache 최적화	KIVI, StreamingLLM	✓	×	×
활성 스티어링(정지)	SEKA, AdaSEKA, ITI, CAA, PASTA	✓	× (단일 개념)	×
본 논문	Q-coverage, Layer-adaptive K+Q	✓	✓ (부호 반전)	history-free 근사

가중치도 프롬프트도 건드리지 않고 행동을 조정하며, 파인튜닝보다 저렴하고 프롬프트 방법보다 표적화되어 있다. 표 1이 이 네 방향과 본 논문의 위치를 한눈에 정리한다.

표 1이 드러내는 핵심은 세 번째와 네 번째 열이다. 기존 활성 스티어링 방법들은 학습 비용을 치르지 않는다는 장점을 공유하지만, 어느 방법도 지금까지 방출한 도구 정보를 담지 않는다. 가장 가까운 선행 방법인 SEKA [Li and Others, 2025b]와 그 확장 AdaSEKA [Li and Others, 2025a]는 $k' = k + \alpha Pk$ 형태의 정지 key-side 증폭을 쓰는데, 고정된 α 와 사영 P 는 정의상 디코딩 단계에도 방출 도구 집합에도 의존하지 않는다. 단일 개념 편집(CounterFact)에서는 이 “정지성”이 오히려 강점이지만, 멀티-툴에서는 같은 성질이 “첫 도구를 두 번째 단계에서 다시 증폭한다”는 행동을 만든다. 본 논문의 첫 번째 관찰은 이 현상이 튜닝 실패가 아니라 연산자 형식 자체의 귀결이라는 점이다. 정리 3.1이 이를 한 줄의 구조적 논증으로 고정한다.

이론이 흥미로운 이유는 그것이 데이터의 어느 위치에 흔적을 남길지 예측한다는 데 있다. 정리 3.1의 관측 가능한 귀결은 SEKA의 `repeated_first_tool_rate`이 `no_steel`보다 높게 측정되어야 한다는 것이다. 이 예측이 맞으면 SEKA의 F1 손실은 설계에 내장된 반복에서 오고, 해결은 SEKA를 더 정교하게 만드는 것이 아니라 “같은 방향으로 덜 가라”이다. 이 관찰은 key를 증폭하는 대신 query를 축소하는 부호 반전 연산자로 직결된다(정리 3.2).

본 논문의 기여는 두 축으로 정리된다. 도구 선택 성능 축에서 (§ 4) 우리는 Q-커버리지와 레이어 적응형 K+Q가 Qwen2.5-7B-Instruct에 대해 MetaTool Subtask4와 τ^2 -bench retail에서 동일한 프롬프트/스코어/디코딩 프로토콜 아래 SEKA 및 AdaSEKA 대비 일관된 이득을 낸다는 것을 보이고, 그 이득이 `repeated_first_tool_rate`의 감소라는 포지션별 footprint로 해석됨을 확인한다. 기저 절제(feature-shuffled, random, PCA-of-K)는 이 이득이 기저 품질이 아니라 연산자 설계에서 옴을 분리한다. 효율성 축에서 (§ 5) 본 방법은 가중치 학습이나 프롬프트 확장 없이 추론 시 hook으로만 작동하므로 파인튜닝 대비 학습 비용이 0, 프롬프트 스캐폴딩 대비 토큰 오버헤드가 0이며, 저장은 per-head 기저 (L, H_{kv}, d, r)만 추가로 든다(Qwen 7B 기준 ≈ 2.6 MB).

논문의 나머지는 이 두 축을 따른다. § 2에서 정지 스티어링 계열이 공유하는 구조적 빈자리를 지도화하고, § 3에서 설정과 세 핵심 정리를 경량화해 담는다(따름정리와 조건부 명제는 부록). § 4과 § 5가 두 중심 주장을 각각 지지한다. § 6은 이 결과가 다른 정지 스티어링 방법들에 대해 무엇을 함의하는지 논의한다.

2 관련 연구

본 논문의 위치를 이해하려면 기존 활성 스티어링 방법들이 공유하는 특정한 빈자리를 먼저 보는 것이 도움이 된다. SEKA [Li and Others, 2025b]와 AdaSEKA [Li and Others, 2025a]는 contrastive question-answer 쌍에서 학습한 저랭크 사영을 attention key에 주입하여 단일 개념 편집 벤치마크에서 state-of-the-art 성능을 달성한다. ITI [Li et al., 2023]와 CAA [Rimsky et al., 2024]는 residual stream에 activation direction을 더해 행동 분포를 바꾼다. PASTA [Zhang et al., 2024b]는 특정 토큰의 post-softmax attention weight를 직접 재조정하고, Focus Directions [Zhu et al., 2025]는 key와 query를 함께 조절해 관련 토큰에 집중하도록 유도한다. 이 방법들의 공통된 특징은 모두 추가 finetuning 없이 추론 시에만 개입한다는 점이며, 그 점이 이들이 매력적인 도구인 이유다. 그러나 같은 공통성 위에 또 하나의 공통성이 얹혀 있다. 어느 방법도 “지금까지 무엇을 방출했는지”에 대한 명시적 상태를 담지 않는다. 정지 key-side 증폭, residual direction, post-softmax 재조정, focus direction 모두 디코딩 단계와 무관한 고정된 변환이다. 정리 3.1은 이 공통된 성질이 왜 멀티-툴 과제에서 한계가 되는지를 기계론적으로 고정한다. 본 논문은 이 기존 방법들을 비판하기 위해서가 아니라, 그들이 차지하지 않은 설계 공간 — 부호 반전된 query 축소 — 을 분명히 드러내기 위해 이 사실을 사용한다.

본 논문이 기존 흐름과 갈라지는 지점은 세 가지로 요약할 수 있지만, 그 셋은 서로 독립적이지 않고 하나의 근본적 선택에서 파생된다. 근본적 선택은 “key를 증폭하지 말고 query를 축소하라”는

83 것이다. 첫째, 과제가 달라진다. 단일 개념 편집이나 prompt highlighting이 아니라, 한 질의에서
 84 두 개 이상의 도구를 순차적으로 복원해야 하는 multi-tool selection을 직접 평가한다. 이
 85 과제에서는 “이미 선택한 방향을 다시 증폭한다”는 행동이 단지 중립적이지 아니라 적극적으로 해롭다.
 86 둘째, 연산자의 위치와 부호가 달라진다. key를 더하는 대신 query에서 빼고, 양의 계수 대신 음의
 87 계수를 쓴다. 음의 Q-side projection은 이미 지배적인 온톨로지 성분을 눌러 거친 coverage pri-
 88 or로 작동하며, 정리 3.2이 이 기하를 정확히 고정한다. 셋째, 기저의 출처가 달라진다. SEKA는
 89 contrastive QA 쌍에서 P_{pos} 를 유도하지만, 본 논문은 도구 카탈로그의 4-facet 온톨로지를 Gram-
 90 Schmidt로 직교화해 B_{ont} 를 얻는다. 이 세 차이는 각각 독립적 기여가 아니라 “부호를 뒤집어
 91 query에서 빼라”는 한 선택의 세 측면이다.

92 벤치마크 선택은 이 서사를 지원하도록 좁게 이루어진다. MetaTool Subtask4 [Huang et al.,
 93 2024]은 각 질의에 정확히 두 개의 정답 도구를 지정한 497개의 프롬프트로 구성되어, 순차 cover-
 94 age를 가장 깨끗하게 측정할 수 있는 벤치마크다. τ^2 -bench retail [Research et al., 2025]은 정답
 95 도구 수가 0에서 13까지 분포하여 “짧은 시퀀스”와 “긴 시퀀스” 체제가 같은 벤치마크 안에 공존한다.
 96 이것이 regime-split을 측정 가능하게 만든다. BFCL [Yan et al., 2024]의 parallel/multiple
 97 subset은 병렬 도구 호출의 공식 벤치마크로 교차 검증에 쓰인다. KV-cache compression [Liu
 98 et al., 2024a]은 본 논문의 초점이며, 모든 실험은 Qwen2.5-Instruct 계열(주 실험은 7B, 보조
 99 스웘은 1.5B/3B/14B) [Qwen Team, 2024]로 제한한다.

100 3 설정과 기제

101 **표기와 연산자.** 단일 헤드 self-attention을 고려한다(멀티헤드는 헤드 직합). 레이어 ℓ 에서
 102 질의 $q \in \mathbb{R}^d$, key $K \in \mathbb{R}^{T \times d}$, value $V \in \mathbb{R}^{T \times d_v}$, 교란 key $\hat{K} = K + E$. 원래 출력
 103 $o(q) = \sum_t s_t(q) v_t$ 이고 $s_t(q) = \text{softmax}(qK^\top / \sqrt{d})_t$. 도구 카탈로그의 4-facet 온톨로지를 Gram-
 104 Schmidt로 직교화한 per-head 기저 $B_{\text{ont}} \in \mathbb{R}^{d \times r}$ 와 사영 $P_{\text{ont}} = B_{\text{ont}} B_{\text{ont}}^\top$ 를 통해 세 연산자를
 105 정의한다:

$$\underbrace{K' = K + \alpha K P_{\text{ont}}}_{\text{정지 K (SEKA)}}, \quad \underbrace{Q' = Q + \beta Q P_{\text{ont}}, \beta < 0}_{\text{Q-커버리지 (ours)}}, \quad \underbrace{\ell < \lfloor \tau L \rfloor : K'; \text{ 모든 } \ell : Q'}_{\text{레이어 적응형 K+Q (ours)}} \quad (1)$$

106 세 연산자가 같은 B_{ont} 를 쓰므로 결과 차이는 연산자 형식에만 귀속된다. 본 논문 전체가 사용하는
 107 분석 가정은 유계 노름 하나뿐이다 (모든 q, v_t, e_t 에 대해 $\|q\| \leq Q_{\text{max}}, \|v_t\| \leq V_{\text{max}}, \|e_t\| \leq \rho$).
 108 (q, K, V) 의 결합 분포에 대한 어떠한 제약도 두지 않는다.

109 **핵심 세 주장.** 본 논문의 이론은 세 개의 주장으로 축약된다. 완전한 증명은 부록 A, 따름정리와
 110 조건부 명제는 부록 B에 있다.

111 **정리 3.1** (정지 K는 방출 상태를 담을 수 없다). (1)의 정지 K-측 연산자를 쓰자. 두 디코딩 히스토리
 112 h, h' 가 같은 hidden state x 를 낳지만 이미 방출된 도구 집합에서 다르다면 $K'(h) = K'(h')$ 이다.

113 증명. $K' = K + \alpha K P_{\text{ont}}$ 는 $(K, \alpha, P_{\text{ont}})$ 만의 함수이고 셋 다 히스토리 불변이다. $\square$

114 같은 논증이 AdaSEKA에도 적용된다(입력에 따른 전문가 선택은 x 의 함수이므로 같은 x 를 낳는
 115 두 히스토리에서 동일). 이 구조적 성질의 관측 가능한 귀결은 repeated_first_tool_rate의
 116 상승이다(따름정리 B.1, 부록).

117 **정리 3.2** (Q-사영의 기하). (1)에서 $\beta < 0$ 일 때 q' 는 q 의 온톨로지 성분을 $(1+\beta)$ 배로 균일 축소하고
 118 직교 성분을 보존한다.

119 증명. $P_{\text{ont}}^2 = P_{\text{ont}}$ 에서 $q' P_{\text{ont}} = (1+\beta)q P_{\text{ont}}, q'(I - P_{\text{ont}}) = q(I - P_{\text{ont}})$. $\square$

120 이것은 exact step-adaptive 제어가 아니라 “지배적 온톨로지 성분을 덜 신뢰하라”의 가장
 121 단순한 history-free 회전이며, (1)의 세 연산자를 온톨로지 부분공간 위의 회전 기반 스티어링으로
 122 통일한다.

123 **정리 3.3** (Attention 출력의 exact integral remainder). $\phi(\tau) := \sum_t \text{softmax}(\ell(q) +$
 124 $\tau \alpha(q))_t v_t$ 에 대해 $\hat{o}(q) - o(q) = L(q, E) + R(q, E)$ 가 정확한 등식으로 성립하며, 유계 노름 아래에서
 125 $\|\hat{o} - o\|^2 \leq 2 \text{Var}_s \alpha(q) \cdot \text{Var}_s[V](q) + C_1 \rho^4, C_1 = 2Q_{\text{max}}^4 V_{\text{max}}^2 / d^2$.

126 이 정리는 진단 도구다. L 과 R 의 완전한 형태와 네 단계 증명은 부록 A.

127 **Regime-split 예측.** 레이어 적응형의 $\tau = 1/4$ 선택은 “초기 레이어는 정보 인코딩에
 128 K-imprinting이 안전, 후기 레이어는 출력 수렴에 K 교란이 해롭다”는 경험적 전제 E1에
 129 조건부다(명제 B.2, 부록). 이 전제와 정리 3.1을 결합하면 K-imprinting의 한계 이득이 시퀀스
 130 길이 k 에 따라 $(1 - \varphi(j-1))$ 꼴로 감소하는 regime-split 예측이 따른다(따름정리 B.3). 이 예측은
 131 §4의 τ^2 -retail smoke 결과와 부록 D의 레이어 경계 sweep이 직접 시험한다.

표 2: MetaTool Subtask4 (N=497), Qwen2.5-7B-Instruct. 굵은 값 locked, 이탤릭은 예상 방향.

방법	F1	Exact	$\Delta F1$
no_steer	0.7307	0.5252	—
canonical SEKA amp=1.0	<i>placeholder</i>	<i>placeholder</i>	$\ll 0$
canonical AdaSEKA amp=1.0	<i>placeholder</i>	<i>placeholder</i>	$\ll 0$
정지 K a0.3	0.6850	0.4728	-4.57
Q-커버리지 (ours)	0.7535	0.5332	+2.28
레이어 적응형 K+Q (ours)	0.7514	0.5473	+2.08

표 3: τ^2 -bench retail. Qwen2.5-7B. N=30 smoke locked.

N	방법	F1	Recall	$\Delta F1$
30 (smoke)	no_steer	0.5735	0.5340	—
	Q-커버리지 (ours)	0.6109	0.5717	+3.74
	레이어 적응형 K+Q (ours)	0.5362	0.4831	-3.73
	canonical SEKA amp=1.0	<i>placeholder</i>	<i>placeholder</i>	≤ 0
	canonical AdaSEKA amp=1.0	<i>placeholder</i>	<i>placeholder</i>	≤ 0
114 (full)	no_steer	<i>placeholder</i>	<i>placeholder</i>	—
	Q-커버리지 (ours)	<i>placeholder</i>	<i>placeholder</i>	> 0
	레이어 적응형 K+Q (ours)	<i>placeholder</i>	<i>placeholder</i>	≈ 0 또는 < 0

4 도구 선택 성능

본 절은 중심 주장 1 — 회전 기반 스티어링이 멀티-툴 도구 선택을 개선한다 — 을 지지하는 증거를 쌓는다. 동일한 프롬프트, 스코어, greedy 디코딩 아래에서 여섯 방법을 비교한다: no_steer, 우리 정지 K 구현 ocq_bias_a0.3, 외부 canonical SEKA, canonical AdaSEKA, 그리고 본 연구의 Q-커버리지(ocq_qbias_b-0.03)와 레이어 적응형 K+Q(ocq_ladapt_k0.05_q-0.03).

4.1 MetaTool Subtask4

MetaTool Subtask4(N=497)는 각 질의에 정확히 두 도구의 정답이 지정되는, 순차 coverage를 가장 깨끗하게 측정하는 벤치마크다. 표 2의 잠금된 수치는 이미 핵심 이야기를 드러낸다. 같은 카탈로그 온톨로지 기저 위에서 정지 key-side 연산자는 -4.57pp의 심각한 음의 부호를 보이는 반면, 부호만 뒤집어 query에서 빼는 본 연구의 두 연산자는 각각 +2.28pp(Q-커버리지)와 +2.08pp(레이어 적응형)의 양의 이득을 낸다. 외부 canonical SEKA/AdaSEKA 수치는 부록 E의 재현 gate를 통과한 뒤 채워진다.

4.2 τ^2 -bench retail

독립 도메인 검증을 위해 τ^2 -bench retail의 첫 턴 action-set selection을 평가한다. 정답 도구 수가 4에서 13까지 분포하는 이 체제는 MetaTool의 $k = 2$ 와 대비되며, 이론의 regime-split 예측을 시험할 수 있는 환경을 제공한다. 표 3의 N=30 smoke는 이미 예상 패턴을 보여준다. Q-커버리지는 Qwen F1을 +3.74pp 끌어올리는 반면 레이어 적응형은 -3.73pp 떨어진다. 이 비대칭은 우연이 아니라 따름정리 B.3의 정량 예측 — K-imprinting의 한계 이득이 긴 시퀀스에서 감소 — 과 정합적이다. 같은 연산자가 $k = 2$ 에서는 최고이고 $k \geq 4$ 에서는 열세라는 패턴은 우리 이론이 이미 예고한 것이다. N=114 full이 통계적 확정을 제공할 것이다.

4.3 승리의 원인: 포지션별 분해

집계 F1에 예측 방향과 일치한다는 것은 필요조건일 뿐이다. 왜 이득이 생기는지에 대한 진짜 증거는 분해에서 나온다. 정리 3.1의 관측 가능한 귀결은 “정지 key-side가 첫 도구를 두 번째 단계에서 다시 고르게 유도한다”이므로, 데이터의 특정 위치 — 두 번째 포지션 — 에 특정한 흔적이 있어야 한다. repeated_first_tool_rate이 SEKA에서 올라가고, 우리 연산자에서 내려가야 하며, 이와 동시에 second_distinct_hit_rate이 우리 연산자에서 올라가야 한다. 이 세 관측이 동시에 성립할 때만 이득이 “반복을 지운 결과”라는 해석이 지지된다.

그림 1와 표 4이 그 패턴을 보여준다. 네 방법에 대해 네 포지션 지표를 나란히 놓으면 정지 K 계열 모두에서 repeated_first_tool_rate이 no_steer보다 뚜렷이 높아지고 second_distinct가 가장 많이 떨어진다. 우리 연산자는 반복을 약화시키면서 두 번째 포지션의 정확도를 끌어올린다. 이 네 수치의 동시 방향성이 본 논문의 핵심 증거다. F1 하나였다면 “같은 기저를 쓰는 두 연산자가

Figure 3. Stepwise coverage on MetaTool Subtask4 N=497.
SEKA raises repeated_first (Cor. 4.2); ours lowers it and raises second_distinct_hit.




그림 1: 포지션별 hit rate. 정지 K-계열의 repeated_first 상승과 우리 연산자의 감소가 동시에 관측되는 것이 따름정리 B.1의 직접 확증이다.

표 4: MetaTool Subtask4 N=497의 포지션별 hit rate. 화살표는 정리가 예측하는 방향.

방법	first_hit	second_hit	second_distinct	repeated_first ↓
no_steer	baseline	baseline	baseline	baseline
canonical SEKA amp=1.0	≈	↓↓	↓↓	↑↑
정지 K a0.3	≈	↓↓	↓↓	↑↑
Q-커버리지 (ours)	≈	↑	↑	↓
레이어 적응형 K+Q (ours)	↑	↑↑	↑↑	↓

163 우연히 다르게 나왔다”는 해석이 가능했겠지만, 네 수치가 같은 이야기를 가리킬 때는 그런 우연
164 해석이 어렵다.

165 4.4 ablation: 대안적 해석을 하나씩 반박

166 중심 주장을 위협할 수 있는 세 가지 대안 해석이 있다. 첫째, 이득이 기저 품질 덕분이라는
167 해석. 둘째, 효과가 단지 “약하게 쓰니까 안전했다”는 해석. 셋째, 연산자가 일종의 “확신 증가제”로
168 작동해 많이 쓸수록 좋다는 해석. 본 절은 이 셋을 각각 반박하는 ablation을 제시하고, 마지막으로
169 정리 3.3의 진단 bound가 실제로 정보적임을 경험적으로 확인한다.

170 **기저 특이성.** 표 5는 “기저 덕분” 해석을 분리한다. 정지 K는 feature-shuffled와 random
171 기저에서 완전히 0으로 붕괴한다. 같은 연산자가 카탈로그 기저에서만 $-4.57pp$ 의 “온전한 음의
172 효과”를 유지한다는 사실은 기저 방향이 정지 K의 행동을 전적으로 결정한다는 뜻이다. Q-
173 커버리지는 기저가 바뀌어도 F1을 0.7068 이상 유지하며 상대적으로 덜 민감하다. 이 비대칭은 두
174 연산자가 부분공간 기하에 다른 의존도를 가진다는 의미다. PCA-of-K 기저의 결과가 마지막 단계를
175 결정한다. PCA가 real과 구별되지 않으면 “카탈로그 온톨로지가 필수”라는 강한 주장이 약화되고,
176 PCA가 중간값 또는 neutral이면 “저랭크 구조가 필요하되 카탈로그가 최적”이라는 약한 주장으로
177 좁혀진다. 어느 경우든 random과 shuffled의 붕괴는 변하지 않으므로 “아무 방향이든 된다”는
178 대안은 이미 배제된다.

179 **“약해서 안전했다”의 반박.** 자연스러운 반론은 real 기저가 null control보다 교란을 덜 주기
180 때문에 안전한 것 아니냐는 것이다. 표 6가 이 설명을 직접 반박한다. real 온톨로지 기저는 실제
181 attention perturbation magnitude(Qwen L=13, $\alpha = 0.3$, N=30)에서 random과 feature-
182 shuffled 기저보다 더 큰 교란을 만든다 — 평균 621.30 vs random 399.56 vs feature-shuffled
183 291.98. 그럼에도 K-side 비교에서 유일하게 안정적인 방향은 real 기저뿐이다. 곧 real 기저가
184 “이기는 이유는 약해서가 아니라 특정한 안정 부분공간에 정렬되어 있기 때문”이다.

185 **“많이 쓸수록 좋다”의 반박.** 세 번째 반론은 Q-커버리지가 단지 일종의 confidence boost로
186 작동해서 $|\beta|$ 가 클수록 좋아져야 한다는 것이다. 이 해석도 데이터가 배제한다. 그림 2의 Q-only
187 β sweep은 좁은 작동 구간을 드러낸다. 평가한 값들 중 $\beta = -0.1$ 근처가 최고이며, $\beta = -0.7$ 에

표 5: Qwen2.5-7B, Subtask4 N=497: 기저 $\times$ 연산자. 굵은 값 locked.

기저	Q-커버리지 F1	정지 K F1
Real B_{ont} (ours)	0.7471	0.6850
Feature-shuffled	0.7254	0.0000
Random orthonormal	0.7068	0.0000
PCA-of-K (calibration)	<i>placeholder</i>	<i>placeholder</i>

표 6: Qwen L=13, $\alpha = 0.3$, N=30에서의 effective attention perturbation magnitude. Real 기저가 가장 크게 교란하는데도 안정성은 real에서만 유지된다.

기저	평균	중앙값	표준편차
Real B_{ont} (ours)	621.30	593.71	317.59
Random orthonormal	399.56	360.01	235.86
Feature-shuffled	291.98	241.87	169.97

188 이르면 F1이 0으로 완전 붕괴한다. 패턴은 “bias가 클수록 좋다”가 아니라 “작은 음의 Q-side pro-
 189 jection은 도움이 되지만, 그 밖의 대부분 설정은 오히려 성능을 깎는다”에 가깝다. 이 좁은 구간은
 190 조잡한 confidence 증가보다 coverage effect 해석과 잘 맞는다.

191 **진단 bound의 경험적 유효성.** 마지막으로 정리 3.3의 부등식이 공허하지 않은지 확인한다.
 192 Qwen2.5-7B(L=13)에서 $\alpha = 0.3$ 의 정지 K 개입에 대해 N=100, 전 head(2800개 head-query
 193 조합)에서 측정한 LHS/RHS 비율은 중앙값 2.36×10^{-8} , pass rate 100%로 bound는 매우
 194 보수적이지만 안정적으로 성립한다. 이것은 Q-side와 K-side 개입을 공통 척도로 비교할 때 정리가
 195 실제로 정보적 진단이 될 수 있음을 뒷받침한다.

196 **단일 도구 체제에서의 거동.** 마지막 보조 증거는 반대 방향에서 주장을 강화한다. MetaTool Sub-
 197 task1의 단일 도구 체제에서 Qwen에 정지 K-bias($\alpha = 0.3$)를 가하면 +11.16pp의 큰 양의 이득을
 198 준다. 언뜻 본 논문의 주장과 어긋나 보이지만 오히려 확증한다. 도구가 하나뿐인 체제에서는 “첫
 199 선택을 반복하라”는 편향이 중립 또는 도움이 되며, 이것이 SEKA 계열이 단일 개념 편집에서 강한
 200 이유와 일치한다. 본 연구의 두 연산자는 SEKA의 범용 대체가 아니라 멀티-툴 과제에 특화된 설계다.

201 5 효율성

202 중심 주장 2 — 회전 기반 스티어링이 대안 대비 효율적이다 — 는 실험이 아니라 네 축의 직접
 203 비교로 지지된다. 표 7가 본 방법을 tool-aware 파인튜닝, 프롬프트 스캐폴딩, KV-cache 최적화,
 204 정지 활성 스티어링과 비교한다.

205 “측정 예정” 칸은 두 보완 측정으로 채워진다. 추론 지연 측정은 네 조건(no steer, Q-커버리지,
 206 레이어 적응형 K+Q, canonical SEKA) 아래에서 per-query wall-clock을 기록하고, 메모리
 207 프로파일은 hook 설치 전후의 peak GPU memory로 실제 추가 footprint를 확인한다. hook이
 208 attention에 $O(T_{dr})$ 행렬 곱만 추가하므로 이론적 오버헤드는 전체 추론 시간의 1% 미만일 것이
 209 예상되며, 측정이 이 예측을 수치로 확정한다. 특기할 점은 KV-cache 최적화 계열과 본 방법이 서로
 210 다른 목표(메모리 vs 과제 성능)를 겨냥하며 결합 가능하다는 것이다. KIVI 등이 캐시를 압축하는
 211 동안 본 방법은 같은 캐시 위에서 과제 수준의 선택을 개선한다.

212 6 논의

213 본 논문의 메시지는 두 축으로 요약된다. 첫째, 멀티-툴 도구 선택에서 활성 스티어링의 가장
 214 가까운 선행 방법(SEKA/AdaSEKA)은 정지 key-side 증폭이라는 형식 때문에 “첫 도구를 두 번째
 215 단계에서 다시 증폭한다”는 구조적 편향을 가지며, 이 편향은 repeated_first_tool_rate이라는
 216 관측 가능한 양으로 데이터에 남는다. 해결은 같은 부분공간 위에서 회전을 Q-축으로 부호 반전해
 217 주는 것으로 충분하다. 둘째, 이 회전 기반 개입은 학습도 프롬프트 확장도 요구하지 않으며,
 218 파인튜닝 대비 학습 비용이 0이고 프롬프트 스캐폴딩 대비 토큰 오버헤드가 0이며 KV-cache 최적화
 219 계열과 orthogonal하게 결합 가능하다.

220 “기저 덕분인가 연산자 덕분인가”는 § 4.4의 ablation이 분리한다. feature-shuffled와 ran-
 221 dom 기저의 정지 K 붕괴는 “아무 방향이든 된다”는 대안을 이미 배제하며, PCA-of-K 행이 채워지면
 222 본 논문의 주장은 두 형태 중 하나로 조정된다: “카탈로그 온톨로지가 operator의 일부”(강한




그림 2: Qwen Subtask4 Q-커버리지 β sweep. 좁은 유효 구간은 confidence-boost 해석과 어긋나고 coverage 해석과 부합한다.

표 7: 효율성 비교. 본 방법은 추론 시 hook으로만 작동하여 학습과 토큰 오버헤드가 0이며, 저장은 per-head 기저만 추가로 든다(Qwen 7B 기준 ≈ 2.6 MB).

접근	학습 비용	토큰 오버헤드	추론 지연	저장
Tool-aware 파인튜닝 (Go-rilla, ToolLlama)	$\mathcal{O}(\text{일})$	0	0	전체 모델
프롬프트 스캐폴딩 (ReAct)	0	+200 ~ 500 토큰	프롬프트 길이 비례	0
KV-cache 최적화 (KIVI)	0	0	근소 감소	캐시 -30%
정지 활성 스티어링 (SEKA)	사영 학습($\mathcal{O}(\text{분})$)	0	근소 증가	사영 행렬
본 논문 (Q-커버리지, K+Q)	0	0	측정 예정	≈ 2.6 MB

해석) 또는 “저랭크 구조가 필요하되 카탈로그가 최적”(약한 해석). 어느 쪽이든 random/shuffled 붕괴는 불변이다.

레이어 적응형이 짧은 시퀀스에서 Q-only를 증가하고 긴 시퀀스에서 자리를 내주는 비대칭은 약점이 아니라 설계 지침의 원천이다. 두 체제 모두에서 본 연산자족은 SEKA보다 강하므로 사용자는 예상 도구 수에 따라 족 내부에서 고르면 된다. 부록 D의 레이어 경계 sweep(Phase 2.5)이 $\tau = 1/4$ 선택의 Pareto frontier를 정량화한다.

한계는 셋이다. 본 연산자는 모두 history-free이므로 정리 3.1이 지적인 방출 상태 결여를 완전히 해소하지는 않는다. 이미 방출된 도구를 명시 추적하는 iterative 연산자가 본 족 위에 얼마나 이득을 더할지는 열린 질문이다. canonical SEKA의 CounterFact 재현이 A6000 환경에서 실패했기 때문에 SEKA 비교는 A100 재현(부록 E) 통과 조건부로 head-to-head를 유지한다. 마지막으로 τ^2 -bench full multi-turn success와 KV-cache compression은 본 논문의 범위 밖이다.

정리 3.1이 SEKA에 국한되지 않고 모든 정지 연산자에 적용되므로 ITI, CAA, PASTA, Focus Directions도 같은 구조적 한계를 공유한다. 이것은 비판이 아니라 진단이며, 멀티-툴 확장 시 같은 “반복 기제”에 부딪힐 것이라는 예측을 이론이 이미 내놓고 있다. 부호 반전된 Q-사영이 이 확장의 기본 도구로 기능할 수 있다는 것이 본 논문이 제안하는 방향이다.

7 결론

본 논문은 멀티-툴 도구 선택을 강화하는 훈련-없는 회전 기반 활성 스티어링을 제시했다. 도구 카탈로그에서 직접 유도한 per-head 온톨로지 부분공간 위에서, Q-커버리지는 질의를 부분공간에서 축소하고, 레이어 적응형 K+Q는 초기 레이어에 K-측 회전을 더해 첫 도구 방향을 각인한다. 두 연산자 모두 history-free이지만 가장 가까운 선행 방법(SEKA/AdaSEKA)의 정지 key-side 증폭과 달리 “방금 쓴 방향에서 덜 가라”는 의미를 부호 반전으로 내장한다. 성능 측에서 Qwen2.5-7B-Instruct에 대해 MetaTool Subtask4와 τ^2 -bench retail 모두에서 일관된 이득이 관측되고, 이 이득은 집계 F1이 아니라 repeated first tool rate의 감소라는 포지션별 footprint로 해석된다. 효율성 측에서 본 방법은 학습과 토큰 오버헤드가 0이며 저장은 per-head 기저 (L, H_{kv}, d, r)만 추가로 든다. 이 두 측은 회전 기반 스티어링이 단일 개념 편집을 넘어 에이전트 도구 호출에도 실용적 도구가 될 수 있음을 시사한다.

A 증명

정리 3.3 증명. 1단계. softmax는 실해석적이므로 ϕ 는 smooth, Taylor의 정리로 $\phi(1) - \phi(0) = \phi'(0) + \int_0^1 (1 - \tau)\phi''(\tau)d\tau$. 2단계. softmax Jacobian $\partial s_t / \partial \ell_{t'} = s_t(\delta_{tt'} - s_{t'})$ 로 $ds_t(\tau)/d\tau =$

표 8: Qwen 크기 스위프 (보조 ablation).

크기	no_steel	SEKA amp=1.0	Q-커버리지	레이어 적응형
1.5B	placeholder	placeholder	placeholder	placeholder
3B	placeholder	placeholder	placeholder	placeholder
7B	0.7307	placeholder	0.7535	0.7514
14B	placeholder	placeholder	placeholder	placeholder




그림 3: ΔF1 vs 정답 도구 수 k (placeholder).

252 $s_t(\tau)(\alpha_t - \bar{\alpha}(\tau))$. 따라서 $\phi'(0) = \sum_t s_t \alpha_t (v_t - o) = L(q, E)$ (정확 등식). 3단계. 직접
 253 계산으로 $\phi''(\tau) = \sum_t s_t(\tau)[(\alpha_t - \bar{\alpha}(\tau))^2 - \text{Var}_s \alpha(\tau)]v_t$. 4단계. 벡터 Cauchy-Schwarz로
 254 $\|L\|^2 \leq \text{Var}_s \alpha(q) \cdot \text{Var}_s[V](q)$. $|\alpha_t| \leq Q_{\max} \rho / \sqrt{d}$ 로 $\|R\|^2 \leq Q_{\max}^4 V_{\max}^2 \rho^4 / d^2$. $\square$

255 B 따름정리와 조건부 명제

256 **따름정리 B.1** (정지 K의 반복 편향). 그리디 디코딩 아래 첫 단계에 $t_1 \in T_{\text{gt}}$ 가 선택되고 t_1 이
 257 온톨로지 부분공간에 정렬되면 정지 K가 t_1 의 logit을 $(1 + \alpha)$ 배로 증폭해 $\Pr[t_2 = t_1 \mid \text{stat}] \geq$
 258 $\Pr[t_2 = t_1 \mid \text{no_steer}]$.

259 **명제 B.2** (레이어 적응형 역할 분리, 조건부). *transformer* 표현이 초기 (토큰 인코딩), 중간
 260 (안정화), 후기 (출력 수렴)의 세 단계로 진화한다는 경험적 전제 E1 아래에서, 정지 K는 후기 수렴을
 261 교란하지만 초기 $\lfloor \tau L \rfloor$ 중에 국한된 K는 도구 방향을 각인하여 precision을 높인다.

262 **따름정리 B.3** (K-imprinting의 시퀀스 길이 감소). 명제 B.2의 전제와 정지성 결합 시, k -길이
 263 시퀀스의 j 번째 도구($j > 1$)에 대한 K-imprinting 한계 이득은 $(1 - \varphi(j - 1))$ 꼴로 상계. Q-
 264 커버리지의 per-step 이득은 j 에 불변.

265 C 보조 실험: 모델 크기와 시퀀스 길이

266 정리 1-3이 모델 크기 무관이므로 Qwen2.5-Instruct 1.5B/3B/7B/14B 스위프는 보조 보존을
 267 확인한다(표 8). 7B 행 locked, 나머지는 실행 대기. 따름정리 B.3의 정량 확증은 ΔF1 vs k
 268 곡선(그림 3).

269 D 보조 실험: 레이어 경계 sweep (Phase 2.5)

270 명제 B.2의 $\tau = 1/4$ 선택을 시험하는 coworker 운영 ablation으로, 6개 경계 구성과 2개 β , 2개
 271 벤치마크를 교차한다. LS-1~LS-4는 τ 의 Pareto frontier를 그리고, LS-5(K+Q 겹침)와 LS-6(Q
 272 후반만)는 competing hypothesis를 구별한다.

273 E SEKA 재현 프로토콜, 매니페스트, 코드 구조

274 외부 SEKA 행은 canonical CounterFact efficacy score (ES = 0.952 ± 0.02)를
 275 재현한 구현에만 채워질 자격을 얻는다. A6000 환경에서 재현 실패(ES=0.374)이므로

표 9: Phase 2.5 layer boundary sweep (실행 대기).

ID	구성	$\Delta F1$ (Subtask4)	$\Delta F1$ (τ^2 -retail)
LS-1	$K \ell < L/7$, Q 나머지	<i>placeholder</i>	<i>placeholder</i>
LS-2	$K \ell < L/4$, Q 나머지 (현 baseline)	+2.08	-3.73
LS-3	$K \ell < L/3$, Q 나머지	<i>placeholder</i>	<i>placeholder</i>
LS-4	$K \ell < L/2$, Q 나머지	<i>placeholder</i>	<i>placeholder</i>
LS-5	$K \ell < L/4$, Q 전 레이어	<i>placeholder</i>	<i>placeholder</i>
LS-6	$K \ell < L/4$, $Q \ell > 3L/4$	<i>placeholder</i>	<i>placeholder</i>

A100 재현이 SEKA 비교 gate다. 모든 수치는 MANIFEST.md에 (표 번호, JSON 경로, 스크립트) 삼중쌍으로 기록된다. 개입 구현은 scripts/ocq/eval_metatool_subtask1.py의 install_{kbias,q_bias,layer_adaptive}_hooks; 구동은 eval_metatool_subtask4.py, eval_tau2_bench.py, eval_subtask4_with_real_seka.py. PCA 기저 builder: scripts/ocq/build_pca_baseline_basis.py.

F U-shape 전제 확인

명제 B.2의 전제 E1은 reports/layer_adaptive_2026_04_17/에서 Qwen2.5-7B($L = 28$)에 대해 확인되었다. 초기 $\ell < 7$ 과 후기 $\ell > 21$ 의 attention MSE가 중간 레이어보다 유의미하게 크다.

참고문헌

- A. Grattafiori et al. The llama 3 herd of models. arXiv, 2024.
- Y. Huang et al. MetaTool: A benchmark for llm tool use. arXiv preprint, 2024.
- A. Jiang et al. Mistral 7b. arXiv, 2023.
- K. Li et al. Inference-time intervention: Eliciting truthful answers from a language model. NeurIPS, 2023.
- W. Li and Others. AdaSEKA: Adaptive expert selection for spectral key-space steering. In International Conference on Learning Representations (ICLR), 2025a.
- W. Li and Others. SEKA: Spectral expert activation for key-space steering. In International Conference on Learning Representations (ICLR), 2025b.
- Z. Liu et al. KIVI: Plug-and-play 2-bit KV cache quantization. ICML, 2024a.
- Zirui Liu, Jiayi Yuan, Hongye Jin, Shaochen Zhong, Zhaozhuo Xu, Vladimir Braverman, Beidi Chen, and Xia Hu. Kivi: A tuning-free asymmetric 2bit quantization for kv cache. Proceedings of Machine Learning Research, 235:32332–32344, 2024b.
- S. Patil et al. Gorilla: Large language model connected with massive apis. arXiv, 2023.
- Y. Qin et al. Toolllm: Facilitating large language models to master 16000+ real-world apis. ICLR, 2024.
- Qwen Team. Qwen2.5 technical report. arXiv:2412.15115, 2024.
- Sierra Research et al. τ^2 -bench: Multi-turn tool-use benchmark. arXiv preprint, 2025.
- N. Rimsky et al. Steering llama 2 via contrastive activation addition. ACL, 2024.
- F. Yan et al. Berkeley function calling leaderboard. Gorilla LLM, 2024.
- S. Yao et al. React: Synergizing reasoning and acting in language models. ICLR, 2023.
- J. Zhang et al. xlam: A family of large action models to empower ai agent systems. arXiv, 2024a.
- Q. Zhang et al. PASTA: Post-softmax attention steering. In ICLR, 2024b.
- R. Zhu et al. Focus directions for long-context attention. arXiv preprint, 2025.