

멀티-툴 선택을 위한 온톨로지 기반 질의 커버리지 바이어스

Anonymous Author(s)

Affiliation

Address

email

초록

멀티-툴 에이전트 프롬프트에서는 모델이 도구 하나를 고르는 데서 끝나지 않고, 서로 다른 두 개 이상의 도구를 순차적으로 내보내야 한다. 이때 핵심 문제는 단일 단계 순위화가 아니라 커버리지다. 본 논문은 q_proj 에서 온톨로지 정렬 성분을 억제하는 질의 공간 바이어스를 평가하고, 동일한 온톨로지 기저를 사용하는 정적 key-space 바이어스와 비교한다. MetaTool Subtask4의 497개 two-tool 질의에서 질의 측 바이어스는 Qwen2.5-7B-Instruct의 macro F1을 0.7307에서 0.7471로, Llama-3.1-8B-Instruct의 macro F1을 0.6227에서 0.6271로 높인다. 반면 정적 key-space 바이어스는 Qwen에서 0.6850, Llama에서 0.3105로 악화된다. 이 결과는 임의의 저랭크 교란으로 설명되지 않는다. Qwen에서 온톨로지 기저를 feature-shuffled 또는 random control로 바꾸면 질의 측 결과는 각각 0.7254, 0.7068로 내려가고, key-side control은 둘 다 0.0000으로 붕괴한다. 추가 진단은 유효 영역이 매우 좁고 최적 Q-only 지점이 $\beta = -0.1$ 근처에 있으며, 실제 온톨로지 교란의 유효 attention magnitude가 null control보다 오히려 더 크다는 점을 보여준다. 따라서 본 논문의 주장은 좁지만 일관적이다. 멀티-툴 선택에서는 query-side coverage bias가 생산적인 방향이고, 정적인 key-side 증폭은 그렇지 않으며, 온톨로지 기저는 임의의 투영군이 아니라 안정적인 특정 부분공간을 식별하기 때문에 중요하다.

1 서론

툴을 사용하는 언어모델 평가는 종종 질의마다 하나의 정답 도구만 있다고 가정한다. 그러나 실제 에이전트 질의는 그렇지 않다. 사용자는 뉴스와 금융 영향을 함께 묻거나, 여행 계획과 환율 정보를 동시에 요청한다. 이런 경우 모델은 도구 하나를 잘 고르는 것보다 서로 다른 도구를 순서대로 빠짐없이 복원해야 한다.

이 논문은 바로 그 멀티-툴 상황을 다룬다. 출발점은 단순한 실패 모드다. 어떤 정적인 attention 개입이 모든 디코딩 단계에서 같은 facet을 계속 증폭하면, 첫 번째 도구를 이미 출력한 뒤에도 같은 facet을 다시 밀어주게 된다. 멀티-툴 질의에서는 이것이 잘못된 귀납 편향이다. 두 번째 단계에서는 첫 번째 단계와 달라질 수 있어야 하기 때문이다.

우리가 평가하는 개입은 기존 key-side steering 실험과 동일한 per-head ontology basis 위에서 정의되는 query-space 바이어스다. 구현은 의도적으로 단순하다. 각 layer에서 query를 ontology subspace로 사영한 뒤, 그 성분에 부호가 있는 계수를 곱해 더한다. 음수 계수는 ontology-aligned query 성분을 억제하므로 coverage bias처럼 작동한다. 가설도 명확하다. 멀티-툴 프롬프트에서는 이런 억제가 두 번째 도구 복원을 도와야 하고, 같은 기저를 쓰는 정적 key-side 바이어스는 효과가 없거나 첫 번째 facet에 과도하게 집중해야 한다.

실험은 이 가설을 지지하지만, 강한 의미에서가 아니라 좁은 의미에서 그렇다. MetaTool Subtask4에서 query-side 바이어스는 Qwen과 Llama 모두에서 양의 효과를 보이지만, 정적 key-side 바이어스는 두 모델 모두에서 음의 효과를 보이며 Llama에서는 거의 붕괴 수준이다. 절대적인 이득은 크지 않다. 따라서 이 논문을 대규모 정확도 돌파로 포장할 수는 없다. 대신 중요한 점은 부호 패턴이 안정적이고, null control이 결정적이며, 기저 특이성에 대한 이야기가 단순한 raw gain보다 더 강하다는 사실이다.

본 논문의 기여는 세 가지다. 첫째, 가장 가까운 선행 흐름의 과제-불일치를 분명히 한다. stationary key-side amplification은 prompt highlighting에는 자연스러울 수 있지만, 두 개 이상의 도구를 순차적으로 복원해야 하는 coverage 문제에는 맞지 않을 수 있다. 둘째, 그 대안으로 training-free ontology-guided query-space suppression을 평가하고, 같은 멀티-툴 벤치마크에서 이 연산자의 부호는 일관되게 양수이고 stationary key-side 증폭의 부호는 음수임을 보인다. 셋째, 그 효과가 임의의 저랭크 교란이 아니라 ontology basis에 특이적이며, perturbation 분석 역시 공허한 수사가 아니라 보수적 진단 도구로 기능함을 보인다. 다만 이 논문은 SEKA나 AdaSEKA를 동일 조건에서 완전히 이겼다고 주장하지 않는다. 주장은 더 좁다. 하나 이상의 도구를 순차적으로 복원해야 할 때는 단순히 저랭크 개입이라는 사실보다, 개입의 위치와 부호가 더 중요하다는 것이다.

2 관련 연구

가장 가까운 선행 흐름은 spectral key-space steering이다. SEKA는 synthetic question-answer pair로부터 저랭크 projection을 학습한 뒤 추론 시 attention key에 주입하고, AdaSEKA는 이를 소수의 expert projection과 입력별 expert selector로 확장한다 [Li et al., 2026]. 이 계열은 더 넓은 inference-time steering 문헌에 속한다. 여기에는 activation-space direction을 사용하는 ITI와 CAA [Li et al., 2023, Rimsky et al., 2024], spectral activation editing [Qiu et al., 2025], post-softmax attention steering [Zhang et al., 2024], prompt anchoring [Tian and Zhang, 2025], 그리고 long-context relevance를 높이기 위한 focus-direction 계열 [Zhu et al., 2025]이 포함된다. 공통점은 추가 finetuning 없이 추론 시 개입한다는 점이지만, 대부분의 목표는 선택된 신호를 보존하거나 증폭하는 데 있다.

본 논문은 먼저 과제가 다르다. 우리는 한 질의에서 두 개의 도구를 순차적으로 내보내야 하는 multi-tool selection을 직접 다룬다. 이 설정에서는 실패 모드가 달라진다. 같은 facet을 계속 증폭하는 방법은 single-selection 벤치마크에서는 합리적으로 보일 수 있어도, sequential coverage가 필요한 문제에서는 구조적으로 맞지 않을 수 있다. 두 번째 디코딩 단계는 첫 번째와 더 비슷해져야 하는 것이 아니라, 오히려 달라져야 하기 때문이다. 그래서 이 논문은 자신을 “또 하나의 SEKA 변형”으로 제시하지 않는다. 대신 stationary key-side recipe가 언제 과제 구조와 어긋나는지를 묻는 논문으로 제시한다.

차이는 개입 위치와 방향의 출처에서도 나타난다. 이 논문에서 양의 결과를 만드는 연산자는 key amplification이 아니라 query-side operator이며, 기저도 synthetic contrastive pair가 아니라 tool catalog에서 직접 만든 ontology에서 온다. 이 차이가 중요하다. AdaSEKA는 입력에 따라 어떤 key-side projector를 쓸지 바꾸지만, 연산의 의미 자체는 여전히 “선택된 부분공간을 더 증폭한다”에 머문다. ITI와 CAA는 activation direction을 따라 행동을 유도하지만 multi-tool coverage operator로 설계되지는 않았다. Focus Directions는 key/query를 조절해 relevant context에 더 집중하게 만들지만, 목적 자체가 sequential tool diversity는 아니다. 반면 여기서는 부호의 의미가 바뀐다. 음의 query-space 계수는 이미 지배적인 ontology-aligned 성분을 눌러주며 거친 coverage prior처럼 행동한다.

더 넓게 보면 이 논문은 training-time routing이 아니라 post-hoc activation steering에 속한다. 개입은 추론 시 attention-space hook으로 적용되며, 추가 학습도 없고 외부 selector network도 없다. 이것은 의도적인 선택이다. history tracking이나 별도의 learned controller를 도입하기 전에, ontology basis의 기하와 개입 위치, 그리고 부호만으로도 coverage와 repetition의 방향이 갈리는지를 먼저 분리해서 보고자 했기 때문이다.

KV-cache compression은 본 논문의 중심 질문과는 별개다. KIVI 같은 방법은 저비트 cache 표현과 메모리-품질 절충을 다루지, tool-selection dynamics를 다루지 않는다 [Liu et al., 2024]. 사용 모델은 instruction-tuned Qwen, Llama, Mistral 계열 [Qwen Team et al., 2024, Grattafiori et al., 2024, Jiang et al., 2023]이며, 주 실험은 MetaTool Subtask4를 사용한다. 이 벤치마크는 two-tool output을 요구하기 때문에, stationary single-facet steering이 부딪힐 것으로 예상되는 sequential coverage 문제를 직접 드러낸다.

3 방법

3.1 온톨로지 기저

모든 실험은 tool catalog로부터 구성한 per-head ontology basis $B_{\text{ont}} \in \mathbb{R}^{L \times H_{\text{kv}} \times d \times r}$ 를 사용한다. 직관적으로 이 기저는 금융, 뉴스, 여행, 미디어 같은 tool facet에서 반복적으로 나타나는 방향을 span한다. 평가 시점에서 기저는 고정되며, query-side와 key-side 개입이 동일한 기저를 공유한다.

표 1: 본문 핵심 주장들의 증명 상태.

주장	유형	완전 증명 여부	추가 모델링 가정 의존성
Stationary key-side steering은 explicit coverage variable을 도입하지 않는다	구조적	예	거의 없음
음의 query-side projection은 coverage에 맞는 부호 의미를 가진다	구조적	예	거의 없음
Attention output perturbation은 qaMSE와 ρ^4 remainder로 제어된다	진단용	예	boundedness 가정 필요
Q-bias가 MetaTool Subtask4의 second-tool recovery를 높인다	경험적	아니오	실험으로 보여야 함

92 3.2 실용적인 query-space coverage bias

93 query tensor q 에 대해 구현된 query-side 개입은 다음과 같다.

$$q' = q + \beta B_{\text{ont}} B_{\text{ont}}^{\top} q.$$

94 $\beta < 0$ 이면 연산자는 ontology subspace에 정렬된 query 성분을 빼준다. 코드에서는 이를
95 q_{proj} 에 대한 forward hook으로 구현한다. 이 방법은 history-free다. 어떤 도구가 이미
96 출력되었는지를 명시적으로 추적하지 않는다. 따라서 우리는 이를 더 강한 이상적 coverage op-
97 erator의 실용적 근사로 해석하며, 문자 그대로의 per-step facet-state tracking으로 해석하지
98 않는다.

99 3.3 정적인 key-side bias

100 비교 대상으로는 동일한 기저를 사용하는 key-side 개입을 둔다.

$$k' = k + \alpha B_{\text{ont}} B_{\text{ont}}^{\top} k.$$

101 이 개입은 정의상 stationary하다. 모든 디코딩 단계에서 같은 ontology-aligned key direc-
102 tion을 증폭한다. 첫 번째로 출력된 도구가 이미 지배적 facet을 차지하고 있다면, 이 연산자는 이후
103 단계에서 그 facet을 억제할 방법이 없다.

104 3.4 작업 가설

105 본 논문의 작업 가설은 두 부분으로 이루어진다. 첫 번째는 정확도 가설이다. 음의 query-side on-
106 tology bias는 지배적인 facet의 반복 사용을 줄여주므로 multi-tool recovery를 향상시켜야 한다.
107 두 번째는 특이성 가설이다. ontology basis를 동일 rank의 random basis나 feature-shuffled
108 basis로 대체하면 효과가 사라져야 한다. 실험은 이 두 주장을 직접 검증하도록 설계되어 있다.

109 4 이론

110 실험을 정당화하는 데 긴 형식 체계가 필요한 것은 아니다. 필요한 것은 세 가지다. 첫째와 둘째는
111 구조적 명제다. 왜 stationary key-side 증폭이 순차적 coverage와 어긋나는지, 왜 query-side
112 suppression이 올바른 history-free 근사인지를 설명한다. 마지막 정리는 perturbation 언어를
113 엄밀한 부등식으로 고정한다.

114 **범위.** 이 절의 역할은 의도적으로 좁다. 두 개의 구조적 사실과 하나의 진단용 perturbation
115 bound를 증명한다. 반대로, benchmark F1을 직접 증명하지 않으며, exact facet-history track-
116 ing도 주장하지 않는다.

117 **정리 1의 상시 가정.** Perturbation 정리에는 다음의 분석 가정만 쓴다:

- 118 1. bounded query norm $\|q\| \leq Q_{\text{max}}$;
- 119 2. bounded value norm $\|v_t\| \leq V_{\text{max}}$;
- 120 3. row-wise key perturbation bound $\|e_t\| \leq \rho$.

121 앞의 두 명제는 이런 boundedness 가정에 의존하지 않는다.

명제 4.1: Stationary key-side steering은 explicit coverage variable을 도입하지 않는다

선형사상 P 와 스칼라 α 를 고정하고, 모든 디코딩 단계에서 같은 key-side 연산자

$$k' = (I + \alpha P)k$$

를 적용하자. 그러면 이 개입 자체는 어떤 facet이 이미 방출되었는지에 대한 정보를 담을 수 없다. 특히 현재 key tensor가 같다면, 과거에 어떤 facet이 사용되었는지와 무관하게 변환된 key는 완전히 동일하다.

122

123 **해석.** 이 명제는 통계적이기보다 구조적이다. 시간에 대해 불변인 key 연산자는 single-target
124 벤치마크에서는 도움을 줄 수 있어도, “이 facet은 이미 썼다”라는 explicit state를 스스로
125 추가하지는 못한다. 그런 정보는 key-side 연산자 바깥의 모델 상태에 이미 들어 있어야 한다. 부록
126 A에 짧은 증명을 실었다.

127 **증명하지 않는 것.** 이 명제는 key-side steering이 항상 무의미하다고 말하지 않는다. 다만 sta-
128 tionary key-side map만으로는 순차적 멀티-툴 복원에 필요한 explicit coverage variable을
129 새로 도입하지 못한다고 말한다.

명제 4.2: Query-side suppression은 가장 단순한 history-free coverage 근사다

온톨로지 부분공간으로의 직교사영을 P_{ont} 라고 하고

$$q' = (I + \beta P_{\text{ont}})q$$

를 $\beta < 0$ 에서 정의하자. 그러면 q 의 ontology-aligned coefficient는 모두 균일하게 축소되고, ontology subspace에 직교한 성분은 그대로 유지된다. 따라서 음의 query-side bias는 외부 상태를 추가하지 않으면서도 지배적인 ontology-aligned mass의 반복 사용을 줄이는 가장 단순한 history-free 연산자다.

130

131 **해석.** 이 명제가 exact facet tracking을 증명하는 것은 아니다. 더 좁고 충분한 사실만을
132 보여준다. history-free 선형 편집 가운데, 음의 query-side bias는 반복 facet 사용을 줄이는 데
133 맞는 부호 의미를 가진다. 실제 대수 전개는 부록 A에 정리했다.

134 **증명하지 않는 것.** 이 명제는 모델이 항상 올바른 두 번째 도구로 전환된다는 것을 보장하지 않는다.
135 다만 외부 상태 없이 쓸 수 있는 history-free 선형 편집 가운데, 반복 facet 사용을 억제하는 부호
136 의미를 가진 가장 단순한 연산자를 식별한다.

정리 4.3: Attention-weighted perturbation bound

질의 q , 원래 key 행렬 K , row-wise 오차 $\|e_t\| \leq \rho$ 를 갖는 교란 key 행렬 $\hat{K} = K + E$, 그리고 대응하는 attention output $\hat{o}(q), o(q)$ 를 두자. 또한

$$\alpha_t(q) = \frac{q \cdot e_t}{\sqrt{d}},$$

$$\text{qaMSE}(q; E) = \sum_{t=1}^T s_t(q) \alpha_t(q)^2$$

를 정의하자. 여기서 $s_t(q)$ 는 원래 attention weight다. bounded-query, bounded-value 가정 아래에서

$$C_1 = \frac{2Q_{\max}^4 V_{\max}^2}{d^2}$$

라는 명시적 상수가 존재하여

$$\mathbb{E}_q \|\hat{o}(q) - o(q)\|^2 \leq 2 \mathbb{E}_q [\text{qaMSE}(q; E) \text{Var}_s[V](q)] + C_1 \rho^4$$

가 성립한다.

137

138 **해석.** 엄밀한 부분은 이 정리 자체이고, 경험적 검증은 그 다음 단계다. 이 정리는 두 항으로 읽으면
139 이해가 쉽다. 첫 번째 항은 attention-weighted 1차 기여이고, 두 번째 항은 ρ^4 로 제어되는 고차

표 2: Subtask4의 주 결과. Q-side bias는 두 모델 모두에서 양의 효과를 보이고, stationary K-side bias는 두 모델 모두에서 음의 효과를 보이며 Llama에서는 붕괴 수준이다.

모델	방법	F1	Exact	Jaccard
Qwen2.5-7B-Inst	No steer	0.7307	0.5252	0.6673
Qwen2.5-7B-Inst	Q-bias $\beta = -0.1$	0.7471	0.5272	0.6791
Qwen2.5-7B-Inst	K-bias $\alpha = 0.3$	0.6850	0.4728	0.6194
Llama-3.1-8B-Inst	No steer	0.6227	0.5030	0.5872
Llama-3.1-8B-Inst	Q-bias $\beta = -0.1$	0.6271	0.5070	0.5919
Llama-3.1-8B-Inst	K-bias $\alpha = 0.3$	0.3105	0.2616	0.2951




그림 1: Subtask4 macro F1. 왼쪽 패널에는 Qwen의 null control도 함께 표시했다.

remainder다. 표 4는 측정된 perturbation-to-bound ratio의 중앙값이 Qwen에서는 2.36×10^{-8} , Llama에서는 6.37×10^{-8} 임을 보여준다. 이 정리가 end-to-end accuracy를 증명하는 것은 아니지만, Q-side와 K-side 개입을 비교할 때 perturbation 언어를 보수적인 진단 도구로 쓰는 것은 정당화한다. 증명은 부록 A에 네 단계로 나누어 제시한다.

증명하지 않는 것. 이 정리는 benchmark theorem이 아니다. qaMSE가 더 작으면 반드시 tool-selection F1이 더 좋다고 말하는 것이 아니라, 주어진 boundedness 가정 아래에서 key 오차가 attention output을 얼마나 교란하는지를 제어하는 진단식을 준다.

비고 4.4

평가한 연산자는 history-free다. ontology subspace로의 사영을 억제할 뿐, 이미 방출된 facet를 명시적으로 추적하지는 않는다. 따라서 이론의 역할도 의도적으로 좁다. 정확한 step-adaptive control을 형식화하는 것이 아니라, 개입의 부호, 특이성, perturbation 안정성을 해석하는 데 초점을 둔다.

5 실험

5.1 설정

주 벤치마크는 MetaTool Subtask4다. 이 벤치마크는 497개의 프롬프트로 이루어져 있으며, 각 질의마다 정확히 두 개의 ground-truth tool이 있다. 평가지표는 macro F1, Exact match, Jaccard다. 주 모델은 Qwen2.5-7B-Instruct와 Llama-3.1-8B-Instruct이며 [Qwen Team et al., 2024, Grattafiori et al., 2024], 모든 평가는 ontology basis를 고정한 greedy decoding으로 수행했다.

5.2 주 결과: Q-side는 양수, K-side는 음수

표 2와 그림 1는 핵심 결과를 요약한다. 부호 패턴은 두 모델 계열에서 일관된다. Q-side coverage bias는 macro F1을 높이고, stationary K-side bias는 성능을 떨어뜨린다.

절대적인 이득은 크지 않다. Qwen에서는 +1.64pp, Llama에서는 +0.44pp에 그친다. 이것만으로 대담한 정확도 개선을 주장할 수는 없다. 중요한 점은 부호가 모델 계열을 바꿔도

표 3: Qwen Subtask4의 null control. K-side 안정성을 유지하면서 Q-side 이득을 주는 기저는 ontology basis뿐이다.

방법	Real basis	Feature-shuffled	Random
Q-bias $\beta = -0.1$ F1	0.7471	0.7254	0.7068
K-bias $\alpha = 0.3$ F1	0.6850	0.0000	0.0000




그림 2: Qwen Subtask4에서의 Q-bias sweep과 small- α_K ablation. 두 곡선 모두 유효 구간이 매우 좁다.

유지된다는 사실과, stationary K-side 개입은 부호가 뒤집힐 뿐 아니라 Llama에서 급격히 무너진다는 사실이다. 따라서 이 논문이 내릴 수 있는 결론은 방향성에 관한 것이다. 멀티-톨 recovery가 목표라면 query-space suppression이 유효한 축이고, stationary key-space amplification은 그렇지 않다.

5.3 온톨로지 특이성이 결정적이다

더 강한 결과는 headline gain 자체보다 null control의 행동이다. 표 3는 ontology basis를 feature-shuffled basis나 random basis로 대체하면 query-side 이득이 사라지고, key-side 안정성은 완전히 붕괴한다는 점을 보여준다.

이 점이 이 논문에서 가장 설득력 있는 실증 결과다. 임의의 저랭크 교란만으로는 충분하지 않다. rank와 채널 스케일을 유지하는 구조 보존형 control도 실패한다. 실무적 함의도 분명하다. ontology basis는 rank가 같은 임의의 projection으로 대체 가능한 부품이 아니다.

5.4 유효한 작동 구간은 매우 좁다

그림 2는 Qwen Subtask4에 대한 두 개의 ablation을 보여준다. Q-only sweep은 평가한 값들 중에서 $\beta = -0.1$ 근처에서 최대를 보인다. 두 번째 sweep은 Q-side operator 위에 작은 K-bias를 추가한 경우인데, $\alpha_K \in [0.025, 0.05]$ 인 아주 좁은 범위만이 Q-only 설정보다 낫다.

이 좁은 작동 구간은 해석에 중요하다. 결과는 “bias가 클수록 좋다”가 아니다. “작은 음의 Q-side projection은 도움이 되지만, 그 밖의 대부분의 설정은 오히려 성능을 깎는다”에 가깝다. 이런 패턴은 조잡한 confidence boost보다 coverage effect 해석과 더 잘 맞는다.

5.5 안정성은 단지 교란이 작아서 생긴 것이 아니다

자연스러운 반론은 실제 ontology basis가 null control보다 교란을 덜 주기 때문에 더 안전한 것 아니냐는 것이다. 그림 3는 이 설명을 반박한다. 실제 ontology basis는 null control보다 더 큰 effective attention perturbation magnitude를 만든다. 그럼에도 안정적인 K-side 방향은 실제 basis뿐이다.

이 때문에 null-control 결과는 의미가 있다. 실제 basis가 이기는 이유는 약해서가 아니라, 특정한 안정 부분공간과 정렬되어 있기 때문이다. 같은 그림은 perturbation bound ratio가 두 모델 계열 모두에서 매우 작게 유지된다는 점도 보여준다.

실제 온톨로지 교란은 더 크지만 안정한 방향은 이 경우뿐이다




그림 3: 두 가지 진단. 왼쪽은 실제 ontology perturbation이 null control보다 더 크다는 점을 보여주고, 오른쪽은 경험적 perturbation-bound ratio가 Qwen과 Llama 모두에서 매우 작다는 점을 보여준다.

표 4: 경험적 perturbation bound 요약. 측정된 left/right ratio는 두 모델 모두에서 매우 작다.

모델	Layer	Head-query count	Median LHS/RHS	Mean LHS
Qwen2.5-7B-Inst	13	2800	2.36×10^{-8}	0.5092
Llama-3.1-8B-Inst	15	3200	6.37×10^{-8}	0.0586

5.6 보조 증거

MetaTool Subtask1의 single-tool 결과와 query-space stability에 기반한 predictor smoke 실험은 일관성 점검으로는 유용하다. 다만 본문의 중심 실증은 multi-tool selection, ontology specificity, 그리고 query-side 개입과 stationary key-side 개입의 대비다.

6 논의

실증 결과는 두 층으로 나뉜다. 첫째, query-side suppression은 크지는 않지만 일관된 양의 효과를 보인다. 둘째, 같은 기저를 쓰는 stationary key-side amplification은 훨씬 더 큰 음의 효과를 보인다. 이 둘을 함께 보면, multi-tool selection의 핵심은 일반적인 저랭크 강조 자체가 아니라 그 개입이 coverage를 돕는지 반복을 강화하는지에 있다는 해석이 자연스럽다.

이 해석은 null control이 더 강하게 뒷받침한다. ontology basis는 단지 교란이 약해서 안전한 방향이 아니다. 오히려 가장 큰 effective perturbation magnitude를 만들면서도 K-side 비교에서 유일하게 안정적인 방향이고, 동시에 Q-side gain을 보존하는 유일한 기저다. 실무적으로는 기저의 품질과 개입 위치를 함께 봐야 한다는 뜻이다. 기저만 좋아서는 충분하지 않고, 개입 강도만으로도 행동을 설명할 수 없다.

6.1 현재 증거가 이미 배제하는 해석

현재 증거만으로도 몇 가지 해석은 이미 배제된다. 첫째, 이 효과는 임의의 저랭크 교란으로 설명되지 않는다. random과 feature-shuffled control은 같은 패턴을 재현하지 못한다. 둘째, 이것은 단지 약한 개입이라서 안전한 현상도 아니다. 실제 ontology basis는 null control보다 더 큰 perturbation을 만들면서도 유일하게 안정적이다. 셋째, “저랭크 추론 개입이면 비슷하다”는 설명도 맞지 않는다. 이 과제에서는 개입의 부호와 위치가 coverage 쪽으로 작동하는지, 아니면 반복 강조 쪽으로 작동하는지가 행동을 가른다.

이 관찰은 왜 closest-prior 비교를 반드시 locked protocol로 해야 하는지도 설명한다. SEKA나 AdaSEKA와의 비교는 scorer, prompt formatting, decoding policy, source basis handling이 모두 같을 때만 의미가 있다. 그렇지 않으면 측정된 차이가 메커니즘 차이인지 평가 프로토콜 차이인지 구분할 수 없다. 그래서 이 논문의 1차 주장은 benchmark ranking보다 task-structure mismatch에 있다.

남는 핵심 해석 문제는 F1 변화가 실제로 sequential coverage를 얼마나 직접 반영하는가이다. 이 질문에는 stepwise 분석이 가장 적합하다. first-tool accuracy, second-tool accuracy, repeated-first-facet failure를 분리해서 보면, 구조 이론이 예측한 방향으로 정말 두 번째 결정이 바뀌는지 더 직접 확인할 수 있다.

7 결론

멀티-툴 선택은 single-tool routing의 작은 변형이 아니다. 한 번 도구를 출력한 뒤 모델에게 필요한 것은 같은 facet의 반복 증폭이 아니라 coverage다. 본 논문의 실험은, 간단한 ontology-guided query-space bias가 이 문제에서 올바른 부호를 가지는 반면, 동일한 기저를 쓰는 stationary key-side bias는 그렇지 않다는 점을 보여준다.

경험적 그림은 간결하다. MetaTool Subtask4에서 Q-bias는 Qwen과 Llama 모두의 F1을 올리고, ontology basis는 효과에 필수적이며, 안정적인 K-side 방향은 가장 작은 perturbation이 아니라 가장 특이적인 basis에서만 나온다. 이 결과는 멀티-툴 선택에서 coverage와 정렬되는 개입은 query-side suppression이며, stationary key amplification은 그렇지 않다는 메커니즘 수준의 결론을 제공한다.

A 증명과 추가 평가 측

A.1 명제 1의 증명

Setup. $T_\alpha = I + \alpha P$ 라고 두자. 디코딩 단계 u 에서 개입은 현재 key vector $k_{u,t}$ 를 $T_\alpha k_{u,t}$ 로 바꾼다. 이 사상은 현재 key tensor와 고정 파라미터 (P, α) 에만 의존하며, 이전에 어떤 도구가 나갔는지, 어떤 facet이 이미 사용되었는지, 혹은 외부 coverage 변수 같은 입력을 갖지 않는다.

1단계: 연산자가 실제로 보는 정보를 적는다. 위 사상은 현재 key tensor와 고정 파라미터 외의 입력을 받지 않는다.

2단계: 현재 key tensor가 같은 두 히스토리를 비교한다. 이제 과거 히스토리는 다르지만 현재 key tensor K_u 는 같은 두 디코딩 히스토리 $h, \tilde{h}$ 를 생각하자. stationary operator이므로 두 경우 모두

$$T_\alpha(K_u) = (I + \alpha P)K_u$$

가 적용된다. 따라서 변환된 key는 완전히 동일하다. 곧 연산자 자체는 “이미 사용함”과 “아직 사용하지 않음”을 구분하는 explicit variable을 새로 더하지 않는다. coverage 정보는 key-side map이 적용되기 이전의 모델 상태 안에 이미 존재해야 한다. 이것으로 명제가 증명된다.

3단계: 결론을 읽는다. 따라서 stationary key-side map은 explicit coverage variable을 자체적으로 생성하지 못한다.

A.2 명제 2의 증명

Setup. 온톨로지 부분공간으로의 직교사영을 P_{ont} 라고 하자. 임의의 질의를

$$q = q_{\parallel} + q_{\perp}, \quad q_{\parallel} = P_{\text{ont}}q, \quad q_{\perp} = (I - P_{\text{ont}})q$$

로 분해하면, query-side 개입은

$$q' = (I + \beta P_{\text{ont}})q = q_{\perp} + (1 + \beta)q_{\parallel}$$

가 된다. 따라서 ontology subspace에 직교한 성분은 그대로 유지되고, ontology-aligned coefficient는 모두 같은 계수 $1 + \beta$ 만큼 축소된다. $\beta < 0$ 이면 ontology-aligned mass가 균일하게 줄어든다. 즉 이 연산자는 새로운 history 변수나 학습된 selector를 도입하지 않으면서도 지배적 facet의 반복 사용을 약화시키는 가장 단순한 history-free coverage surrogate다.

1단계: 질의를 온톨로지 성분과 직교 성분으로 나눈다. 위 분해는 개입이 바꿀 수 있는 부분과 바꿀 수 없는 부분을 분리한다.

2단계: 개입을 대입해 닫힌 형태를 얻는다. 개입은 $q_{\perp}$ 는 그대로 두고 $q_{\parallel}$ 만 $1 + \beta$ 배 한다.

3단계: 부호 의미를 읽는다. $\beta < 0$ 이면 ontology-aligned mass가 일괄적으로 줄어들프로, 반복 facet 사용을 줄이는 방향의 가장 단순한 history-free surrogate가 된다.

253 A.3 정리 1의 증명

254 **Setup.** 질의 q 를 고정하고, 원래 attention logit을

$$\ell_t(q) = \frac{q \cdot k_t}{\sqrt{d}}, \quad \alpha_t(q) = \frac{q \cdot e_t}{\sqrt{d}}$$

255 라고 쓰자. 또한 $s_t(q) = \text{softmax}(\ell(q))_t$ 로 두고, 보간 출력

$$\phi(\tau) = \sum_{t=1}^T \text{softmax}(\ell(q) + \tau \alpha(q))_t v_t, \quad \tau \in [0, 1]$$

256 를 정의하자. 그러면 $\phi(0) = o(q)$ 이고 $\phi(1) = \hat{o}(q)$ 다. 적분 나머지항을 갖는 Taylor 정리에 의해

$$\hat{o}(q) - o(q) = L(q, E) + R(q, E)$$

257 이며,

$$L(q, E) = \sum_{t=1}^T s_t(q) \alpha_t(q) (v_t - o(q)), \quad R(q, E) = \int_0^1 (1 - \tau) \phi''(\tau) d\tau$$

258 이다.

259 **1단계: 정확한 분해.** 직전 식은 근사가 아니라 exact identity다. 남은 증명은 두 가지 재료만 쓴다.
260 1차항에 대한 weighted Cauchy-Schwarz 한 번과 remainder에 대한 Hessian 상계 한 번이다.

261 **2단계: 1차항 상계.** 먼저 1차항에 weighted Cauchy-Schwarz를 적용하면

$$\|L(q, E)\|^2 \leq \left(\sum_{t=1}^T s_t(q) \alpha_t(q)^2 \right) \left(\sum_{t=1}^T s_t(q) \|v_t - o(q)\|^2 \right) = \text{qaMSE}(q; E) \text{Var}_s[V](q)$$

262 를 얻는다.

263 **3단계: remainder 상계.** 다음으로 softmax Hessian 항등식으로부터

$$\|\phi''(\tau)\| \leq 2V_{\max} \sum_{t=1}^T s_t(\tau) \alpha_t(q)^2$$

264 가 따른다. 또한 $\|q\| \leq Q_{\max}$, $\|e_t\| \leq \rho$ 이면

$$|\alpha_t(q)| \leq \frac{Q_{\max} \rho}{\sqrt{d}}$$

265 이므로

$$\|R(q, E)\| \leq V_{\max} \sup_{\tau \in [0, 1]} \sum_{t=1}^T s_t(\tau) \alpha_t(q)^2 \leq \frac{Q_{\max}^2 V_{\max} \rho^2}{d}$$

266 다.

267 **4단계: 결합.** 마지막으로 $\|L + R\|^2 \leq 2\|L\|^2 + 2\|R\|^2$ 를 쓰면

$$\|\hat{o}(q) - o(q)\|^2 \leq 2 \text{qaMSE}(q; E) \text{Var}_s[V](q) + \frac{2Q_{\max}^4 V_{\max}^2 \rho^4}{d^2}$$

268 를 얻는다. 마지막으로 q 에 대해 기대값을 취하면 정리가 증명된다.

269 A.4 추가로 확인된 보조 증거

270 두 가지 보조 결과는 유의미하지만 본문을 이끌 정도로 강하지는 않다.

271 첫째, Subtask1의 strict scorer에서도 ontology basis 특이성은 유지된다. Qwen의 mean
272 scorer에서는 real ontology basis가 top-1 accuracy를 0.3678에서 0.4181로 올리지만, ran-
273 dom과 feature-shuffled control은 각각 0.1377, 0.2553에 머문다. Llama의 mean scor-
274 er에서도 real basis는 0.2312 $\rightarrow$ 0.2573으로 올라가고, random과 feature-shuffled control은
275 각각 0.2251, 0.2171에 그친다. 이는 ontology basis의 효과가 단일 scorer 하나에만 묶여 있지
276 않다는 뜻이다.

277 둘째, 작은 α_K 를 더한 Q+K 상호작용은 Qwen에서 보이지만 아직 headline으로 올리기에는
278 국소적이다. $\beta = -0.1$ 위에 $\alpha_K = 0.025$ 와 $\alpha_K = 0.05$ 를 더하면 macro F1이 각각 0.7529,
279 0.7502로 Q-only의 0.7471보다 높다. 그러나 이 밴드는 매우 좁고 cross-family 재검증이 아직
280 충분하지 않으므로, 독립적인 핵심 방법이라기보다 query-side suppression의 가능한 refine-
281 ment로 해석하는 편이 안전하다.

A.5 Closest-prior 비교를 위한 프로토콜 메모

외부 비교 가운데 가장 결정적인 것은 동일 scorer, 동일 prompt template, 동일 ontology catalog를 맞춘 SEKA, AdaSEKA head-to-head다. 이런 정합이 없으면 큰 성능 차이도 메커니즘 차이보다 평가 프로토콜 차이로 치부되기 쉽다.

메커니즘 검증 가운데 가장 결정적인 것은 stepwise coverage 분해다. 중심 주장은 최종 정답이 조금 바뀐다는 데 있지 않고, 첫 번째 도구가 나온 뒤 같은 facet을 반복하는 경향을 줄인다는 데 있다. 따라서 first-tool과 second-tool을 분리한 분석이 또 하나의 aggregate row보다 훨씬 강한 증거가 된다.

질적 검증은 heatmap 단독보다 trajectory 묶음이 낫다. 권장 묶음은 per-token hook over-head, decoding step별 ontology-energy trace, 그리고 steering 전후의 emitted tool sequence를 보여주는 소수의 사례다. attention map은 이런 stepwise dynamics가 먼저 확인된 뒤 보조 그림으로 붙을 때 가장 설득력이 크다.

참고문헌

Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Anjali Mathur, Ashwin Schelten, Amy Vaughan, et al. The llama 3 herd of models. arXiv preprint arXiv:2407.21783, 2024.

Albert Q. Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, et al. Mistral 7b. arXiv preprint arXiv:2310.06825, 2023.

Kenneth Li, Oam Patel, Fernanda Viégas, Hanspeter Pfister, and Martin Wattenberg. Inference-time intervention: Eliciting truthful answers from a language model. arXiv preprint arXiv:2306.03341, 2023.

Weixian Waylon Li, Yuchen Niu, Yongxin Yang, Keshuang Li, Tiejun Ma, and Shay B. Cohen. Spectral attention steering for prompt highlighting. In The Fourteenth International Conference on Learning Representations, 2026. URL <https://openreview.net/forum?id=XfLvGIFmAN>.

Zirui Liu, Jiayi Yuan, Hongye Jin, Shaochen Zhong, Zhaozhuo Xu, Vladimir Braverman, Beidi Chen, and Xia Hu. Kivi: A tuning-free asymmetric 2bit quantization for kv cache. Proceedings of Machine Learning Research, 235:32332–32344, 2024.

Yifu Qiu, Zheng Zhao, Yftah Ziser, Anna Korhonen, Edoardo Ponti, and Shay B. Cohen. Spectral editing of activations for large language model alignment. In The Thirteenth International Conference on Learning Representations, 2025. URL <https://openreview.net/forum?id=pqYceEa87j>.

Qwen Team, An Yang, Baolin Yang, Beichen Zhang, Binyuan Hui, Bowen Zheng, Bowen Yu, Cheng Li, Dayiheng Liu, Fei Huang, et al. Qwen2.5 technical report. arXiv preprint arXiv:2412.15115, 2024.

Nina Rimskey, Noga Gabrieli, Sarel Obler, Tomer Lindsay, Amit Arbisser, and Bernardo Huberman. Steering language models with activation engineering. arXiv preprint arXiv:2308.10248, 2024.

Yuan Tian and Tianyi Zhang. Selective prompt anchoring for code generation. In Proceedings of the 42nd International Conference on Machine Learning, 2025. URL <https://proceedings.mlr.press/v267/tian25a.html>.

Qingru Zhang, Chandan Singh, Liyuan Liu, Xiaodong Liu, Bin Yu, Jianfeng Gao, and Tuo Zhao. Tell your model where to attend: Post-hoc attention steering for llms. In The Twelfth International Conference on Learning Representations, 2024. URL <https://arxiv.org/abs/2311.02262>.

Youxiang Zhu, Ruochen Li, Danqing Wang, Daniel Haehn, and Xiaohui Liang. Focus directions make your language models pay more attention to relevant contexts. arXiv preprint arXiv:2503.23306, 2025.