

멀티-툴 선택을 위한 온톨로지 기반 질의 커버리지 바이어스

Anonymous Author(s)

Affiliation

Address

email

Abstract

멀티-툴 에이전트 프롬프트에서는 모델이 도구 하나를 고르는 데서 끝나지 않고, 서로 다른 두 개 이상의 도구를 순차적으로 내보내야 한다. 이때 핵심 문제는 단일 단계 순위화가 아니라 커버리지다. 본 논문은 q_proj 에서 온톨로지 정렬 성분을 억제하는 질의 공간 바이어스를 평가하고, 동일한 온톨로지 기저를 사용하는 정적 key-space 바이어스와 비교한다. MetaTool Subtask4의 497개 two-tool 질의에서 질의 측 바이어스는 Qwen2.5-7B-Instruct의 macro F1을 0.7307에서 0.7471로, Llama-3.1-8B-Instruct의 macro F1을 0.6227에서 0.6271로 높인다. 반면 정적 key-space 바이어스는 Qwen에서 0.6850, Llama에서 0.3105로 악화된다. 이 결과는 임의의 저랭크 교란으로 설명되지 않는다. Qwen에서 온톨로지 기저를 feature-shuffled 또는 random control로 바꾸면 질의 측 결과는 각각 0.7254, 0.7068로 내려가고, key-side control은 둘 다 0.0000으로 붕괴한다. 추가 진단은 유효 영역이 매우 좁고 최적 Q-only 지점이 $\beta = -0.1$ 근처에 있으며, 실제 온톨로지 교란의 유효 attention magnitude가 null control보다 오히려 더 크다는 점을 보여준다. 따라서 본 논문의 주장은 좁지만 일관적이다. 멀티-툴 선택에서는 query-side coverage bias가 생산적인 방향이고, 정적인 key-side 증폭은 그렇지 않으며, 온톨로지 기저는 임의의 투영군이 아니라 안정적인 특정 부분공간을 식별하기 때문에 중요하다.

1 서론

툴을 사용하는 언어모델 평가는 종종 질의마다 하나의 정답 도구만 있다고 가정한다. 그러나 실제 에이전트 질의는 그렇지 않다. 사용자는 뉴스와 금융 영향을 함께 묻거나, 여행 계획과 환율 정보를 동시에 요청한다. 이런 경우 모델은 도구 하나를 잘 고르는 것보다 서로 다른 도구를 순서대로 빠짐없이 복원해야 한다.

이 논문은 바로 그 멀티-툴 상황을 다룬다. 출발점은 단순한 실패 모드다. 어떤 정적인 attention 개입이 모든 디코딩 단계에서 같은 facet을 계속 증폭하면, 첫 번째 도구를 이미 출력한 뒤에도 같은 facet을 다시 밀어주게 된다. 멀티-툴 질의에서는 이것이 잘못된 귀납 편향이다. 두 번째 단계에서는 첫 번째 단계와 달라질 수 있어야 하기 때문이다.

우리가 평가하는 개입은 기존 key-side steering 실험과 동일한 per-head ontology basis 위에서 정의되는 query-space 바이어스다. 구현은 의도적으로 단순하다. 각 layer에서 query를 ontology subspace로 사영한 뒤, 그 성분에 부호가 있는 계수를 곱해 더한다. 음수 계수는 ontology-aligned query 성분을 억제하므로 coverage bias처럼 작동한다. 가설도 명확하다. 멀티-툴 프롬프트에서는 이런 억제가 두 번째 도구 복원을 도와야 하고, 같은 기저를 쓰는 정적 key-side 바이어스는 효과가 없거나 첫 번째 facet에 과도하게 집중해야 한다.

실험은 이 가설을 지지하지만, 강한 의미에서가 아니라 좁은 의미에서 그렇다. MetaTool Subtask4에서 query-side 바이어스는 Qwen과 Llama 모두에서 양의 효과를 보이지만, 정적 key-side 바이어스는 두 모델 모두에서 음의 효과를 보이며 Llama에서는 거의 붕괴 수준이다. 절대적인

이득은 크지 않다. 따라서 이 논문을 대규모 정확도 돌파로 포장할 수는 없다. 대신 중요한 점은 부호 패턴이 안정적이고, null control이 결정적이며, 기저 특이성에 대한 이야기가 단순한 raw gain보다 더 강하다는 사실이다.

본 논문은 세 가지를 주장한다. 첫째, 현재 벤치마크에서 멀티-툴 선택에 유효한 방향은 query-space coverage bias다. 둘째, ontology basis는 핵심 요소다. 이를 random basis나 feature-shuffled basis로 바꾸면 query-side 이득이 사라지고 key-side 안정성도 무너진다. 셋째, attention perturbation 분석에서 사용하는 국소 경계는 공허한 형식주의가 아니다. Qwen과 Llama 모두에서 경험적 비율이 매우 작게 측정되며, 이는 이 개입들을 진단하는 언어로서 경계를 사용하는 것이 수치적으로 무리하지 않음을 뜻한다. 다만 이 논문은 SEKA나 AdaSEKA를 동일 조건에서 완전히 이겼다고 주장하지 않는다. 주장은 더 좁다. 하나 이상의 도구를 순차적으로 복원해야 할 때는 단순히 저랭크 개입이라는 사실보다, 개입의 위치와 부호가 더 중요하다는 것이다.

2 관련 연구

가장 가까운 선행 흐름은 spectral key-space steering이다. SEKA는 synthetic question-answer pair로부터 저랭크 projection을 학습한 뒤 추론 시 attention key에 주입하고, AdaSEKA는 이를 소수의 expert projection과 입력별 expert selector로 확장한다 [Li et al., 2026]. 이 계열은 prompt highlighting과 단일 목표 강조에 맞게 설계되어 있다. projection이 한 번 선택되면 같은 방향이 디코딩 전 과정에 걸쳐 반복 적용되므로, 연산자 자체는 본질적으로 stationary하다. 이런 설계는 하나의 지배적인 target attribute를 보존하거나 복원하는 문제에서는 자연스럽다.

본 논문은 먼저 과제가 다르다. 우리는 한 질의에서 두 개의 도구를 순차적으로 내보내야 하는 multi-tool selection을 직접 다룬다. 이 설정에서는 실패 모드가 달라진다. 같은 facet을 계속 증폭하는 방법은 single-selection 벤치마크에서는 합리적으로 보일 수 있어도, sequential coverage가 필요한 문제에서는 구조적으로 맞지 않을 수 있다. 두 번째 디코딩 단계는 첫 번째와 더 비슷해져야 하는 것이 아니라, 오히려 달라져야 하기 때문이다. 그래서 이 논문은 자신을 “또 하나의 SEKA 변형”으로 제시하지 않는다. 대신 stationary key-side recipe가 언제 과제 구조와 어긋나는지를 묻는 논문으로 제시한다.

차이는 개입 위치에서도 나타난다. 이 논문에서 양의 결과를 만드는 연산자는 key amplification이 아니라 query-side operator다. 여전히 저랭크이고 ontology-derived basis를 사용하므로, SEKA류 편집과 충분히 가까워 비교가 무의미하지는 않다. 동시에 keys에서 queries로 이동하면 부호의 의미가 달라진다. 음의 query-space 계수는 이미 지배적인 ontology-aligned 성분을 눌러주며 거친 coverage prior처럼 행동한다. 실험을 해석할 때 독자가 기억해야 할 핵심 대비는 바로 이 지점이다.

더 넓게 보면 이 논문은 training-time routing이 아니라 post-hoc activation steering에 속한다. 개입은 추론 시 attention-space hook으로 적용되며, 추가 학습도 없고 외부 selector network도 없다. 이것은 의도적인 선택이다. history tracking이나 별도의 learned controller를 도입하기 전에, ontology basis의 기하와 개입 위치만으로도 효과의 부호가 결정되는지를 먼저 분리해서 보고자 했기 때문이다.

KV-cache compression은 본 논문의 중심 질문과는 별개다. KIVI 같은 방법은 저비트 cache 표현과 메모리-품질 절충을 다루지, tool-selection dynamics를 다루지 않는다 [Liu et al., 2024]. 이 저장소의 이전 초안에는 그런 압축 실험도 포함되어 있었지만, 현재 원고는 의도적으로 steering과 multi-tool selection에만 초점을 맞춘다. 사용 모델은 instruction-tuned Qwen, Llama, Mistral 계열 [Qwen Team et al., 2024, Grattafiori et al., 2024, Jiang et al., 2023]이며, 주 실험은 MetaTool Subtask4를 사용한다. 이 벤치마크는 two-tool output을 요구하기 때문에, stationary single-facet steering이 부딪힐 것으로 예상되는 sequential coverage 문제를 직접 드러낸다.

3 방법

3.1 온톨로지 기저

모든 실험은 tool catalog로부터 구성된 per-head ontology basis $B_{\text{ont}} \in \mathbb{R}^{L \times H_{\text{kv}} \times d \times r}$ 를 사용한다. 직관적으로 이 기저는 금융, 뉴스, 여행, 미디어 같은 tool facet에서 반복적으로 나타나는

85 방향을 span한다. 평가 시점에서 기저는 고정되며, query-side와 key-side 개입이 동일한 기저를
86 공유한다.

87 3.2 실용적인 query-space coverage bias

88 query tensor q 에 대해 구현된 query-side 개입은 다음과 같다.

$$q' = q + \beta B_{\text{ont}} B_{\text{ont}}^{\top} q.$$

89 $\beta < 0$ 이면 연산자는 ontology subspace에 정렬된 query 성분을 빼준다. 코드에서는 이를
90 q_{proj} 에 대한 forward hook으로 구현한다. 이 방법은 history-free다. 어떤 도구가 이미
91 출력되었는지를 명시적으로 추적하지 않는다. 따라서 우리는 이를 더 강한 이상적 coverage op-
92 erator의 실용적 근사로 해석하며, 문자 그대로의 per-step facet-state tracking으로 해석하지
93 않는다.

94 3.3 정적인 key-side bias

95 비교 대상으로는 동일한 기저를 사용하는 key-side 개입을 둔다.

$$k' = k + \alpha B_{\text{ont}} B_{\text{ont}}^{\top} k.$$

96 이 개입은 정의상 stationary하다. 모든 디코딩 단계에서 같은 ontology-aligned key direc-
97 tion을 증폭한다. 첫 번째로 출력된 도구가 이미 지배적 facet을 차지하고 있다면, 이 연산자는 이후
98 단계에서 그 facet을 억제할 방법이 없다.

99 3.4 작업 가설

100 본 논문의 작업 가설은 두 부분으로 이루어진다. 첫 번째는 정확도 가설이다. 음의 query-side on-
101 tology bias는 지배적인 facet의 반복 사용을 줄여주므로 multi-tool recovery를 향상시켜야 한다.
102 두 번째는 특이성 가설이다. ontology basis를 동일 rank의 random basis나 feature-shuffled
103 basis로 대체하면 효과가 사라져야 한다. 실험은 이 두 주장을 직접 검증하도록 설계되어 있다.

104 4 이론

105 실험을 정당화하는 데 긴 형식 체계가 필요한 것은 아니다. 여기서는 두 개의 단순한 구조적 명제와
106 하나의 경험적 정리만으로 충분하다.

107 **명제 4.1.** 정적인 key-side projection은 emission history를 표현할 수 없다. 특히 같은 연산자
108 $k' = k + \alpha P k$ 가 모든 디코딩 단계에 적용되면, 추가 상태가 없는 한 이 연산자는 “이미 사용한
109 facet”과 “아직 사용하지 않은 facet”을 구분할 수 없다.

110 이 명제는 통계적이기보다 구조적이다. 연산자가 시간에 대해 불변이기 때문에, coverage에
111 해당하는 단계별 정보는 모델 내부 동역학에서만 나올 수 있다. 개입 자체는 상태를 제공하지 않는다.

112 **명제 4.2.** *coverage*의 query-side 대응물은 현재 query를 이미 사용된 facet 방향에서 억제하는
113 연산자다. 실용적인 history-free 근사는 full ontology subspace에 대한 사영을 억제하는 것이다.

114 첫 문장은 이상적인 메커니즘을 설명하고, 둘째 문장은 본 논문이 실제로 평가한 구현을 설명한다.
115 따라서 실험의 질문은 거친 근사만으로도 two-tool benchmark에서 올바른 부호를 얻을 수
116 있는가이다.

117 **정리 4.3.** LHS를 경험적 attention-output perturbation, RHS를 프로젝트의 perturbation
118 analysis에서 정의한 local bound term이라고 하자. Qwen과 Llama 모두에서 관측된 median
119 ratio LHS/RHS는 10^{-8} 수준이므로, 이 논문이 다루는 개입에 대해 해당 진단 경계는 수치적으로
120 보수적이다.

121 이 정리는 본 논문에서 경험적 진술이다. 역할은 end-to-end accuracy를 증명하는 것이 아니라,
122 query-side와 key-side 개입을 설명할 때 사용하는 perturbation language가 실제 출력 변화의
123 크기와 양립 가능하다는 것을 보이는 데 있다.

124 **비고 4.4.** 여기서의 이론은 이 저장소의 이전 초안보다 의도적으로 좁다. 우리는 현재 구현이 정확한
125 step-adaptive facet tracking을 실현한다고 주장하지 않으며, 검증되지 않은 compression 또는
126 predictor 결과를 주된 정리 사슬에 포함하지 않는다.

표 1: Subtask4의 주 결과. Q-side bias는 두 모델 모두에서 양의 효과를 보이고, stationary K-side bias는 두 모델 모두에서 음의 효과를 보이며 Llama에서는 붕괴 수준이다.

모델	방법	F1	Exact	Jaccard
Qwen2.5-7B-Inst	No steer	0.7307	0.5252	0.6673
Qwen2.5-7B-Inst	Q-bias $\beta = -0.1$	0.7471	0.5272	0.6791
Qwen2.5-7B-Inst	K-bias $\alpha = 0.3$	0.6850	0.4728	0.6194
Llama-3.1-8B-Inst	No steer	0.6227	0.5030	0.5872
Llama-3.1-8B-Inst	Q-bias $\beta = -0.1$	0.6271	0.5070	0.5919
Llama-3.1-8B-Inst	K-bias $\alpha = 0.3$	0.3105	0.2616	0.2951




그림 1: Subtask4 macro F1. 왼쪽 패널에는 Qwen의 null control도 함께 표시했다.

5 실험

5.1 설정

주 벤치마크는 MetaTool Subtask4다. 이 벤치마크는 497개의 프롬프트로 이루어져 있으며, 각 질의마다 정확히 두 개의 ground-truth tool이 있다. 평가지표는 macro F1, Exact match, Jaccard다. 주 모델은 Qwen2.5-7B-Instruct와 Llama-3.1-8B-Instruct이며 [Qwen Team et al., 2024, Grattafiori et al., 2024], 모든 평가는 ontology basis를 고정한 greedy decoding으로 수행했다.

5.2 주 결과: Q-side는 양수, K-side는 음수

표 1와 그림 1는 핵심 결과를 요약한다. 부호 패턴은 두 모델 계열에서 일관된다. Q-side coverage bias는 macro F1을 높이고, stationary K-side bias는 성능을 떨어뜨린다.

절대적인 이득은 크지 않다. Qwen에서는 +1.64pp, Llama에서는 +0.44pp에 그친다. 이것만으로 대담한 정확도 개선을 주장할 수는 없다. 중요한 점은 부호가 모델 계열을 바꿔도 유지된다는 사실과, stationary K-side 개입은 부호가 뒤집힐 뿐 아니라 Llama에서 급격히 무너진다는 사실이다. 따라서 이 논문이 내릴 수 있는 결론은 방향성에 관한 것이다. 멀티-툴 recovery가 목표라면 query-space suppression이 유효한 축이고, stationary key-space amplification은 그렇지 않다.

5.3 온톨로지 특이성이 결정적이다

더 강한 결과는 headline gain 자체보다 null control의 거동이다. 표 2는 ontology basis를 feature-shuffled basis나 random basis로 대체하면 query-side 이득이 사라지고, key-side 안정성은 완전히 붕괴한다는 점을 보여준다.

이 점이 이 논문에서 가장 설득력 있는 실증 결과다. 임의의 저랭크 교란만으로는 충분하지 않다. rank와 채널 스케일을 유지하는 구조 보존형 control도 실패한다. 실무적 함의도 분명하다. ontology basis는 rank가 같은 임의의 projection으로 대체 가능한 부품이 아니다.

표 2: Qwen Subtask4의 null control. K-side 안정성을 유지하면서 Q-side 이득을 주는 기저는 ontology basis뿐이다.

방법	Real basis	Feature-shuffled	Random
Q-bias $\beta = -0.1$ F1	0.7471	0.7254	0.7068
K-bias $\alpha = 0.3$ F1	0.6850	0.0000	0.0000

The useful regime is narrow: beta near -0.1 and alpha_K near 0.025-0.05




그림 2: Qwen Subtask4에서의 Q-bias sweep과 small- α_K ablation. 두 곡선 모두 유효 구간이 매우 좁다.

149 5.4 유효한 작동 구간은 매우 좁다

150 그림 2는 Qwen Subtask4에 대한 두 개의 ablation을 보여준다. Q-only sweep은 평균한 값들
151 중에서 $\beta = -0.1$ 근처에서 최대를 보인다. 두 번째 sweep은 Q-side operator 위에 작은 K-bias를
152 추가한 경우인데, $\alpha_K \in [0.025, 0.05]$ 인 아주 좁은 범위만이 Q-only 설정보다 낫다.

153 이 좁은 작동 구간은 해석에 중요하다. 결과는 “bias가 클수록 좋다”가 아니다. “작은 음의 Q-
154 side projection은 도움이 되지만, 그 밖의 대부분의 설정은 오히려 성능을 깎는다”에 가깝다. 이런
155 패턴은 조잡한 confidence boost보다 coverage effect 해석과 더 잘 맞는다.

156 5.5 안정성은 단지 교란이 작아서 생긴 것이 아니다

157 자연스러운 반론은 실제 ontology basis가 null control보다 교란을 덜 주기 때문에 더 안전한 것
158 아니냐는 것이다. 그림 3는 이 설명을 반박한다. 실제 ontology basis는 null control보다 더 큰
159 effective attention perturbation magnitude를 만든다. 그럼에도 안정적인 K-side 방향은 실제
160 basis뿐이다.

161 이 때문에 null-control 결과는 의미가 있다. 실제 basis가 이기는 이유는 약해서가 아니라, 특정한
162 안정 부분공간과 정렬되어 있기 때문이다. 같은 그림은 perturbation bound ratio가 두 모델 계열
163 모두에서 매우 작게 유지된다는 점도 보여준다.

164 5.6 보조 증거

165 저장소에는 MetaTool Subtask1의 single-tool 결과와 query-space stability에 기반한 predic-
166 tor smoke 실험도 포함되어 있다. 그러나 본 논문은 그것들을 주된 주장으로 삼지 않는다. 그
167 결과들은 일관성 점검으로는 유용하지만, 현재 원고는 multi-tool selection, ontology speci-
168 ficity, 그리고 query-side 개입과 stationary key-side 개입의 대비에 집중할 때 가장 강하다.

169 6 논의

170 이 논문은 보편적 steering 프레임워크 논문이라기보다, 범위를 좁힌 메커니즘 논문으로 읽는
171 편이 맞다. Q-side 이득은 실제로 존재하지만 작다. 반면 K-side 안정성 결과는 훨씬 크고
172 결정적이지만, 그것은 multi-tool prompt에서 stationary key-space steering이 어디서




그림 3: 두 가지 진단. 왼쪽은 실제 ontology perturbation이 null control보다 더 크다는 점을 보여주었고, 오른쪽은 경험적 perturbation-bound ratio가 Qwen과 Llama 모두에서 매우 작다는 점을 보여준다.

표 3: 경험적 perturbation bound 요약. 측정된 left/right ratio는 두 모델 모두에서 매우 작다.

모델	Layer	Head-query count	Median LHS/RHS	Mean LHS
Qwen2.5-7B-Inst	13	2800	2.36×10^{-8}	0.5092
Llama-3.1-8B-Inst	15	3200	6.37×10^{-8}	0.0586

173 실패하는지를 보여주는 부정적 교훈에 가깝다. 이 두 사실을 분리해서 쓰는 편이 논문의 응집성을
174 높인다.

175 한계도 세 가지가 분명하다. 첫째, 평가한 Q-side operator는 history-free 근사다. coverage
176 메커니즘에서 영감을 받았지만, 어떤 facet이 이미 방출되었는지를 명시적으로 추적하지는 않는다.
177 둘째, multi-tool 결과는 아직 단일 benchmark family에서만 확인되었다. 셋째, 정확히 같은 모델,
178 프롬프트, 디코딩 조건에서 외부 SEKA 또는 AdaSEKA 구현과 맞춘 대규모 비교는 아직 없다. 이
179 부재는 주장을 숨기는 부분이 아니라, 논문의 범위를 규정하는 경계로 읽어야 한다.

180 그럼에도 기여는 남는다. 이 논문은 안정적인 부호 패턴을 확인하고, 강한 null control로 기저
181 특이성을 분리하며, 단지 perturbation magnitude가 작아서 안전한 것 아니냐는 쉬운 대안을
182 제거한다. 이 정도면 현재의 multi-tool setting에서 ontology-guided query suppression이
183 stationary key amplification보다 더 맞는 방향이라는 좁은 주장을 지지하기에 충분하다. 동시에
184 이후의 정합 비교가 어떻게 설계되어야 하는지도 분명해진다. 핵심 질문은 SEKA류 projection이
185 도움이 되느냐가 아니라, sequential facet coverage가 필요한 상황에서 어떤 stationary key-
186 side 방법이 과연 경쟁력을 유지할 수 있느냐이다.

187 7 결론

188 멀티-툴 선택은 single-tool routing의 작은 변형이 아니다. 한 번 도구를 출력한 뒤 모델에게 필요한
189 것은 같은 facet의 반복 증폭이 아니라 coverage다. 본 논문의 실험은, 간단한 ontology-guided
190 query-space bias가 이 문제에서 올바른 부호를 가지는 반면, 동일한 기저를 쓰는 stationary key-
191 side bias는 그렇지 않다는 점을 보여준다.

192 경험적 그림은 간결하다. MetaTool Subtask4에서 Q-bias는 Qwen과 Llama 모두의 F1을
193 올리고, ontology basis는 효과에 필수적이며, 안정적인 K-side 방향은 가장 작은 perturbation이
194 아니라 가장 특이적인 basis에서만 나온다. 이 사실들은 다음 단계도 분명히 제시한다. 더 넓지만
195 약한 주장을 덧붙이기보다, 실제 history-aware coverage operator를 구현하고 검증하는 편이
196 타당하다.

197 참고문헌

198 Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Ka-
199 dian, Ahmad Al-Dahle, Aiesha Letman, Anjali Mathur, Ashwin Schelten, Amy Vaughan,

200 et al. The llama 3 herd of models. arXiv preprint arXiv:2407.21783, 2024.

201 Albert Q. Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh
202 Chaplot, Diego de las Casas, et al. Mistral 7b. arXiv preprint arXiv:2310.06825, 2023.

203 Weixian Waylon Li, Yuchen Niu, Yongxin Yang, Keshuang Li, Tiejun Ma, and Shay B. Co-
204 hen. Spectral attention steering for prompt highlighting. In The Fourteenth Inter-
205 national Conference on Learning Representations, 2026. URL [https://openreview.](https://openreview.net/forum?id=XfLvGIFmAN)
206 [net/forum?id=XfLvGIFmAN](https://openreview.net/forum?id=XfLvGIFmAN).

207 Zirui Liu, Jiayi Yuan, Hongye Jin, Shaochen Zhong, Zhaozhuo Xu, Vladimir Braverman,
208 Beidi Chen, and Xia Hu. Kivi: A tuning-free asymmetric 2bit quantization for kv cache.
209 Proceedings of Machine Learning Research, 235:32332–32344, 2024.

210 Qwen Team, An Yang, Baolin Yang, Beichen Zhang, Binyuan Hui, Bowen Zheng, Bowen
211 Yu, Cheng Li, Dayiheng Liu, Fei Huang, et al. Qwen2.5 technical report. arXiv preprint
212 arXiv:2412.15115, 2024.