

부호 반영 회전 스티어링: 온톨로지 부분공간 위의 멀티-툴 도구 선택을 위한 훈련-없는 Q-커버리지와 부호 예측기

Anonymous Author(s)

Affiliation

Address

email

초록

멀티-툴 도구 호출을 강화하는 기존 네 접근 — tool-aware 파인튜닝, 프롬프트 스캐폴딩, KV-cache 최적화, 활성 스티어링 — 중 본 논문은 활성 스티어링에 속하는 훈련-없는 회전 기반 방법을 제시한다. 카탈로그에서 직접 유도한 per-head 온톨로지 부분공간 P_{ont} 위에서 질의를 $Q' = Q + \beta Q P_{\text{ont}}$ 로 회전시키되, 회전의 부호는 도메인마다 다르다. MetaTool Subtask4와 τ^2 -bench retail에서는 $\beta < 0$ (coverage 억제)이 승리하지만 τ^2 -bench telecom에서는 $\beta > 0$ (증폭)이 +24.78pp로 우세하다. 이 도메인 의존성이 기존 활성 스티어링 문헌이 해결하지 못한 “어느 부호를 쓸 것인가” 문제를 부각한다. 본 논문은 baseline forward pass 한 번으로 측정 가능한 값 $\bar{r}_G - \bar{r}$ 의 부호가 최적 β^* 의 부호와 일치함을 softmax gradient로부터 직접 증명하고(정리 3.3), 이 예측기를 Adaptive Sign Routing 알고리즘으로 구현하여 4개 Qwen2.5-7B 도메인(MetaTool ST4, τ^2 -retail/telecom/airline)에서 부호 예측 정확도와 성능 이득을 동시에 검증한다. 가장 가까운 선행 방법인 SEKA와 AdaSEKA는 정지 key-side 증폭이 방출 도구 상태를 구조적으로 담을 수 없어(정리 3.1) 멀티-툴에서 한계를 가지며, 본 연구의 회전 기반 연산자는 이를 SEKA와 동일한 프로토콜 아래 여러 도메인에서 일관되게 상회한다. 방법은 가중치 학습이 0, 토큰 오버헤드가 0, 저장이 per-head 기저 (L, H_{kv}, d, r) 만 추가(≈ 2.6 MB on Qwen 7B)로 추론 시 저랭크 hook이다. 카탈로그 온톨로지 기저를 feature-shuffled, random, PCA-of-K로 교체 시 효과가 사라져, 이득이 기저 품질이 아니라 회전 연산자 설계와 부호 선택에서 옴을 분리한다.

1 서론

LLM 에이전트가 실전에서 유용하려면 한 질의에 여러 도구를 순차적으로 호출할 수 있어야 한다. “뉴스에서 주식 기사 찾아 요약해줘”라는 요청 하나에 NewsTool과 ResearchHelper를 순서대로 부르지 못하면, single-call 벤치마크에서의 높은 점수는 실전 가치와 연결되지 않는다. 이 멀티-툴 능력을 강화하는 길은 지금까지 네 방향으로 나뉘어 왔고 각각 서로 다른 비용-표적 trade-off를 가진다.

대량의 도구 호출 예시로 모델을 직접 finetuning하는 방법(Gorilla [Patil et al., 2023], Tool-Llama [Qin et al., 2024], xLAM [Zhang et al., 2024a])은 성능은 강하지만 가중치 수정이 필요해 카탈로그가 바뀔 때마다 재학습 비용을 치러야 한다. 프롬프트 스캐폴딩(ReAct [Yao et al., 2023] 등)은 학습이 필요 없는 대신 프롬프트 길이에 따라 비용이 선형 증가한다. KV-cache 최적화(KIVI [Liu et al., 2024b])는 추론 시간을 줄이는 데 집중하여 “무엇을 고를지”라는 과제 수준의 결정에는 직접 개입하지 않는다. 네 번째 방향이 본 논문이 속하는 활성 스티어링이다. 추론 시 attention에 저랭크 개입을 주입하여 가중치도 프롬프트도 건드리지 않고 행동을 조정한다.

활성 스티어링의 가장 가까운 선행 방법인 SEKA [Li and Others, 2025b]와 AdaSEKA [Li and Others, 2025a]는 attention key에 정지(stationary) 스펙트럴 증폭 $k' = k + \alpha P k$ 를 가한다. 단일 개념 편집(CounterFact)에서는 state-of-the-art지만 멀티-툴에서는 “이미 방출한

표 1: 멀티-툴 호출 강화의 네 접근과 본 논문의 위치.

접근	대표 방법	학습 free	멀티-툴 표적	부호 결정
Tool-aware finetuning	Gorilla, ToolLlama, xLAM	×	✓	n/a
Prompt scaffolding	ReAct, ToT	✓	프롬프트	n/a
KV-cache 최적화	KIVI, StreamingLLM	✓	×	n/a
정지 활성 스티어링	SEKA, AdaSEKA, ITI, CAA, PASTA	✓	×	고정(보통 +)
본 논문	Q-회전 + Adaptive Sign Routing	✓	✓	이론적 예측기

37 도구 방향”을 두 번째 단계에서 다시 증폭하여 실패한다. 본 논문은 먼저 이 실패가 정지 형식 자체의
38 구조적 귀결임을 한 줄로 증명한다(정리 3.1): 정지 연산자는 정의상 디코딩 단계와 방출 집합에
39 의존하지 않으므로 그 출력은 어떤 히스토리도 답을 수 없다.

40 이 구조적 한계를 넘는 가장 단순한 회전은 key를 증폭하는 대신 query를 회전시키는 것이다:
41 $Q' = Q + \beta QP_{\text{ont}}$. 그런데 β 의 부호가 어느 쪽이어야 하는가? 기존 이론은 $\beta < 0$ (“지배적
42 성분을 덜 신뢰하라”는 coverage prior)과 $\beta > 0$ (“온톨로지 정렬 방향을 증폭”)을 모두 정당화할
43 수 있지만, 어느 부호가 주어진 과제에서 이기는지 예측하지 못한다. 실제로 본 연구가 측정한 4개
44 Qwen 도메인에서 부호는 도메인마다 다르다: τ^2 -bench telecom에서는 $\beta > 0$ 이 +24.78pp로
45 이기고(표 3), MetaTool ST4와 τ^2 -retail에서는 $\beta < 0$ 이 이긴다. 부호가 free hyperparameter로
46 남으면 본 논문의 실용적 가치는 “grid search로 찾아 쓰세요”로 축소된다.

47 본 논문의 핵심 기여는 이 부호를 데이터 없이 예측하는 이론적 도구다. baseline forward pass
48 한 번의 softmax 분포에서 ground-truth 도구에 걸린 ontology-projected score의 조건부 평균
49 $\bar{r}_G$ 와 전체 평균 $\bar{r}$ 을 비교하면, softmax gradient identity로부터

$$\text{sign}(\beta^*) = \text{sign}(\bar{r}_G - \bar{r})$$

50 이 직접 유도된다(정리 3.3). 이것이 본 논문의 두 번째 정리이고, 단 한 번의 forward pass만
51 추가하여 per-query 또는 per-domain으로 부호를 결정하는 Adaptive Sign Routing 알고리즘을
52 낳는다. 네 Qwen 도메인에서 이 예측기는 부호를 4/4 정확히 맞췄고, 예측된 부호로 회전을 걸면
53 SEKA와 AdaSEKA를 일관되게 상회한다.

54 본 논문의 기여는 세 축으로 정리된다. 첫째, 정지 key-side 증폭이 멀티-툴에서 구조적으로
55 실패한다는 사실과 그 footprint가 repeated first tool rate의 상승임을 증명하고(정리 3.1)
56 데이터로 확증한다(§ 4.3). 둘째, 부호 예측기 정리 3.3와 Adaptive Sign Routing을 도입하여
57 Qwen2.5-7B의 네 도메인에서 부호를 4/4 맞추고 일관된 성능 이득을 낸다(§ 4.1, § 4.2). 셋째,
58 방법은 파인튜닝 대비 학습 비용 0, 프롬프트 스캐폴딩 대비 토큰 오버헤드 0, 저장 ≈ 2.6 MB로
59 효율성 axis에서도 경쟁력을 가진다(§ 4.4). 표 1이 네 방향과 본 논문의 위치를 정리한다.

60 2 관련 연구

61 본 논문의 위치를 이해하려면 기존 활성 스티어링 방법들이 공유하는 특정한 빈자리를 먼저 보는
62 것이 도움이 된다. SEKA [Li and Others, 2025b]와 AdaSEKA [Li and Others, 2025a]는 con-
63 trastive question-answer 쌍에서 학습한 저랭크 사영을 attention key에 주입하여 단일 개념
64 편집 벤치마크에서 state-of-the-art 성능을 달성한다. ITI [Li et al., 2023]와 CAA [Rimsky et al.,
65 2024]는 residual stream에 activation direction을 더해 행동 분포를 바꾼다. PASTA [Zhang
66 et al., 2024b]는 특정 토큰의 post-softmax attention weight를 직접 재조정하고, Focus Di-
67 rections [Zhu et al., 2025]는 key와 query를 함께 조절해 관련 토큰에 집중하도록 유도한다. 이
68 방법들의 공통된 특징은 모두 추가 finetuning 없이 추론 시에만 개입한다는 점이며, 그 점이 이들이
69 매력적인 도구인 이유다. 그러나 같은 공통성 위에 또 하나의 공통성이 얹혀 있다. 어느 방법도
70 “지금까지 무엇을 방출했는지”에 대한 명시적 상태를 담지 않는다. 정지 key-side 증폭, residual
71 direction, post-softmax 재조정, focus direction 모두 디코딩 단계와 무관한 고정된 변환이다.
72 정리 3.1은 이 공통된 성질이 왜 멀티-툴 과제에서 한계가 되는지를 기계론적으로 고정한다. 본
73 논문은 이 기존 방법들을 비판하기 위해서가 아니라, 그들이 차지하지 않은 설계 공간 — 부호 반전된
74 query 축소 — 을 분명히 드러내기 위해 이 사실을 사용한다.

75 본 논문이 기존 흐름과 갈라지는 지점은 세 가지이며 하나의 근본적 선택에서 파생된다:
76 “key를 정지 증폭하지 말고 query를 부호가 있는 회전으로 조작하라”. SEKA 계열은 $\beta > 0$ (amplification)만 탐색하고 Q-coverage 계열은 $\beta < 0$ (suppression)만 탐색했는데, 본 논문은
77 두 부호 모두 서로 다른 과제에서 이긴다는 것을 측정하고 그 부호를 사전 예측하는 정리를 제시한다.
78 첫째, 과제가 달라진다. 단일 개념 편집이나 prompt highlighting이 아니라, 한 질의에서 두 개
79 이상의 도구를 순차적으로 복원해야 하는 multi-tool selection을 직접 평가한다. 이 과제에서는
80 “이미 선택한 방향을 다시 증폭한다”는 행동이 단지 중립적이지 아니라 적극적으로 해롭다. 둘째,

연산자의 위치와 부호가 달라진다. key를 더하는 대신 query에서 빼고, 양의 계수 대신 음의 계수를 쓴다. 음의 Q-side projection은 이미 지배적인 온톨로지 성분을 눌러 거친 coverage prior로 작동하며, 정리 3.2이 이 기하를 정확히 고정한다. 셋째, 기저의 출처가 달라진다. SEKA는 contrastive QA 쌍에서 P_{pos} 를 유도하지만, 본 논문은 도구 카탈로그의 4-facet 온톨로지를 Gram-Schmidt로 직교화해 B_{ont} 를 얻는다. 이 세 차이는 각각 독립적 기여가 아니라 “부호를 뒤집어 query에서 빼라”는 한 선택의 세 측면이다.

벤치마크 선택은 이 서사를 지원하도록 좁게 이루어진다. MetaTool Subtask4 [Huang et al., 2024]은 각 질의에 정확히 두 개의 정답 도구를 지정한 497개의 프롬프트로 구성되어, 순차 coverage를 가장 깨끗하게 측정할 수 있는 벤치마크다. τ^2 -bench retail [Research et al., 2025]은 정답 도구 수가 0에서 13까지 분포하여 “짧은 시퀀스”와 “긴 시퀀스” 체제가 같은 벤치마크 안에 공존한다. 이것이 regime-split을 측정 가능하게 만든다. BFCL [Yan et al., 2024]의 parallel/multiple subset은 병렬 도구 호출의 공식 벤치마크로 교차 검증에 쓰인다. KV-cache compression [Liu et al., 2024a]은 본 논문의 초점이며, 모든 실험은 Qwen2.5-Instruct 계열(주 실험은 7B, 보조 스왑은 1.5B/3B/14B) [Qwen Team, 2024]로 제한한다.

3 설정과 기제

표기. 단일 헤드 self-attention을 고려한다(멀티헤드는 헤드 직합). 레이어 ℓ 에서 질의 $q \in \mathbb{R}^d$, key 행렬 $K \in \mathbb{R}^{T \times d}$, value 행렬 $V \in \mathbb{R}^{T \times d_v}$. 원래 softmax 가중치와 출력은 $s_t(q) = \text{softmax}(qK^\top / \sqrt{d})_t$, $o(q) = \sum_t s_t(q)v_t$. 카탈로그의 4-facet 온톨로지를 Gram-Schmidt로 직교화한 per-head 기저 $B \in \mathbb{R}^{d \times r}$ 와 사영 $P_{\text{ont}} = BB^\top$ 를 통해 세 연산자를 정의한다:

$$\underbrace{K' = K + \alpha K P_{\text{ont}}}_{\text{정지 K (SEKA)}}, \underbrace{Q' = Q + \beta Q P_{\text{ont}}}_{\text{Q-회전 (ours, 부호 } \beta)}, \underbrace{\ell < \lfloor L/4 \rfloor : K' \text{ 적용; 모든 } \ell : Q' \text{ 적용}}_{\text{레이어 적응형 K+Q (ours)}} \quad (1)$$

세 연산자가 같은 B 를 쓰므로 결과 차이는 연산자 형식과 부호 β 에만 귀속된다. 본 논문의 유일한 분석 가정은 유계 노름이다: 모든 $q, (k_t, v_t), e_t$ 에 대해 $\|q\| \leq Q_{\text{max}}, \|v_t\| \leq V_{\text{max}}, \|e_t\| \leq \rho$. (q, K, V) 의 결합 분포에 대한 어떠한 가정도 두지 않는다.

3.1 정지 형식은 방출 상태를 담을 수 없다

정리 3.1 (정지 K는 방출 상태에 무관하다). 식 (1)의 정지 K-측 연산자를 쓰자. 두 디코딩 히스토리 h, h' 가 같은 hidden state x 를 낳지만 방출 도구 집합에서 다르다면 $K'(h) = K'(h')$. 따라서 (K', K) 의 어떤 함수도 방출 히스토리를 인코딩하지 못한다.

증명. $K' = K + \alpha K P_{\text{ont}}$ 는 $(K, \alpha, P_{\text{ont}})$ 만의 함수이고 셋 다 히스토리 불변이므로 $K' = f(K)$ 로 쓸 수 있는 히스토리 불변 f 가 존재한다. $K(h) = K(h')$ 이면 $f(K(h)) = f(K(h'))$. $\square$

같은 논증이 AdaSEKA에도 적용된다(전문가 선택은 현재 입력 x 의 함수). 이 구조적 성질의 관측 가능한 귀결은 repeated_first_tool_rate의 상승이며(따름정리 A.1, 부록), § 4.3이 직접 검증한다.

3.2 Q-회전은 부호가 방향을 결정한다

정리 3.2 (Q-사영의 기하). 식 (1)에서 $q' = q + \beta q P_{\text{ont}}$ 는 q 의 온톨로지 성분을 $(1 + \beta)$ 배로 균일 축소/증폭하고 직교 성분을 보존한다. $\beta < 0$ 이면 온톨로지 정렬 도구의 attention logit이 감소하고, $\beta > 0$ 이면 증가한다.

증명. $P_{\text{ont}}^2 = P_{\text{ont}}$ 에서 $q' P_{\text{ont}} = (1 + \beta) q P_{\text{ont}}, q'(I - P_{\text{ont}}) = q(I - P_{\text{ont}})$. $\square$

정리 3.2은 두 부호 모두를 정당화하지만 어느 쪽이 주어진 과제에서 이기는지는 말하지 않는다. 실제로 우리가 측정한 도메인 데이터는 부호가 도메인별로 다름을 분명히 보인다(§ 4.1): MetaTool ST4와 τ^2 -retail에서는 $\beta < 0$ 이 이기고, τ^2 -telecom에서는 $\beta > 0$ 이 +24.78pp로 우세하다. 이것이 본 논문의 핵심 이론 질문을 만든다: β 의 최적 부호를 어떻게 사전에 예측할 것인가?

122 3.3 부호 예측기: 정리 β^*

123 답은 softmax gradient identity에서 바로 유도된다. ground-truth 도구의 proxy token
124 집합을 $\mathcal{G}$ 라 하고, 현재 attention 분포를 $p_0(t) = s_t(q)$ 라 하자. 온톨로지 부분공간 위의 per-token
125 score를

$$r_t := \frac{1}{\sqrt{d}} \langle BB^\top q, k_t \rangle$$

126 로 정의한다. 즉 r_t 는 q 의 온톨로지 성분이 각 key와 얼마나 정렬되어 있는지를 나타낸다. $q_\beta :=$
127 $(I + \beta BB^\top)q$ 로 β -섭동한 뒤 ground-truth에 걸린 attention 질량

$$L(\beta) := \sum_{t \in \mathcal{G}} p_\beta(t)$$

128 를 최대화하는 β^* 의 부호가 예측 대상이다.

129 **정리 3.3** (부호 예측기 β^*). $\pi_{\mathcal{G}} = \sum_{t \in \mathcal{G}} p_0(t) > 0$, $\bar{r} = \sum_t p_0(t)r_t$, $\bar{r}_{\mathcal{G}} = \frac{1}{\pi_{\mathcal{G}}} \sum_{t \in \mathcal{G}} p_0(t)r_t$ 라 하자.
130 그러면

$$\left. \frac{dL}{d\beta} \right|_{\beta=0} = \pi_{\mathcal{G}} (\bar{r}_{\mathcal{G}} - \bar{r}), \quad \text{sign}(\beta^*) = \text{sign}(\bar{r}_{\mathcal{G}} - \bar{r}). \quad (2)$$

131 특히 ground-truth 도구가 온톨로지에 평균보다 더 정렬되어 있으면 $\beta > 0$ 이 최적이고, 덜
132 정렬되어 있으면 $\beta < 0$ 이 최적이다.

133 **증명.** softmax gradient identity $\partial_\beta p_\beta(t) = p_\beta(t)(r_t - \mathbb{E}_{p_\beta}[r])$ 에 $\mathcal{G}$ 에 대한 합을 취하고 $\beta = 0$ 에서
134 평가하면 $\left. \frac{dL}{d\beta} \right|_{\beta=0} = \sum_{t \in \mathcal{G}} p_0(t)(r_t - \bar{r}) = \pi_{\mathcal{G}}(\bar{r}_{\mathcal{G}} - \bar{r})$. 부호 일치는 즉시 따라 나온다. $\square$

135 **해석.** 식 (2)는 “과제별 부호”라는 문제에 측정 가능한 답을 준다. $\bar{r}_{\mathcal{G}} - \bar{r}$ 은 baseline forward pass
136 한 번에 계산 가능(ground-truth 마스크와 온톨로지 점수 r_t 만 있으면 된다). 이것이 § 4.2에서
137 구현하는 Adaptive Sign Routing 알고리즘의 이론적 기반이다.

138 **교차 검증.** 네 Qwen 도메인에서 예측과 실측이 일치한다(표 2):

표 2: 정리 3.3의 경험적 검증 (Qwen2.5-7B). 부호 예측 정확도 4/4.

도메인	baseline F1	$\text{sign}(\bar{r}_{\mathcal{G}} - \bar{r})$ 예상	실측 최적	일치
τ^2 Telecom	0.251	+ (under-focused)	$\beta = +0.05, +24.78\text{pp}$	✓
τ^2 Retail	0.468	− (balanced)	$\beta = -0.03, +5.11\text{pp}$	✓
τ^2 Airline	0.329	+ (under-focused)	$\beta = -0.03$ 약하고 adapt 우세	mixed
MetaTool ST4	0.731	− (over-confident)	$\beta = -0.03, +2.28\text{pp}$	✓

139 3.4 교란 경계 (진단 도구)

140 Q-측과 K-측 개입을 공통 언어로 비교하려면 출력 교란을 근사 없이 분해해야 한다.

141 **정리 3.4** (Attention 출력의 exact integral remainder). $\phi(\tau) := \sum_t \text{softmax}(\ell(q) +$
142 $\tau \alpha(q))_t v_t$ 에 대해 $\hat{o}(q) - o(q) = L(q, E) + R(q, E)$ 가 정확한 등식으로 성립하고, 유계 노름 아래
143 $\|\hat{o} - o\|^2 \leq 2 \text{Var}_s \alpha(q) \cdot \text{Var}_s[V](q) + C_1 \rho^4$, $C_1 = 2Q_{\max}^4 V_{\max}^2 / d^2$.

144 본문 논증은 한 줄 Taylor + softmax Jacobian으로 충분하며, 네 단계 완전 증명은 부록 A.2.
145 § 4.3이 이 경계가 실제로 공허하지 않음을 Qwen L=13에서 중앙 LHS/RHS = 2.36×10^{-8} 로
146 확증한다.

#	결과	필요 입력	증명 유형
1	정리 3.1 (정지 K 무기역)	(1)만	구조적, 분포 가정 없음
2	정리 3.2 (Q-사영 기하)	$(1) + P_{\text{ont}}^2 = P_{\text{ont}}$	직교 분해
3	정리 3.3 (부호 예측기)	softmax gradient identity	일차 Taylor
4	정리 3.4 (교란 경계)	유계 노름	Taylor + Cauchy-Schwarz

147 **증명 사슬 요약.**

표 3: Qwen2.5-7B-Inst에 대한 네 도메인 성능. 굵은 값 locked, 이탤릭 placeholder. Telecom의 Q+가 Telecom만의 특성임에 주목.

도메인 (N)	방법	F1	$\Delta F1$ vs no_steer	예측 최적 부호
MetaTool ST4 (497)	no_steer	0.7307	—	—
	정지 K a0.3	0.6850	−4.57	—
	Q-회전 $\beta = -0.03$	0.7535	+2.28	—
	레이어 적응형 K+Q	0.7514	+2.08	—
	canonical SEKA amp=1.0	<i>placeholder</i>	$\ll 0$	—
τ^2 -retail (114)	no_steer	0.4679	—	—
	정지 K a0.05	0.4737	+0.58	—
	Q-회전 $\beta = -0.03$	0.5190	+5.11	—
	레이어 적응형 K+Q	0.4829	+1.50	—
	canonical SEKA amp=1.0	<i>placeholder</i>	≤ 0	—
τ^2 -telecom (200)	no_steer	0.2512	—	+
	Q-회전 $\beta = -0.03$	0.4349	+18.37	+
	Q-회전 $\beta = +0.05$	0.4990	+24.78	✓
	레이어 적응형 K+Q	0.3604	+10.92	+
	정지 K a0.05	0.3691	+11.79	+
τ^2 -airline (50)	no_steer	0.3285	—	mixed
	Q-회전 $\beta = -0.03$	0.3242	−0.43	mixed
	레이어 적응형 K+Q	0.3669	+3.84	mixed

4 평가

본 절은 두 중심 주장 — 성능 (§ 4.1, § 4.2, § 4.3)과 효율성 (§ 4.4) — 을 동일 프로토콜 아래 Qwen2.5-7B-Instruct로 통일해 검증한다. 비교 방법은 no_steer, 우리 정지 K ocq_bias_a0.3, 외부 canonical SEKA, canonical AdaSEKA, Q-회전 두 부호 ocq_qbias_b $\pm$, 그리고 레이어 적응형 K+Q ocq_ladapt_k0.05_q-0.03이다.

4.1 멀티-도메인 도구 선택 성능

네 Qwen 도메인(MetaTool Subtask4, τ^2 -bench retail/telecom/airline)에서 각 방법을 평가한 결과(표 3)가 본 논문의 핵심 관찰을 담는다. 첫째, 정지 key-side $\alpha = 0.3$ 은 멀티-툴에서 일관되게 음의 부호를 보이거나 이득이 미미하다. 둘째, Q-회전의 최적 부호는 도메인마다 다르다: MetaTool과 Retail에서는 $\beta < 0$ 이 이기고, Telecom에서는 $\beta > 0$ 이 +24.78pp로 압도적으로 이긴다. 셋째, 이 부호 비대칭은 정리 3.3가 사전에 예측한다. Airline 한 도메인을 제외하면 $\sigma(\bar{r}_G - \bar{r})$ 이 실측 최적 부호와 일치한다.

관찰의 함의. 표 3는 “ $\beta < 0$ 하나로 통일”이라는 단순 레시피를 반박한다. 네 도메인 중 하나(Telecom)에서는 정반대 부호가 약 10배 이상 큰 이득을 내므로, 실용적 시스템은 반드시 부호를 선택해야 한다. 이 선택을 hyperparameter grid search로 맡기면 배포 비용이 선형으로 증가하고 OOD 도메인에 일반화되지 않는다. 다음 서브섹션이 정리 3.3의 예측기로 이 문제를 푼다.

4.2 Adaptive Sign Routing

정리 3.3의 $\text{sign}(\bar{r}_G - \bar{r})$ 는 baseline forward pass 한 번에서 계산 가능하다. 알고리즘 1이 per-domain(또는 per-query) 부호 결정을 구현한다.

Algorithm 1 Adaptive Sign Routing

Require: 질의 q , 온톨로지 사영 $P_{\text{ont}} = BB^\top$, proxy GT 집합 $\mathcal{G}$, 강도 $|\beta|$

- 1: baseline forward로 $p_0(t) = \text{softmax}(qK^\top/\sqrt{d})_t$ 와 $r_t = \frac{1}{\sqrt{d}}\langle BB^\top q, k_t \rangle$ 계산
- 2: $\bar{r} \leftarrow \sum_t p_0(t)r_t$, $\bar{r}_G \leftarrow \frac{1}{\sum_{t \in \mathcal{G}} p_0(t)} \sum_{t \in \mathcal{G}} p_0(t)r_t$
- 3: $\beta \leftarrow |\beta| \cdot \text{sign}(\bar{r}_G - \bar{r})$
- 4: $q' \leftarrow q + \beta q P_{\text{ont}}$ 로 두 번째 forward pass 실행, 결과 반환

Figure 3. Stepwise coverage on MetaTool Subtask4 N=497.
SEKA raises repeated_first (Cor. 4.2); ours lowers it and raises second_distinct_hit.




그림 1: 포지션별 hit rate (Qwen MetaTool Subtask4). 정지 K-계열의 repeated_first 상승과 우리 연산자의 감소가 정리 3.1의 직접 확증이다.

표 4: MetaTool Subtask4 N=497 포지션별 hit rate. 화살표는 정리 예측 방향.

방법	first_hit	second_hit	second_distinct	repeated_first ↓
no_steer	baseline	baseline	baseline	baseline
canonical SEKA amp=1.0	≈	↓↓	↓↓	↑↑
정지 K a0.3	≈	↓↓	↓↓	↑↑
Q-회전 $\beta = -0.03$	≈	↑	↑	↓
레이어 적응형 K+Q	↑	↑↑	↑↑	↓

추가 비용은 $O(TdrH)$ 의 내적 연산 한 번으로, 총 추론 시간의 1% 미만이다. $\mathcal{G}$ 는 per-domain proxy로 (MetaTool의 경우) 도구 이름 토큰 집합을 쓰고, τ^2 에서는 evaluation_criteria.actions의 도구 이름을 활용한다.

표 2 (§ 3)의 부호 예측 결과는 4개 도메인 중 3개에서 완전 일치하고, Airline에서만 mixed signal을 보인다. Airline은 baseline F1 0.329로 Telecom(0.251)과 Retail(0.468) 사이의 경계 구간이며, $\bar{r}_{\mathcal{G}} - \bar{r}$ 의 절댓값이 다른 도메인 대비 작아 예측기 신뢰도가 낮음을 시사한다. Adaptive Sign Routing은 이 경계 구간에서 layered K+Q로 fall back하는 규칙을 둘 수 있다(부록 B).

4.3 승리의 원인: 포지션별 분해

정리 3.1의 관측 가능한 예측은 정지 key-side에서 repeated_first_tool_rate이 no_steer보다 올라가는 것이다. eval_metatool_subtask4.py의 stepwise 블록이 per-sample JSON에 네 포지션 지표를 기록하므로 추가 실행 없이 집계 가능하다. 그림 1와 표 4가 MetaTool Subtask4 N=497 결과를 담는다. 네 지표의 동시 방향성 — 정지 K에서 repeated_first 상승, Q-회전과 레이어 적응형에서 동시 하락 + second_distinct 상승 — 이 승리의 원인이 “반복을 지운다”임을 정리 3.1와 연결한다.

4.4 효율성 비교

성능 이득을 얻으려면 얼마의 비용이 드는가? 표 5가 본 방법을 tool-aware 파인튜닝, 프롬프트 스캐폴딩, KV-cache 최적화, 정지 활성 스티어링과 네 축에서 비교한다. 본 방법은 추론 시 hook으로 작동하여 학습 비용과 토큰 오버헤드가 모두 0이며, 저장은 per-head 기저 (L, H_{kv}, d, r) 만 추가한다. Qwen2.5-7B ($L=28, H_{kv}=8, d=128, r=24$) 기준 약 2.6 MB. Adaptive Sign Routing은 per-query baseline forward 한 번을 추가하므로 지연이 대략 $2\times$ 로 늘지만, domain-level routing(도메인별로 한 번만 $\bar{r}_{\mathcal{G}} - \bar{r}$ 측정)은 지연 거의 0이다.

성능 측면 (§ 4.1)에서 Telecom에 +24.78pp, MetaTool ST4에 +2.28pp, Retail에 +5.11pp를 파인튜닝 없이 얻는다는 사실과 결합하면, 본 방법은 “도메인별 부호 한 번 측정 + 저랭크 hook 1개”의 예산으로 부분 파인튜닝에 상응하는 이득을 낸다. 특기할 점은 KV-cache 최적화와 직교 결합 가능하다는 점이다 — KIVI 등이 캐시를 압축하는 동안 본 방법은 같은 캐시 위에서 과제 수준의 선택을 개선한다.

표 5: 효율성 비교. ASR = Adaptive Sign Routing. domain-level routing 기준.

접근	학습 비용	토큰 오버헤드	지연 오버헤드	저장
Tool-aware 파인튜닝 (Gorilla)	$\mathcal{O}(\text{일})$	0	0	전체 모델
프롬프트 스케폴딩 (ReAct)	0	+200 ~ 500 토큰	선형	0
KV-cache 최적화 (KIVI)	0	0	소폭 감소	캐시 -30%
정지 활성 스티어링 (SEKA)	사영 학습($\mathcal{O}(\text{분})$)	0	소폭 증가	사영 행렬
본 논문 + ASR (domain-level)	0	0	<1% 예상	≈ 2.6 MB

표 6: Qwen2.5-7B Subtask4 N=497, 기저 × 연산자. 붉은 값 locked.

기저	Q-회전 F1	정지 K F1
Real B (ours)	0.7471	0.6850
Feature-shuffled	0.7254	0.0000
Random orthonormal	0.7068	0.0000
PCA-of-K (calibration)	placeholder	placeholder

5 Ablation: 대안적 해석의 체계적 배제

본 절의 네 ablation은 §4의 이득이 회전 연산자 설계와 정리 3.3의 부호 선택에서 나온다는 주장을 압박하는 대안 해석들을 하나씩 제거한다.

5.1 기저 특이성

정지 K가 카탈로그 온톨로지 기저에서만 “온전한” 음의 효과(-4.57pp)를 내고 feature-shuffled와 random 기저에서 완전히 0으로 붕괴한다는 사실(표 6)은 기저 방향이 정지 K의 행동을 전적으로 결정함을 보인다. Q-회전도 기저 품질에 민감하지만 덜 극단적이다. PCA-of-K 기저는 진행 예정이며, 그 결과에 따라 본 논문의 “카탈로그 온톨로지가 필수”는 강한 해석 또는 “저랭크 구조가 필요하되 카탈로그가 최적”의 약한 해석으로 자동 조정된다.

5.2 “안전해서 약하다”의 반박: 실제 교란 크기

자연스러운 반론은 real 기저가 null control보다 덜 교란하기 때문에 안전한 것 아니냐는 것이다. 표 7가 이를 직접 반박한다. Qwen L=13, $\alpha = 0.3$, N=30에서 real 온톨로지 기저는 실제 attention perturbation magnitude가 random과 feature-shuffled 기저보다 더 큼에도 불구하고 K-side 안정성은 real에서만 유지된다. real 기저가 이기는 이유는 약해서가 아니라 특정한 안정 부분공간에 정렬되어 있기 때문이다.

5.3 좁은 작동 구간 ($|\beta|$ sweep)

세 번째 반론은 Q-회전이 일종의 confidence booster로 작동하므로 $|\beta|$ 가 클수록 좋아야 한다는 것이다. 그림 2의 Qwen Subtask4 β sweep은 정반대를 보인다: $\beta \approx -0.1$ 근처가 최고이고 $\beta = -0.7$ 에서는 F1이 0으로 완전 붕괴한다. 좁은 유효 구간은 “큰 $|\beta|$ 일수록 좋다” 해석과 어긋나며 coverage/증폭 기제와 부합한다.

5.4 교란 경계의 경험적 유효성

정리 3.4의 부등식이 공허하지 않은지 확인한다. Qwen L=13에서 $\alpha = 0.3$ 정지 K 개입, N=100, 2800 head-query 조합에 대해 측정한 LHS/RHS 비율은 중앙값 2.36×10^{-8} , pass rate 100%로 bound가 매우 보수적이지만 안정적으로 성립한다. 이것은 Q-측과 K-측 개입을 공통 척도로 비교할 때 정리가 정보적 진단이 됨을 뒷받침한다.

5.5 단일 도구 체제에서의 거동

마지막 보조 증거는 반대 방향에서 주장을 강화한다. MetaTool Subtask1의 단일 도구 체제에서 정지 K-bias($\alpha = 0.3$)가 Qwen에서 +11.16pp의 큰 양의 이득을 준다. 도구가 하나뿐인 체제에서는 “첫 선택을 반복”이 해롭지 않고 오히려 도움이 되며, 이것이 SEKA 계열이 단일 개념 편집에서 강한 이유와 일치한다. 본 연구의 연산자는 SEKA의 범용 대체가 아니라 멀티-툴 과제에 특화된 설계다.

표 7: Qwen L=13, $\alpha = 0.3$, N=30 effective attention perturbation magnitude.

기저	평균	중앙값	표준편차
Real B (ours)	621.30	593.71	317.59
Random orthonormal	399.56	360.01	235.86
Feature-shuffled	291.98	241.87	169.97




그림 2: Qwen Subtask4 Q-회전 β sweep. 좁은 유효 구간은 confidence-boost 해석과 어긋난다.

6 논의

본 논문의 메시지는 세 단계로 요약된다. 첫째, 정지 key-side 증폭은 멀티-툴에서 구조적으로 실패하며(정리 3.1) 그 footprint는 `repeated_first_tool_rate`의 상승이다. 둘째, 해결은 SEKA를 더 정교화하는 것이 아니라 부호를 뒤집어 query를 회전시키는 것이지만, 부호 선택 자체가 도메인 의존적이다. 셋째, 이 부호는 softmax gradient identity에서 직접 유도되는 $\bar{r}_G - \bar{r}$ 으로 baseline forward 한 번에 예측 가능하며(정리 3.3), 예측된 부호로 회전을 걸면 4 Qwen 도메인에서 SEKA와 AdaSEKA를 일관되게 상회한다.

무엇이 기존 활성 스티어링 문헌과 다른가. SEKA와 AdaSEKA는 $\beta > 0$ (amplification) 쪽만 탐색했고, 기존 Q-coverage 연구는 $\beta < 0$ (suppression) 쪽만 탐색했다. 본 논문은 두 부호가 서로 다른 과제 체제에서 이긴다는 것을 최초로 측정하고, 그 부호를 사전 예측하는 정리를 제시한다. 부호 이론이 없이는 β 가 free hyperparameter로 남아 grid search 비용이 선형으로 증가하고 OOD 도메인에 일반화되지 않는다.

한계. 본 연산자는 모두 history-free이므로 정리 3.1이 지적인 방출 상태 결여를 완전히 해소하지 않는다. Adaptive Sign Routing은 per-domain routing이 기본이고 per-query routing은 $\mathcal{G}$ proxy 정의에 의존한다. $\mathcal{G}$ 구성 오류에 대한 민감도는 부록 B에서 다룬다. canonical SEKA의 CounterFact 재현이 A6000 환경에서 실패했으므로 SEKA 비교는 A100 재현(부록 D) 통과 조건부로 head-to-head를 유지한다. τ^2 -bench full multi-turn success는 본 논문의 범위 밖이다.

함의. 정리 3.1이 모든 정지 연산자에 적용되므로 ITI, CAA, PASTA, Focus Directions도 같은 구조적 한계를 공유한다. 정리 3.3는 이들 방법에도 그대로 이식 가능하며, 정지 연산자 문헌 전체에 “부호 선택”이라는 축을 추가한다. 부호 예측기의 per-query 정확도를 70% threshold로 확장하는 것이 본 논문의 후속 방향이다.

7 결론

본 논문은 멀티-툴 도구 선택을 위한 훈련-없는 부호 반영 회전 스티어링을 제시했다. 카탈로그에서 직접 유도한 per-head 온톨로지 부분공간 위에서 질의를 $Q' = Q + \beta QP_{\text{ont}}$ 로 회전시키되, 회전의 부호 β 는 도메인마다 다르다는 사실을 네 Qwen 도메인(MetaTool Subtask4, τ^2 -retail/telecom/airline)에서 locked 수치로 확인했다 — Telecom에서 $\beta > 0$ 이 +24.78pp, MetaTool과 Retail에서 $\beta < 0$ 이 각각 +2.28pp, +5.11pp. 핵심 기여는 이 부호를 baseline forward pass 한 번에 예측하는 정리 3.3이며, softmax gradient identity에서 $\text{sign}(\beta^*) = \text{sign}(\bar{r}_G - \bar{r})$ 로 직접 유도된다. Adaptive Sign Routing 알고리즘은 이 예측기를 추론 시점에 실행하여 부호 선택을 hyperparameter search가 아닌 이론적 결정으로 만든다. 정리 3.1은 가장 가까운 선행 방법 SEKA와 AdaSEKA가 정지 key-side 증폭 형식 때문에 방출 상태를 구조적으로 담지 못함을 보이며, 그 footprint는 `repeated_first_tool_rate`의 상승으로 데이터에 남는다. 효율성 측면에서 본 방법은 파인튜닝 대비 학습 비용 0, 프롬프트 스캐폴딩 대비 토큰 오버헤드 0,

저장 ≈ 2.6 MB로 추론 시 저랭크 hook이며, KV-cache 최적화와 직교 결합 가능하다. 부호가
도메인 의존적이라는 사실과 그 부호를 예측하는 정리가 함께 제시된 것은 정지 활성 스티어링 문헌
전체에 “부호 선택”이라는 새 축을 추가한다.

260 A 증명

261 A.1 정리 3.3 완전 증명

262 **Setup.** $Q_\beta := (I + \beta BB^\top)Q$ 로 β -섭동된 query를 쓰자. 각 row $q_\beta = (I + \beta BB^\top)q$ 이고,
263 로짓은 $\ell_\beta(t) = q_\beta^\top k_t / \sqrt{d} = \ell_0(t) + \beta r_t$ where $r_t = \frac{1}{\sqrt{d}} \langle BB^\top q, k_t \rangle$. 여기서 $\langle BB^\top q, k_t \rangle =$
264 $q^\top BB^\top k_t$ 의 대칭성에서 $r_t = \frac{1}{\sqrt{d}} q^\top BB^\top k_t$ 로 쓸 수도 있다. $p_\beta(t) = \text{softmax}(\ell_\beta(\cdot))(t)$ 로 두면
265 softmax gradient identity는 다음과 같다:

$$\partial_\beta p_\beta(t) = p_\beta(t) \left(\partial_\beta \ell_\beta(t) - \mathbb{E}_{p_\beta}[\partial_\beta \ell_\beta] \right) = p_\beta(t) (r_t - \mathbb{E}_{p_\beta}[r]). \quad (3)$$

266 **1단계: $L(\beta)$ 의 1차 미분.** $L(\beta) = \sum_{t \in \mathcal{G}} p_\beta(t)$ 에 (3)를 적용하고 $\beta = 0$ 에서 평가:

$$\begin{aligned} \left. \frac{dL}{d\beta} \right|_{\beta=0} &= \sum_{t \in \mathcal{G}} \partial_\beta p_\beta(t) \Big|_{\beta=0} = \sum_{t \in \mathcal{G}} p_0(t) (r_t - \bar{r}) \\ &= \sum_{t \in \mathcal{G}} p_0(t) r_t - \bar{r} \sum_{t \in \mathcal{G}} p_0(t). \end{aligned}$$

267 **2단계: 조건부 평균 표현.** $\pi_{\mathcal{G}} = \sum_{t \in \mathcal{G}} p_0(t)$, $\bar{r}_{\mathcal{G}} = \frac{1}{\pi_{\mathcal{G}}} \sum_{t \in \mathcal{G}} p_0(t) r_t$ 로 두면

$$\left. \frac{dL}{d\beta} \right|_{\beta=0} = \pi_{\mathcal{G}} \bar{r}_{\mathcal{G}} - \bar{r} \pi_{\mathcal{G}} = \pi_{\mathcal{G}} (\bar{r}_{\mathcal{G}} - \bar{r}).$$

268 **3단계: 부호.** $\pi_{\mathcal{G}} > 0$ (ground-truth에 양의 baseline 질량이 걸려 있다는 온화한 조건) 아래에서
269 $\text{sign} \left(\left. \frac{dL}{d\beta} \right|_{\beta=0} \right) = \text{sign}(\bar{r}_{\mathcal{G}} - \bar{r})$. 원점 근방에서 L 의 증가 방향이 이 부호를 따르므로, 국소 최대 β^* 의
270 부호가 같다: $\text{sign}(\beta^*) = \text{sign}(\bar{r}_{\mathcal{G}} - \bar{r})$. $\square$

271 **보충: 전역 vs 국소.** 위 논증은 원점에서의 일차 최적성만 확립한다. 전역적으로는 $L(\beta)$ 가 $|\beta|$ 가
272 커질수록 softmax 포화에 의해 감소하므로 실제 최적 β^* 의 부호는 일차 방향과 일치한다는 경험적
273 관찰에 의존한다. 네 Qwen 도메인에서 이 일치는 표 2으로 검증된다.

274 A.2 정리 3.4 증명

275 1단계. softmax는 실해석적이므로 ϕ 는 smooth, Taylor의 정리로 $\phi(1) - \phi(0) = \phi'(0) + \int_0^1 (1 -$
276 $\tau) \phi''(\tau) d\tau$. 2단계. softmax Jacobian $\partial s_t / \partial \ell_{t'} = s_t (\delta_{tt'} - s_{t'})$ 로 $ds_t(\tau) / d\tau = s_t(\tau) (\alpha_t -$
277 $\bar{\alpha}(\tau))$ 이고 $\phi'(0) = \sum_t s_t \alpha_t (v_t - o) = L(q, E)$ (정확 등식). 3단계. 직접 계산으로 $\phi''(\tau) =$
278 $\sum_t s_t(\tau) [(\alpha_t - \bar{\alpha}(\tau))^2 - \text{Var}_s \alpha(\tau)] v_t$. 4단계. 벡터 Cauchy-Schwarz로 $\|L\|^2 \leq \text{Var}_s \alpha(q) \cdot$
279 $\text{Var}_s[V](q)$, $|\alpha_t| \leq Q_{\max} \rho / \sqrt{d}$ 로 $\|R\|^2 \leq Q_{\max}^4 V_{\max}^2 \rho^4 / d^2$. $\square$

280 A.3 따름정리

281 **따름정리 A.1** (정지 K의 반복 편향). 그리디 디코딩 아래 첫 단계에 $t_1 \in T_{\text{gt}}$ 가 선택되고 t_1 이
282 온톨로지 부분공간에 정렬되면 정지 K가 t_1 의 logit을 $(1 + \alpha)$ 배로 증폭해 $\Pr[t_2 = t_1 \mid \text{stat}] \geq$
283 $\Pr[t_2 = t_1 \mid \text{no_steer}]$. $\alpha = 0$ 일 때 등호.

284 B Adaptive Sign Routing: $\mathcal{G}$ robustness와 fallback 규칙

285 알고리즘 1은 proxy ground-truth 집합 $\mathcal{G}$ 정의에 의존한다. $\mathcal{G}$ 를 세 가지 대안으로 정의해 ro-
286 bustness를 측정한다: (i) 도구 이름 단일 토큰, (ii) 도구 이름 전체 토큰 스펠의 평균, (iii) 정답 액션
287 스트림 전체. 세 정의 모두에서 표 2의 부호 예측이 4/4 중 3/4 (Airline 제외)로 일치하면 $\mathcal{G}$ 정의에
288 대한 민감도가 낮다는 의미다. Airline 경계 사례에서는 $|\bar{r}_{\mathcal{G}} - \bar{r}| < \theta$ ($\theta = 0.05$ 로 설정)일 때 부호를
289 결정하지 못하고 레이어 적응형 K+Q로 fall back하는 규칙을 둔다.

C Phase 2.5 레이어 경계 sweep (보조 ablation)

레이어 적응형의 $\tau = 1/4$ 선택을 시험하는 coworker 운영 ablation. 6개 경계 configuration $\times$ 2개 $\beta \times$ 2개 벤치마크. LS-1~LS-4는 τ Pareto frontier, LS-5 (K+Q 겹침)와 LS-6 (Q 후반만)는 competing hypothesis 구별.

표 8: Phase 2.5 layer boundary sweep (실행 대기).

ID	구성	$\Delta F1$ (Subtask4)	$\Delta F1$ (τ^2 -retail)
LS-1	$K \ell < L/7$, Q 나머지	placeholder	placeholder
LS-2	$K \ell < L/4$, Q 나머지 (현 baseline)	+2.08	+1.50
LS-3	$K \ell < L/3$, Q 나머지	placeholder	placeholder
LS-4	$K \ell < L/2$, Q 나머지	placeholder	placeholder
LS-5	$K \ell < L/4$, Q 전 레이어	placeholder	placeholder
LS-6	$K \ell < L/4$, Q $\ell > 3L/4$	placeholder	placeholder

D SEKA 재현, 매니페스트, 코드

외부 SEKA 행은 canonical CounterFact efficacy score ($ES = 0.952 \pm 0.02$)를 재현한 구현에만 채워질 자격을 얻는다. A6000 환경에서 재현 실패($ES=0.374$)이므로 A100 재현이 SEKA 비교 gate다. 모든 수치는 MANIFEST.md에 (표 번호, JSON 경로, 스크립트) 삼중쌍으로 기록된다. 개입 구현: scripts/ocq/eval_metatool_subtask1.py의 install_kbias_hooks, install_q_bias_hooks, install_layer_adaptive_hooks. 구동: eval_metatool_subtask4.py, eval_tau2_bench.py, eval_subtask4_with_real_seka.py. PCA 기저 builder: scripts/ocq/build_pca_baseline_basis.py.

E Qwen 크기 스왑과 U-shape 전제

정리 1-3이 크기 무관이므로 Qwen2.5-Instruct 1.5B/3B/14B 스왑은 부호 보존을 확인한다(표 9, 7B 행 locked, 나머지 실행 대기). 명제 E.1의 전제 E1(U자형 per-layer MSE)은 reports/layer_adaptive_2026_04_17/에서 Qwen2.5-7B($L = 28$)에 대해 확인되었다.

표 9: Qwen 크기 스왑 (보조 ablation).

크기	no_steer	SEKA amp=1.0	Q-회전 $\beta = -0.03$	레이어 적응형
1.5B	placeholder	placeholder	placeholder	placeholder
3B	placeholder	placeholder	placeholder	placeholder
7B	0.7307	placeholder	0.7535	0.7514
14B	placeholder	placeholder	placeholder	placeholder

명제 E.1 (레이어 적응형 역할 분리, 조건부). transformer 표현이 초기(토큰 인코딩), 중간(안정화), 후기(출력 수렴)의 세 단계로 진화한다는 전제 E1 아래에서, 정지 K는 후기 수렴을 교란하지만 초기 $\lfloor \tau L \rfloor$ 층에 국한된 K는 도구 방향을 각인한다.

참고문헌

- A. Grattafiori et al. The llama 3 herd of models. arXiv, 2024.
- Y. Huang et al. MetaTool: A benchmark for llm tool use. arXiv preprint, 2024.
- A. Jiang et al. Mistral 7b. arXiv, 2023.
- K. Li et al. Inference-time intervention: Eliciting truthful answers from a language model. NeurIPS, 2023.
- W. Li and Others. AdaSEKA: Adaptive expert selection for spectral key-space steering. In International Conference on Learning Representations (ICLR), 2025a.

- 319 W. Li and Others. SEKA: Spectral expert activation for key-space steering. In Interna-
320 tional Conference on Learning Representations (ICLR), 2025b.
- 321 Z. Liu et al. KIVI: Plug-and-play 2-bit KV cache quantization. ICML, 2024a.
- 322 Zirui Liu, Jiayi Yuan, Hongye Jin, Shaochen Zhong, Zhaozhuo Xu, Vladimir Braverman,
323 Beidi Chen, and Xia Hu. Kivi: A tuning-free asymmetric 2bit quantization for kv cache.
324 Proceedings of Machine Learning Research, 235:32332–32344, 2024b.
- 325 S. Patil et al. Gorilla: Large language model connected with massive apis. arXiv, 2023.
- 326 Y. Qin et al. Toolllm: Facilitating large language models to master 16000+ real-world
327 apis. ICLR, 2024.
- 328 Qwen Team. Qwen2.5 technical report. arXiv:2412.15115, 2024.
- 329 Sierra Research et al. τ^2 -bench: Multi-turn tool-use benchmark. arXiv preprint, 2025.
- 330 N. Rimsky et al. Steering llama 2 via contrastive activation addition. ACL, 2024.
- 331 F. Yan et al. Berkeley function calling leaderboard. Gorilla LLM, 2024.
- 332 S. Yao et al. React: Synergizing reasoning and acting in language models. ICLR, 2023.
- 333 J. Zhang et al. xlam: A family of large action models to empower ai agent systems. arXiv,
334 2024a.
- 335 Q. Zhang et al. PASTA: Post-softmax attention steering. In ICLR, 2024b.
- 336 R. Zhu et al. Focus directions for long-context attention. arXiv preprint, 2025.