

Layer-Adaptive Ontology Steering: 멀티-툴 도구 선택을 위한 훈련-없는 K+Q 회전과 부호 진단

Anonymous Author(s)

Affiliation

Address

email

초록

본 논문은 멀티-툴 도구 선택을 위한 훈련-없는 온톨로지 스티어링을 제시한다. 핵심 관찰은 기존 SEKA류의 정지 key-side 증폭이 멀티-툴에서 두 이유로 실패한다는 점이다: 이미 방출한 도구 상태를 담지 못하는 구조적 무기역성과, 후반 레이어의 출력 수렴 구간을 교란하는 과도한 K-측 개입이다. 이를 바탕으로 우리는 초기 레이어에는 K-측 증폭으로 도구 방향을 각인하고, 전 레이어에는 Q-측 회전으로 이미 지배적인 facet을 눌러 coverage를 넓히는 layer-adaptive K+Q steering을 제안한다. MetaTool Subtask4에서 정지 K는 -4.57pp 로 붕괴하지만, 동일한 온톨로지 기저 위의 layer-adaptive 연산자는 $+2.08\text{pp}$ 를 회복한다. τ^2 -bench에서는 regime split이 나타난다: retail에서는 음의 Q-회전이 $+5.11\text{pp}$, telecom에서는 양의 Q-회전이 $+24.78\text{pp}$ 로 가장 크고, airline에서는 layer-adaptive가 $+3.84\text{pp}$ 로 최고다. 이 결과는 멀티-툴에서 중요한 것이 “더 강한 K”가 아니라 레이어별 역할 분리를 보인다. 이론적으로 우리는 정지 K가 방출 히스토리를 인코딩할 수 없음을 증명하고, signed Q-회전에 대해서는 softmax gradient identity로부터 $\left. \frac{dL}{d\beta} \right|_{\beta=0} = \pi_G(\bar{r}_G - \bar{r})$ 를 유도해 도메인별 부호 역전을 설명한다. 방법은 학습 비용 0, 토큰 오버헤드 0, 저장 $\approx 2.6\text{ MB}$ 의 저랭크 hook이며, 기저를 feature-shuffled나 random으로 바꾸면 효과가 사라져 이득이 온톨로지 정렬과 연산자 설계에서 온다는 점도 확인한다.

1 서론

LLM 에이전트가 실전에서 유용하려면 한 질의에서 여러 도구를 순차적으로 고를 수 있어야 한다. “뉴스에서 주식 관련 기사를 찾아 요약해 달라”는 요청은 검색 도구와 요약 도구를 연달아 불러야 하며, 같은 기능을 가진 여러 도구가 도메인별로 섞여 있으면 무엇을 먼저 쓰고 무엇을 다음으로 남겨야 하는지를 함께 결정해야 한다. 이 멀티-툴 setting의 핵심은 단일 정답률이 아니라 coverage와 비반복성이며, 서로 다른 목적을 가진 여러 해법 경로가 이 문제를 공격해 왔다.

도구 선택 성능을 강화하는 경로는 네 갈래로 나뉜다. tool-aware finetuning은 도구 호출 예시로 모델 가중치를 직접 조정해 강한 성능을 내지만 카탈로그가 바뀔 때마다 재학습 비용을 치러야 한다. 프롬프트 스캐폴딩은 학습 없이 추론 시 프롬프트로 행동을 유도하지만 프롬프트 길이에 비례해 토큰 비용이 증가한다. KV-cache 최적화는 추론 자원을 줄여 주지만 “무엇을 고를지”라는 과제 수준의 결정에는 개입하지 않는다. 네 번째 갈래인 활성 스티어링은 attention에 저랭크 개입을 주입해 가중치와 프롬프트를 모두 건드리지 않고 행동을 바꾼다. 본 논문은 활성 스티어링에 속하며, 표 1이 네 접근을 학습 비용, 멀티-툴 표적성, 부호 결정 방식의 축에서 비교한다.

활성 스티어링 계열은 훈련 없이 추론 시점에 행동을 조정한다는 장점을 공유하지만, 대부분의 기존 구현은 정지 연산자다. 즉 같은 저랭크 방향을 모든 디코딩 단계에 걸쳐 동일하게 밀어 넣는다. 이 형식은 단일 개념 편집이나 단일 도구 선택처럼 “한 방향을 강화하는” 과제에는 자연스러운 선택이지만, 멀티-툴에는 맞지 않는다. 첫 도구를 이미 방출한 뒤에도 연산자는 방출 사실을 모른 채 같은 방향을 계속 증폭하여 두 번째 단계에서 첫 도구를 다시 고르게 유도한다. 이것이 멀티-툴에서 정지 활성 스티어링이 coverage 대신 반복을 만드는 구조적 이유이며, 본 논문의 첫 이론적 관찰이 이 현상을 형식화한다.

표 1: 멀티-툴 호출 강화의 네 접근과 본 논문의 위치.

접근	대표 방법	학습 free	멀티-툴 표적	부호 결정
Tool-aware finetuning	Gorilla, ToolLlama, xLAM	×	✓	n/a
Prompt scaffolding	ReAct, ToT	✓	프롬프트	n/a
KV-cache 최적화	KIVI, StreamingLLM	✓	×	n/a
정지 활성 스티어링	SEKA, AdaSEKA, ITI, CAA, PASTA	✓	×	고정(보통 +)
본 논문	Layer-adaptive K+Q steering	✓	✓	레이어 스케줄 + 부호 진단

대안을 찾을 때 “K 대신 Q를 돌리자”만으로는 충분하지 않다. Q를 온톨로지 부분공간에서 회전시키는 연산자 $Q' = Q + \beta Q P_{\text{ont}}$ 는 부호에 따라 온톨로지 정렬 방향을 눌러 coverage를 넓히거나 강화해 focus를 좁히는 두 얼굴을 가진다. 어느 부호가 주어진 과제에서 유리한지는 선형적으로 결정되지 않는다. 반대로 K와 Q를 모든 레이어에 걸쳐 동시에 적용하면 후반 레이어의 출력 수렴 과정이 교란되어 성능이 오히려 무너진다. 문제의 본질은 “K냐 Q냐”가 아니라 어느 레이어에서 무엇을 쓰느냐에 있다. 본 논문의 중심 설계인 layer-adaptive K+Q는 초기 레이어에서는 K로 도구 방향을 각인하고, 이후 레이어에서는 Q로 이미 지배적인 facet을 눌러 남은 facet을 보게 한다. develop 브랜치 실험 궤적은 이 설계를 일관되게 지지한다. 정지 K를 모든 레이어에 적용하면 MetaTool Subtask4에서 -4.57pp 로 붕괴하지만, K를 초기 1/4 레이어에만 두면 같은 기저로 $+2.08\text{pp}$ 가 회복된다.

이 layer-adaptive 설계 위에서 signed Q는 task regime에 따라 다른 해석을 받는다. baseline F1이 낮고 온톨로지 정렬이 부족한 domain에서는 양의 β 가 focus를 좁혀 이득을 내고, baseline이 이미 온톨로지에 치우친 domain에서는 음의 β 가 과도 편향을 풀어 coverage를 돌려준다. 어느 쪽이 유리한지는 baseline forward pass 한 번에서 측정 가능한 양 — ground-truth proxy에 걸린 온톨로지 정렬도의 조건부 평균과 전체 평균의 차이 — 의 부호로 설명된다. 본 논문은 이 관계를 일차 수준에서 정리하고, 네 Qwen 도메인에서의 regime 차이를 단일 진단식으로 설명한다.

본 논문의 기여는 네 가지로 요약된다. 첫째, 정지 활성 스티어링이 멀티-툴에서 구조적으로 방출 상태를 담지 못한다는 불가능성 결과를 제시하고, 그 footprint가 포지셔널 hit rate에서 repeated_first_tool_rate 상승으로 관측됨을 확인한다. 둘째, 초기 K와 후반 Q를 분리한 layer-adaptive 스케줄을 도입하여 “K를 어디까지 허용할지”라는 설계 원리를 구현한다. 셋째, signed Q-회전에 대해 softmax gradient identity에서 일차 부호 진단을 유도해 도메인별 부호 역전을 설명한다. 넷째, 방법은 학습 비용 0, 토큰 오버헤드 0, 저장 약 2.6 MB의 저랭크 hook으로 효율성 측면에서도 실용적이며, KV-cache 최적화와도 직교 결합 가능하다.

2 관련 연구

본 논문의 위치는 표 1이 정리한 네 접근 속에서 읽어야 한다. 각 축이 무엇을 공략하는지와 본 논문이 어느 빈자리를 채우는지를 차례로 서술한다.

tool-aware finetuning은 가중치를 직접 업데이트해 도구 사용을 학습한다. Gorilla [Patil et al., 2023]는 대규모 API 호출 데이터로 function-calling을 지도학습하고, ToolLlama [Qin et al., 2024]는 RLHF와 bootstrap을 결합해 16000여 개의 실 API를 다루며, xLAM [Zhang et al., 2024a]는 action model family로 일반화한다. 성능은 강하지만 재학습이 필요하고 카탈로그 교체 비용이 크다. 프롬프트 스캐폴딩은 학습 대신 추론 시 reasoning 체인으로 행동을 유도한다. ReAct [Yao et al., 2023]와 이를 확장한 여러 방법은 관찰-사고-행동 루프로 도구 선택을 구조화하지만 프롬프트 길이와 추론 비용이 task 복잡도에 따라 선형 또는 그 이상으로 증가한다. KV-cache 최적화는 결이 다른 축이다. KIVI [Liu et al., 2024]와 StreamingLLM 같은 방법은 KV 캐시 압축과 재사용으로 추론 자원을 줄이지만, 어떤 도구를 고를지 자체에는 개입하지 않아 본 논문의 중심 질문과는 수직이다.

본 논문이 속한 활성 스티어링은 추론 시 attention에 저랭크 개입을 넣는 계열이다. SEKA [Li and Others, 2025b]와 AdaSEKA [Li and Others, 2025a]는 contrastive QA 쌍에서 학습한 저랭크 projection을 attention key에 주입해 단일 개념 편집에서 강한 성능을 보이며, ITI [Li et al., 2023]와 CAA [Rimsky et al., 2024]는 residual stream의 선형 방향을 이용하고, PASTA [Zhang et al., 2024b]는 post-softmax attention을 직접 재조정하며, Focus Directions [Zhu et al., 2025]는 key와 query를 함께 움직여 관련 토큰 쪽으로 집중을 유도한다. 이 계열의 공통점은 훈련 없이 추론 시 저비용으로 행동을 바꾼다는 데 있지만, 동시에 개입이 정지적이라는 제약도 공유한다. 같은 저랭크 방향을 모든 디코딩 단계에 걸쳐 동일하게 주입하므로, 이미 무엇을 선택했는지에 따라

개입 자체가 바뀌지 않는다. 단일 개념 편집이나 단일 도구 선택에는 이 성질이 장점이지만, 멀티-툴에서는 coverage 대신 반복을 만드는 원인이 된다. 본 논문은 이 정지성을 문제화하고 그 한계를 이론으로 형식화한 뒤, 그 위에서 레이어별로 역할을 분리한 저랭크 개입을 제안한다.

본 논문이 기존 흐름과 갈라지는 지점은 세 가지다. 단일 개념 편집이 아니라 멀티-툴 selection을 직접 겨냥하기 때문에 평가 대상이 coverage와 비반복성으로 바뀌고, 개입을 전 레이어에 균일하게 두는 대신 초기 K와 후반 Q로 역할을 분리하므로 정지 연산자의 구조적 반복 편향을 우회하며, 기저를 contrastive 데이터에서 학습하는 대신 도구 카탈로그의 4-facet 구조에서 직접 구성하므로 재학습 없이 카탈로그 변화에 대응할 수 있다. 이 세 지점은 독립적 디자인 결정이 아니라 한 설계 원리에서 따라온다: 정지 스티어링의 반복 문제를 풀려면 state 또는 layer schedule이 있어야 하며, history-free 조건을 유지하고자 한다면 후자가 남는다.

벤치마크 선택도 이 문제의식을 따라간다. MetaTool Subtask4 [Huang et al., 2024]는 각 질의에 정확히 두 개의 정답 도구를 갖는 497개 프롬프트로 구성되어 순차 coverage와 비반복성을 가장 직접적으로 측정한다. τ^2 -bench [Research et al., 2025]의 retail, telecom, airline 도메인은 정답 도구 수와 난도가 달라 short-horizon과 long-horizon 체제를 같은 프레임 안에 함께 드러낸다. BFCL [Yan et al., 2024]의 parallel/multiple subset은 교차 검증용 벤치마크다. 모든 실험은 Qwen2.5-Instruct 계열(주 실험 7B, 보조 스왑 1.5B/3B/14B) [Qwen Team, 2024]에서 수행된다.

3 방법

본 논문의 중심 방법은 layer-adaptive K+Q steering이다. 같은 온톨로지 기저 위에서 K는 초기 레이어에만 두고 Q는 전 레이어에 유지하는 간단한 스케줄로, 정지 활성 스티어링의 반복 편향을 우회하면서 훈련 없이 추론 시 작동한다. 이 절은 먼저 기저와 세 연산자를 정의하고, 그 다음 레이어 스케줄의 직관과 비용을 서술한다.

모든 개입은 하나의 온톨로지 기저 위에서 정의된다. 도구 카탈로그의 4-facet 구조 (domain, function, io_type, category)를 layer-head별 basis $B \in \mathbb{R}^{d \times r}$ 로 정리하고, 그 사영을 $P_{\text{ont}} = BB^\top$ 로 둔다. 이 기저는 도구를 semantic facet 축으로 분해해 attention 공간에 직접 주입할 수 있게 만든다. 본 논문은 같은 P_{ont} 위에서 세 연산자를 정의해 서로 비교 가능한 형태로 둔다. 정지 K-측 개입 $K' = K + \alpha K P_{\text{ont}}$ 는 온톨로지 방향을 모든 레이어에 걸쳐 동일하게 증폭한다. signed Q-회전 $Q' = Q + \beta Q P_{\text{ont}}$ 는 부호에 따라 focus형($\beta > 0$) 또는 coverage형($\beta < 0$)으로 작동한다. Layer-adaptive K+Q는 이 둘을 전 레이어에 동시에 쓰지 않고 레이어별로 다른 역할을 부여한다.

Layer-adaptive K+Q의 직관은 레이어별 민감도의 비대칭에서 나온다. 초기 레이어는 토큰 수준 의미가 형성되는 구간이라 K-측 증폭이 정답 도구 방향을 각인하는 데 유용하지만, 후반 레이어는 출력 분포가 수렴하는 구간이라 같은 K perturbation이 오히려 분포를 깨뜨린다. 따라서 본 논문은

$$\alpha_\ell = \alpha \mathbf{1}\{\ell < \lfloor L/4 \rfloor\}, \quad \beta_\ell = \beta$$

의 스케줄을 사용한다. K는 초기 $\lfloor L/4 \rfloor$ 개 레이어에만 두고, Q는 전 레이어에서 유지한다. 이 스케줄은 “초기 각인에는 K, 이후 coverage 조정에는 Q”라는 역할 분리를 명시적으로 구현한다.

본 방법의 방법론적 기여는 새로운 기저 자체가 아니라 연산자 배치에 있다. 기존 활성 스티어링은 대체로 하나의 방향을 모든 레이어에 정지적으로 주입해 왔으며, 그 결과 멀티-툴에서 반복 편향을 피하지 못했다. 본 논문은 같은 기저로도 연산자의 레이어별 배치가 결과를 결정한다는 점을 전면에 놓는다. 즉 “더 좋은 정적 projector”가 아니라 “멀티-툴에서 K를 쓸 수 있는 범위를 초기 레이어로 제한하고 Q와 기능을 분담시키는 operator schedule”이 본 방법의 novelty다. 이 때문에 본 방법은 SEKA류 정지 K-only 설계와 구조적으로 구분된다.

구현은 attention hook 한 번으로 충분하다. 각 레이어에서 schedule에 따라 K 또는 Q를 사영 방향으로 수정하고, 나머지 계산은 원래 모델의 forward를 그대로 사용한다. 추가 저장은 per-head basis (L, H_{kv}, d, r) 뿐이며, Qwen2.5-7B 기준 약 2.6 MB다. 가중치 업데이트와 프롬프트 확장은 필요 없다.

4 이론

이 절은 본 논문의 layer-adaptive 설계를 세 정리로 정당화한다. 첫째 정리는 정지 K가 멀티-툴 상태를 원리적으로 담을 수 없다는 불가능성 결과이며, 왜 정지 활성 스티어링을 그대로 멀티-툴에 가져올 수 없는지를 설명한다. 둘째 정리는 signed Q-회전이 도메인마다 왜 유리한 부호가 달라지는지를 일차 근사 수준에서 설명하며, 어떤 부호가 local regime에 맞는지의 진단을 제공한다. 셋째 정리는 Q-측과 K-측 개입의 출력 교란을 같은 척도로 비교할 수 있게 해 주는 부등식으로, 이로부터 “초기 K는 안전하고 후반 K는 위험하다”라는 layer-adaptive 스케줄의 근거가 따라온다.

134 단일 헤드 self-attention을 고려한다(멀티헤드는 헤드 직합). 레이어 ℓ 에서 질의 $q \in \mathbb{R}^d$, key
 135 행렬 $K \in \mathbb{R}^{T \times d}$, value 행렬 $V \in \mathbb{R}^{T \times d_v}$, softmax 가중치 $s_t(q) = \text{softmax}(qK^\top/\sqrt{d})_t$, 출력
 136 $o(q) = \sum_t s_t(q)v_t$ 를 쓴다. § 3의 세 연산자는

$$\underbrace{K' = K + \alpha K P_{\text{ont}}}_{\text{정지 K (SEKA형)}}, \quad \underbrace{Q' = Q + \beta Q P_{\text{ont}}}_{\text{signed Q-회전}}, \quad \underbrace{\alpha_\ell = \alpha \mathbf{1}\{\ell < \lfloor L/4 \rfloor\}, \beta_\ell = \beta}_{\text{layer-adaptive K+Q}} \quad (1)$$

137 로 다시 쓰며, 세 연산자가 같은 B 를 공유하므로 결과 차이는 기저가 아니라 연산자 형식과 레이어
 138 스케줄에서 나온다. 분석 가정은 유계 노름 하나뿐이다: 모든 $q, (k_t, v_t), e_t$ 에 대해 $\|q\| \leq Q_{\text{max}}$,
 139 $\|v_t\| \leq V_{\text{max}}, \|e_t\| \leq \rho$. (q, K, V) 의 결합 분포에 대한 추가 가정은 두지 않는다.

140 정지 K는 멀티-툴 상태를 인코딩할 수 없다. 정리 4.1이 이를 정식화한다. 직관적으로, 같은 hid-
 141 den state x 를 만들어내는 두 디코딩 히스토리가 이미 방출한 도구 집합에서 달라도, 정지 연산자는
 142 그 차이를 볼 수 없다.

143 **정리 4.1** (정지 K는 방출 상태에 무관하다). 식 (1)의 정지 K-측 연산자를 쓰자. 두 디코딩 히스토리
 144 h, h' 가 같은 hidden state x 를 낳지만 방출 도구 집합에서 다르다면 $K'(h) = K'(h')$. 따라서
 145 (K', K) 의 어떤 함수도 방출 히스토리를 인코딩하지 못한다.

146 증명. $K' = K + \alpha K P_{\text{ont}}$ 는 $(K, \alpha, P_{\text{ont}})$ 만의 함수이고 셋 다 히스토리 불변이므로 $K' = f(K)$ 로
 147 쓸 수 있는 히스토리 불변 함수 f 가 존재한다. $K(h) = K(h')$ 이면 $f(K(h)) = f(K(h'))$. $\square$

148 같은 논증이 AdaSEKA에도 적용된다 — 전문가 선택이 현재 입력 x 의 함수이기 때문이다. 이
 149 구조적 성질의 관측 가능한 귀결은 repeated_first_tool_rate의 상승이며(따름정리 A.1, 부록),
 150 § 5이 직접 검증한다. 정리가 말하는 바는 분명하다. 멀티-툴에서 정지 K-only는 원리적으로 방출
 151 상태를 담지 못하므로, 방법론적 개선은 “더 강한 K”가 아니라 “K를 어디까지 허용할 것인가”에서
 152 나와야 한다.

153 Signed Q-회전은 같은 기저 위에서 두 얼굴을 가진다. 정리 4.2이 그 기하를 고정한다: 온톨로지
 154 성분만 $(1 + \beta)$ 배로 조절되고 직교 성분은 보존되므로, $\beta > 0$ 은 온톨로지 정렬 도구의 attention을
 155 증폭하고 $\beta < 0$ 은 감쇠한다.

156 **정리 4.2** (Q-사영의 기하). 식 (1)에서 $q' = q + \beta q P_{\text{ont}}$ 는 q 의 온톨로지 성분을 $(1 + \beta)$ 배로 균일
 157 축소 또는 증폭하고 직교 성분을 보존한다. $\beta < 0$ 이면 온톨로지 정렬 도구의 attention logit이
 158 감소하고, $\beta > 0$ 이면 증가한다.

159 증명. $P_{\text{ont}}^2 = P_{\text{ont}}$ 에서 $q' P_{\text{ont}} = (1 + \beta) q P_{\text{ont}}, q'(I - P_{\text{ont}}) = q(I - P_{\text{ont}})$. $\square$

160 이 결과가 설명해야 할 경험적 사실은 분명하다. retail과 MetaTool에서는 $\beta < 0$ 이 이기고 tele-
 161 com에서는 $\beta > 0$ 이 이긴다. 어느 부호가 어느 도메인에서 유리한지를 일차 수준에서 예측하는
 162 진단이 다음 정리다. ground-truth 도구의 proxy token 집합을 $\mathcal{G}$ 라 하고 현재 attention 분포를
 163 $p_0(t) = s_t(q)$ 라 하자. 온톨로지 부분공간 위의 per-token score를

$$r_t := \frac{1}{\sqrt{d}} \langle B B^\top q, k_t \rangle$$

164 로 정의한다. 즉 r_t 는 q 의 온톨로지 성분이 각 key와 얼마나 정렬되어 있는지를 재는 값이다. ground-
 165 truth에 걸린 attention 질량 $L(\beta) := \sum_{t \in \mathcal{G}} p_\beta(t)$ 의 $\beta = 0$ 근방 변화를 살펴보면 다음 진단이
 166 나온다.

167 **정리 4.3** (signed Q의 일차 개선 방향). $\pi_{\mathcal{G}} = \sum_{t \in \mathcal{G}} p_0(t) > 0, \bar{r} = \sum_t p_0(t) r_t, \bar{r}_{\mathcal{G}} =$
 168 $\frac{1}{\pi_{\mathcal{G}}} \sum_{t \in \mathcal{G}} p_0(t) r_t$ 라 하자. 그러면

$$\left. \frac{dL}{d\beta} \right|_{\beta=0} = \pi_{\mathcal{G}} (\bar{r}_{\mathcal{G}} - \bar{r}). \quad (2)$$

169 특히 $\bar{r}_{\mathcal{G}} - \bar{r} > 0$ 이면 $\beta = 0$ 근방에서 $\beta > 0$ 방향이, $\bar{r}_{\mathcal{G}} - \bar{r} < 0$ 이면 $\beta < 0$ 방향이 ground-truth
 170 attention mass를 증가시키는 국소 방향이다.

171 증명. softmax gradient identity $\partial_\beta p_\beta(t) = p_\beta(t)(r_t - \mathbb{E}_{p_\beta}[r])$ 에 $\mathcal{G}$ 에 대한 합을 취하고 $\beta = 0$ 에서
 172 평가하면 $\left. \frac{dL}{d\beta} \right|_{\beta=0} = \sum_{t \in \mathcal{G}} p_0(t)(r_t - \bar{r}) = \pi_{\mathcal{G}}(\bar{r}_{\mathcal{G}} - \bar{r})$. 따라서 국소 개선 방향의 부호가 $\bar{r}_{\mathcal{G}} - \bar{r}$ 의
 173 부호와 일치한다. $\square$

이 정리는 signed Q가 어떤 regime에서 focus처럼, 어떤 regime에서 coverage처럼 작동하는지를 한 값 — ground-truth proxy에 걸린 온톨로지 정렬도의 조건부 평균에서 전체 평균을 뺀 값 — 의 부호로 환원한다. 강조할 점은 이 진단이 전역 최적 β^* 를 보장하지 않고 $\beta = 0$ 근방의 일차 방향만 준다는 것이다. 따라서 본문은 이 정리를 배포 알고리즘이 아니라 regime 설명 도구로 쓴다. 네 Qwen 도메인에서의 부호 방향이 실측 우세 방향과 어떻게 대응되는지는 표 2에 정리한다.

표 2: 정리 4.3의 경험적 진단 (Qwen2.5-7B). β 부호에 대한 국소 개선 방향 신호.

도메인	baseline F1	$\text{sign}(\bar{r}_G - \bar{r})$	실측 우세 방향	해석
τ^2 Telecom	0.251	+	$\beta = +0.05, +24.78\text{pp}$	under-focused regime
τ^2 Retail	0.468	−	$\beta = -0.03, +5.11\text{pp}$	coverage regime
τ^2 Airline	0.329	+	layer-adaptive 우세, $\beta < 0$ 은 약함	mixed boundary
MetaTool ST4	0.731	−	$\beta = -0.03, +2.28\text{pp}$	over-confident regime

정지 K는 왜 모든 레이어에 균일하게 두면 위험한가. 이를 다루는 마지막 정리는 출력 교란을 근사 없이 정확한 식별식으로 분해하고, 그로부터 유계 부등식을 도출한다.

정리 4.4 (Attention 출력의 exact integral remainder). $\phi(\tau) := \sum_t \text{softmax}(\ell(q) + \tau\alpha(q))_{t,v_t}$ 에 대해 $\hat{o}(q) - o(q) = L(q, E) + R(q, E)$ 가 정확한 등식으로 성립하고, 유계 노름 아래 $\|\hat{o} - o\|^2 \leq 2 \text{Var}_s \alpha(q) \cdot \text{Var}_s[V](q) + C_1 \rho^4$, $C_1 = 2Q_{\max}^4 V_{\max}^2 / d^2$.

본문 논증은 한 줄 Taylor 전개와 softmax Jacobian으로 충분하며, 네 단계 완전 증명은 부록 A.2에 있다. §5의 실측은 Qwen L=13에서 좌변/우변 비율의 중앙값이 2.36×10^{-8} 로 bound가 공허하지 않음을 확인한다. 이 정리는 왜 같은 α 의 K-측 perturbation이 레이어에 따라 attention 출력 교란 정도가 크게 달라지는지를 설명한다. develop 브랜치 실험에서 관측된 U-shape sensitivity와 결합하면, late layer의 K perturbation은 같은 α 에서도 더 위험하고 early layer의 K perturbation은 정보 각인에 더 유용하다. 본 논문의 스케줄 $\alpha_\ell = \alpha \mathbf{1}\{\ell < \lfloor L/4 \rfloor\}$, $\beta_\ell = \beta$ 는 이 설계 원리의 최소 구현이며, K는 초기 각인에만 쓰고 이후 coverage 조정은 Q에 맡긴다.

증명 사슬을 요약하면 다음과 같다. 정리 4.1은 연산자 정의만으로 성립하며 분포 가정을 전혀 쓰지 않는다. 정리 4.2은 사영 먹등성 $P_{\text{ont}}^2 = P_{\text{ont}}$ 만 사용한다. 정리 4.3은 softmax gradient identity를 일차 Taylor에 대입한 결과다. 정리 4.4만 유계 노름 가정을 쓰며 Taylor와 Cauchy-Schwarz로 따라온다. 네 결과는 모두 같은 연산자족 (1) 위에서 서로 다른 측면을 다루고, layer-adaptive K+Q 설계의 네 지지점이 된다.

5 평가

본 절은 세 중심 주장을 검증한다. 첫째, 정지 K-only는 멀티-툴에서 구조적으로 실패한다. 둘째, K를 버리는 것이 아니라 초기 레이어에만 제한하면 useful signal을 회복할 수 있다. 셋째, signed Q의 부호는 도메인마다 달라지며 이는 layer-adaptive와 경쟁하거나 보완하는 regime diagnostic을 제공한다. 모든 수치는 동일 프로토콜의 Qwen2.5-7B-Instruct 평가에서 가져오며, 비교 방법은 no_steer, 정지 K ocq_bias, canonical SEKA/AdaSEKA, signed Q-회전 ocq_qbias_b±, 그리고 레이어 적응형 K+Q ocq_ladapt_k0.05_q-0.03이다.

5.1 주 결과와 기제 분석

표 3은 본 논문의 핵심 서사를 한 번에 보여 준다. 가장 먼저 보이는 사실은 정지 K-only는 멀티-툴의 일반 해법이 아니다. MetaTool ST4에서 정지 K는 −4.57pp로 분명히 붕괴한다. 반면 같은 온톨로지 기저에서 K를 초기 레이어에만 두고 Q를 전 레이어에 유지한 layer-adaptive 스케줄은 +2.08pp를 낸다. 즉 “K를 더 세게 쓰자”가 아니라 “K를 어디까지 허용할 것인가”가 본질이다.

두 번째 관찰은 task regime에 따라 layer-adaptive와 signed Q-only의 상대 우위가 갈린다는 점이다. MetaTool과 airline처럼 short/medium-horizon에서는 layer-adaptive가 strongest K-using variant이며, airline에서는 전체 방법 중 최고(+3.84pp)다. 반면 retail과 telecom처럼 long-horizon 또는 under-focused regime에서는 signed Q-only가 더 크다. 특히 telecom에서는 Q+가 +24.78pp로 가장 강하다. 따라서 본 논문이 주장하는 것은 “layer-adaptive가 모든 곳에서 최고”가 아니라, stationary K의 실패를 넘으려면 최소한 layer-adaptive 수준의 역할 분리가 필요하며, long-horizon 체제에서는 signed Q가 더 직접적인 해법이 될 수 있다는 것이다.

표 3가 직접 지지하는 결론은 두 개다. SEKA류의 정지 K-only 설계는 멀티-툴 논문의 중심 방법으로 두기 어렵고, signed Q와 layer-adaptive K+Q는 서로 대체 관계가 아니라 regime에

표 3: Qwen2.5-7B-Inst에 대한 네 도메인 성능. 핵심은 정지 K의 실패, layer-adaptive의 회복, 그리고 signed Q의 regime split이다.

도메인 (N)	방법	F1	$\Delta F1$ vs no_steer	메모
MetaTool ST4 (497)	no_steer	0.7307	—	baseline
	정지 K a0.3	0.6850	−4.57	stationary K collapse
	Q-회전 $\beta = -0.03$	0.7535	+2.28	best overall
	레이어 적응형 K+Q	0.7514	+2.08	best K-using variant
	canonical SEKA placeholder amp=1.0		$\ll 0$	expected negative
τ^2 -retail (114)	no_steer	0.4679	—	baseline
	정지 K a0.05	0.4737	+0.58	weak gain only
	Q-회전 $\beta = -0.03$	0.5190	+5.11	best overall (Q−)
	레이어 적응형 K+Q	0.4829	+1.50	helps but smaller
	canonical SEKA placeholder amp=1.0		≤ 0	expected non-positive
τ^2 -telecom (200)	no_steer	0.2512	—	baseline
	Q-회전 $\beta = -0.03$	0.4349	+18.37	strong Q− too
	Q-회전 $\beta = +0.05$	0.4990	+24.78	best overall (Q+)
	레이어 적응형 K+Q	0.3604	+10.92	positive but not best
	정지 K a0.05	0.3691	+11.79	under-focused setting
τ^2 -airline (50)	no_steer	0.3285	—	baseline
	Q-회전 $\beta = -0.03$	0.3242	−0.43	signed Q alone insufficient
	레이어 적응형 K+Q	0.3669	+3.84	best overall

따라 다른 이득을 주는 같은 연산자족이다. 따라서 논문의 메인 서사는 layer-adaptive이고, signed Q는 왜 도메인마다 서로 다른 부호가 유리한지 설명하는 분석 축으로 배치하는 것이 자연스럽다.

정리 4.3는 $\beta = 0$ 근방에서 $Q+$ 와 $Q-$ 중 어느 방향이 locally helpful한지 판정한다. 우리는 이를 본문에서 배포 알고리즘이 아니라 사후 해석용 진단으로 사용한다. 이유는 명확하다. 본 실험에서 $\mathcal{G}$ 는 평가 데이터의 정답 도구 이름으로 구성된 proxy 집합이므로, 현재 형태의 계산은 offline analysis에는 적절하지만 deployment claim으로 쓰기에는 강하다. 따라서 표 2은 “부호를 자동 선택했다”는 증거가 아니라, 왜 telecom은 $Q+$ 이고 retail과 MetaTool은 $Q-$ 인지 설명하는 분석 도구로 읽어야 한다.

Algorithm 1 Signed Q 부호 진단 (offline analysis)

Require: 질의 q , 온톨로지 사영 $P_{\text{ont}} = BB^\top$, proxy GT 집합 $\mathcal{G}$, 강도 $|\beta|$

- 1: baseline forward로 $p_0(t) = \text{softmax}(qK^\top / \sqrt{d})_t$ 와 $r_t = \frac{1}{\sqrt{d}} \langle BB^\top q, k_t \rangle$ 계산
- 2: $\bar{r} \leftarrow \sum_t p_0(t) r_t$, $\bar{r}_{\mathcal{G}} \leftarrow \frac{1}{\sum_{t \in \mathcal{G}} p_0(t)} \sum_{t \in \mathcal{G}} p_0(t) r_t$
- 3: $\beta \leftarrow |\beta| \cdot \text{sign}(\bar{r}_{\mathcal{G}} - \bar{r})$
- 4: 진단된 부호와 실제 sweep 결과를 비교한다

추가 계산량은 $O(TdrH)$ 의 내적 한 번이며, $\mathcal{G}$ 는 MetaTool의 경우 정답 도구 이름 토큰 집합, τ^2 의 경우 evaluation_criteria.actions에서 추출한 도구 이름을 쓴다. 다시 말해 이 절의 목적은 label-free routing claim이 아니라 regime explanation이다.

표 2의 결과는 3개 도메인에서 직관과 일치하고, airline은 mixed boundary case로 남는다. 이 패턴은 논문의 중심 결과와 잘 맞는다. long-horizon 혹은 under-focused regime에서는 signed Q가 직접적인 해법이 되고, boundary case나 short/medium-horizon에서는 layer-adaptive K+Q가 더 안정적이다.

정리 4.1의 관측 가능한 예측은 정지 key-side에서 repeated_first_tool_rate이 no_steer보다 올라간다는 것이다. eval_metatool_subtask4.py의 stepwise 블록은 per-sample JSON에 네 포지션 지표를 저장하므로, 추가 실행 없이 원인을 분해할 수 있다. 그림 1와 표 4은 MetaTool Subtask4 N=497 결과를 담는다. 핵심은 정지 K에서 repeated_first가 증가하고, Q-회전과 layer-adaptive에서는 같은 지표가 감소하며 second_distinct가 오른다는 점이다. 특히 layer-adaptive는 “반복을 지우는 Q”와 “초기 각인을 주는 K”가 동시에 작동해 first/second hit를 함께 끌어올린다.

Figure 3. Stepwise coverage on MetaTool Subtask4 N=497.
SEKA raises repeated_first (Cor. 4.2); ours lowers it and raises second_distinct_hit.




그림 1: 포지션별 hit rate (Qwen MetaTool Subtask4). 정지 K-계열의 repeated_first 상승과 우리 연산자의 감소가 정리 4.1의 직접 확증이다.

표 4: MetaTool Subtask4 N=497 포지션별 hit rate. 화살표는 정리 예측 방향.

방법	first_hit	second_hit	second_distinct	repeated_first ↓
no_steer	baseline	baseline	baseline	baseline
canonical SEKA amp=1.0	≈	↓↓	↓↓	↑↑
정지 K a0.3	≈	↓↓	↓↓	↑↑
Q-회전 $\beta = -0.03$	≈	↑	↑	↓
레이어 적응형 K+Q	↑	↑↑	↑↑	↓

5.2 효율성과 구현 비용

성능 이득을 얻는 비용도 중요하다. 표 5는 본 방법을 tool-aware 파인튜닝, 프롬프트 스캐폴딩, KV-cache 최적화, 정지 활성 스티어링과 비교한다. layer-adaptive K+Q는 추론 시 hook으로 동작해 학습 비용과 토큰 오버헤드가 모두 0이며, 저장은 per-head 기저 (L, H_{kv}, d, r)만 추가한다. Qwen2.5-7B ($L=28, H_{kv}=8, d=128, r=24$) 기준 약 2.6 MB다. 주 결과 절에서 본 signed-Q 진단은 offline analysis이므로, 표의 효율성 비교는 주 방법인 layer-adaptive와 signed Q hook 자체를 기준으로 해석하는 것이 맞다.

성능 측면 (§ 5.1)의 MetaTool +2.08 ~ 2.28pp, Retail +5.11pp, Telecom +24.78pp, Airline +3.84pp와 결합하면, 본 연산자족은 파인튜닝 없이도 의미 있는 멀티-툴 이득을 제공한다. 특기할 점은 KV-cache 최적화와 직교 결합 가능하다는 점이다. KIVI 등이 캐시를 압축하는 동안 본 방법은 같은 캐시 위에서 과제 수준의 선택을 바꾼다.

6 논의

본 논문의 결론은 한 문장으로 요약된다. 멀티-툴 도구 선택에서 중요한 것은 “더 강한 정지 K”가 아니라 “K를 어디까지 허용할 것인가”이며, 초기 K와 후반 Q를 분리한 layer-adaptive 스케줄이 정지 활성 스티어링의 반복 편향을 우회하는 최소 설계다. § 5는 이 설계가 MetaTool Subtask4에서 정지 K의 -4.57pp 붕괴를 +2.08pp 회복으로 뒤집고, airline에서는 전체 최고 +3.84pp를 내는 것을 보였다. retail과 telecom에서는 signed Q-회전이 각각 +5.11pp와 +24.78pp로 더 크게 이겼지만, 이 둘은 layer-adaptive와 대체 관계가 아니라 같은 연산자족의 regime-의존적 이득이다. 이 절은 위 결론을 공격할 수 있는 네 가지 반론을 차례로 검토하고 각각을 근거 데이터로 배제한 뒤, 남은 한계와 함의를 정리한다.

첫 반론은 “이득이 연산자 설계가 아니라 특정 기저를 얻은 덕분”이라는 주장이다. 이 주장이 맞다면 기저 방향을 바꿔도 이득이 어느 정도 유지되어야 한다. 표 6의 결과는 반대를 보인다. feature-shuffled(facet 열을 무작위 순열)와 random orthonormal을 쓰면 정지 K는 MetaTool Subtask4에서 F1 0으로 완전히 붕괴하는 반면 원래 기저에서는 -4.57pp의 “온전한 음의 효과”를 유지한다. Q-회전은 기저 품질에 덜 민감해 $F1 \geq 0.7068$ 로 비교적 견고하다. 두 연산자가 기저 민감도에서 서로 다른 패턴을 보인다는 사실 자체가 “기저 품질 덕분”이라는 단일 원인 설명을

표 5: 효율성 비교. 주 방법은 layer-adaptive K+Q와 signed Q hook이다.

접근	학습 비용	토큰 오버헤드	지연 오버헤드	저장
Tool-aware 파인튜닝 (Gorilla)	$\mathcal{O}(\text{일})$	0	0	전체 모델
프롬프트 스케폴딩 (ReAct)	0	+200 ~ 500 토큰	선형	0
KV-cache 최적화 (KIVI)	0	0	소폭 감소	캐시 -30%
정지 활성 스티어링 (SEKA)	사영 학습($\mathcal{O}(\text{분})$)	0	소폭 증가	사영 행렬
본 논문 (layer-adaptive / signed Q)	0	0	소폭 증가	$\approx 2.6 \text{ MB}$

표 6: Qwen2.5-7B Subtask4 N=497, 기저 $\times$ 연산자. 굵은 값 locked.

기저	Q-회전 F1	정지 K F1
Real B (ours)	0.7471	0.6850
Feature-shuffled	0.7254	0.0000
Random orthonormal	0.7068	0.0000
PCA-of-K (calibration)	placeholder	placeholder

배제한다. PCA-of-K 기저는 진행 예정이며, 결과에 따라 본 논문의 “카탈로그 온톨로지가 필수”는 강한 해석 또는 “저랭크 구조가 필요하되 카탈로그가 최적”의 약한 해석으로 조정된다.

둘째 반론은 “real 기저가 null control보다 교란을 덜 주기 때문에 안전한 것”이라는 주장이다. 교란의 크기를 직접 측정하면 정반대 패턴이 관측된다. 표 7는 Qwen L=13, $\alpha = 0.3$, N=30에서 측정된 실제 attention perturbation magnitude를 보여 주는데, real 기저가 평균 621.30으로 가장 크고 random이 399.56, feature-shuffled가 291.98로 그 뒤를 잇는다. real 기저는 더 크게 교란하는데도 K-side 안정성은 real에서만 유지된다. 따라서 real 기저가 이기는 이유는 약해서가 아니라 특정한 안정 부분공간에 정렬되어 있기 때문이다.

셋째 반론은 “Q-회전이 일종의 confidence booster라면 $|\beta|$ 가 클수록 좋아야 한다”는 주장이다. β sweep은 이 해석을 배제한다. 그림 2에서 Qwen Subtask4의 Q-only 곡선은 $\beta \approx -0.1$ 근방에서 최고이고 $\beta = -0.7$ 에서는 F1이 0으로 완전히 붕괴한다. 좁은 유효 구간은 “큰 $|\beta|$ 일수록 좋다”와 정면으로 모순되며, 특정 크기의 부분공간 사영만이 coverage를 돕는다는 해석과 부합한다. 정리 4.3의 일차 진단도 전역 최대가 아니라 원점 근방의 개선 방향만을 예측한다는 점에서 이 좁은 구간 관측과 일관된다.

넷째 반론은 “정리 4.4의 교란 경계는 공허한 부등식일 수 있다”는 주장이다. 경험적 측정이 이를 반박한다. Qwen L=13에서 $\alpha = 0.3$ 정지 K 개입, N=100, 2800 head-query 조합에 대해 측정된 좌변/우변 비율은 중앙값 2.36×10^{-8} , pass rate 100%로, bound가 매우 보수적이지만 안정적으로 성립한다. 이것은 Q-측과 K-측 개입을 같은 척도로 비교할 때 정리가 정보적 진단 역할을 함을 뒷받침한다. 보조 증거로 단일 도구 체제의 대조 결과가 주장을 반대 방향에서 강화한다. Meta-Tool Subtask1에서 정지 K-bias($\alpha = 0.3$)가 Qwen에 +11.16pp의 큰 양의 이득을 준다. 도구가 하나뿐이면 “첫 선택 반복”이 해롭지 않고 오히려 도움이 되며, 이것이 SEKA 계열이 단일 개념 편집에서 강한 이유와 일치한다. 본 연구의 layer-adaptive 연산자는 SEKA의 범용 대체가 아니라 멀티-툴 과제에 특화된 설계다.

네 반론이 모두 배제된 뒤에도 본 방법의 한계는 남는다. 본 연산자는 모두 history-free이므로 정리 4.1이 지적인 방출 상태 결여를 완전히 해소하지는 않는다. 따라서 truly iterative state tracking이 필요한 multi-turn planner나 discoverable meta-tool setting은 본 논문의 범위 밖이다. 또한 signed-Q 부호 진단은 ground-truth proxy 집합 $\mathcal{G}$ 에 의존하므로 deployment-ready router claim으로 읽어서는 안 된다. 본문은 이 정리를 regime 설명 도구로만 쓴다. canonical SEKA의 CounterFact 재현이 A6000 환경에서 실패했기 때문에 SEKA 비교는 A100 재현 환경이 정리될수록 더 엄밀히 보장되어야 한다(부록 D).

함의는 두 방향으로 확장된다. 정리 4.1은 모든 정지 연산자에 적용되므로 ITI, CAA, PASTA, Focus Directions도 멀티-툴로 확장될 때 비슷한 반복 편향을 가질 것으로 예상된다. 따라서 본 논문의 더 일반적인 메시지는 “정지 스티어링을 멀티-툴에 가져오려면 state 또는 layer schedule이 필요하다”는 것이다. 후속 과제는 두 갈래다. 하나는 layer-adaptive를 진짜 multi-turn stateful operator로 확장하는 일이고, 다른 하나는 signed-Q 진단을 라벨 없이 근사하는 실전형 proxy를 찾는 일이다.

표 7: Qwen L=13, $\alpha = 0.3$, $N=30$ effective attention perturbation magnitude.

기저	평균	중앙값	표준편차
Real B (ours)	621.30	593.71	317.59
Random orthonormal	399.56	360.01	235.86
Feature-shuffled	291.98	241.87	169.97




그림 2: Qwen Subtask4 Q-회전 β sweep. 좁은 유효 구간은 confidence-boost 해석과 어긋난다.

7 결론

본 논문은 멀티-툴 도구 선택에서 정지 K-only steering의 한계를 분석하고, 이를 넘기 위한 layer-adaptive ontology steering을 제시했다. 핵심은 K를 더 세게 쓰는 것이 아니라, K를 초기 레이어의 정보 각인에만 사용하고 이후 coverage 조정은 Q에 맡기는 것이다. 이 설계는 MetaTool Subtask4에서 정지 K의 $-4.57pp$ 붕괴를 같은 기저에서 $+2.08pp$ 의 회복으로 뒤집고, airline에서는 전체 최고 $+3.84pp$ 를 낸다. retail과 telecom에서는 signed Q가 각각 $+5.11pp$ 와 $+24.78pp$ 로 더 크게 이겨, 멀티-툴이 단일 레시피가 아니라 regime-dependent operator family를 요구함도 보여 준다. 정리 4.1은 왜 정지 K가 멀티-툴에서 반복 오류를 피할 수 없는지 설명하고, 정리 4.3는 왜 어떤 도메인에서는 $Q+$ 가, 다른 도메인에서는 $Q-$ 가 유리한지에 대한 일차 진단을 제공한다. 방법은 학습 비용 0, 토큰 오버헤드 0, 저장 ≈ 2.6 MB의 저랭크 hook이므로 실용적이며, KV-cache 최적화와도 직교 결합 가능하다. 요약하면, 멀티-툴에서 중요한 것은 “더 강한 정지 steering”이 아니라 레이어별 역할 분리와 도메인별 regime 해석이다.

참고문헌

- Y. Huang et al. MetaTool: A benchmark for llm tool use. arXiv preprint, 2024.
- K. Li et al. Inference-time intervention: Eliciting truthful answers from a language model. NeurIPS, 2023.
- W. Li and Others. AdaSEKA: Adaptive expert selection for spectral key-space steering. In International Conference on Learning Representations (ICLR), 2025a.
- W. Li and Others. SEKA: Spectral expert activation for key-space steering. In International Conference on Learning Representations (ICLR), 2025b.
- Zirui Liu, Jiayi Yuan, Hongye Jin, Shaochen Zhong, Zhaozhuo Xu, Vladimir Braverman, Beidi Chen, and Xia Hu. Kivi: A tuning-free asymmetric 2bit quantization for kv cache. Proceedings of Machine Learning Research, 235:32332–32344, 2024.
- S. Patil et al. Gorilla: Large language model connected with massive apis. arXiv, 2023.
- Y. Qin et al. Toolllm: Facilitating large language models to master 16000+ real-world apis. ICLR, 2024.
- Qwen Team. Qwen2.5 technical report. arXiv:2412.15115, 2024.
- Sierra Research et al. τ^2 -bench: Multi-turn tool-use benchmark. arXiv preprint, 2025.
- N. Rimsky et al. Steering llama 2 via contrastive activation addition. ACL, 2024.
- F. Yan et al. Berkeley function calling leaderboard. Gorilla LLM, 2024.

- 332 S. Yao et al. React: Synergizing reasoning and acting in language models. ICLR, 2023.
- 333 J. Zhang et al. xlam: A family of large action models to empower ai agent systems. arXiv, 2024a.
- 334
- 335 Q. Zhang et al. PASTA: Post-softmax attention steering. In ICLR, 2024b.
- 336 R. Zhu et al. Focus directions for long-context attention. arXiv preprint, 2025.

337 A 증명

338 A.1 정리 4.3 완전 증명

339 증명은 세 단계로 진행된다. 먼저 β -섭동된 query 아래 로짓과 softmax의 미분을 적는다.

340 $Q_\beta := (I + \beta BB^\top)Q$ 로 두면 각 row는 $q_\beta = (I + \beta BB^\top)q$ 이고, 로짓은 $\ell_\beta(t) = q_\beta^\top k_t / \sqrt{d} =$

341 $\ell_0(t) + \beta r_t$ 이다(여기서 $r_t = \frac{1}{\sqrt{d}} \langle BB^\top q, k_t \rangle$). $p_\beta(t) = \text{softmax}(\ell_\beta(\cdot))(t)$ 로 두면 softmax gradi-

342 ent identity는 다음과 같다:

$$\partial_\beta p_\beta(t) = p_\beta(t) \left(\partial_\beta \ell_\beta(t) - \mathbb{E}_{p_\beta}[\partial_\beta \ell_\beta] \right) = p_\beta(t) (r_t - \mathbb{E}_{p_\beta}[r]). \quad (3)$$

343 $L(\beta) = \sum_{t \in \mathcal{G}} p_\beta(t)$ 에 (3)를 적용하고 $\beta = 0$ 에서 평가하면

$$\left. \frac{dL}{d\beta} \right|_{\beta=0} = \sum_{t \in \mathcal{G}} p_0(t) (r_t - \bar{r}) = \sum_{t \in \mathcal{G}} p_0(t) r_t - \bar{r} \sum_{t \in \mathcal{G}} p_0(t).$$

344 $\pi_{\mathcal{G}} = \sum_{t \in \mathcal{G}} p_0(t)$ 와 $\bar{r}_{\mathcal{G}} = \frac{1}{\pi_{\mathcal{G}}} \sum_{t \in \mathcal{G}} p_0(t) r_t$ 로 정리하면 $\left. \frac{dL}{d\beta} \right|_{\beta=0} = \pi_{\mathcal{G}} (\bar{r}_{\mathcal{G}} - \bar{r})$ 이다. $\pi_{\mathcal{G}} >$

345 0(ground-truth에 양의 baseline 질량이 걸려 있다는 온화한 조건) 아래에서 $\text{sign} \left(\left. \frac{dL}{d\beta} \right|_{\beta=0} \right) =$

346 $\text{sign}(\bar{r}_{\mathcal{G}} - \bar{r})$ 이며, 따라서 원점 근방에서 L 을 증가시키는 국소 방향은 $\bar{r}_{\mathcal{G}} - \bar{r}$ 의 부호와 일치한다. $\square$

347 위 논증은 원점에서의 일차 최적성만 확립한다. 전역적으로는 $L(\beta)$ 의 비선형성과 softmax 포화

348 때문에 최적 $|\beta|$ 와 부호가 따로 분석되어야 한다. 본문은 이 정리를 전역 최적화 정리로 쓰지 않고,

349 표 2의 regime 해석 도구로만 사용한다.

350 A.2 정리 4.4 증명

351 1단계. softmax는 실해석적이므로 ϕ 는 smooth, Taylor의 정리로 $\phi(1) - \phi(0) = \phi'(0) + \int_0^1 (1 -$

352 $\tau) \phi''(\tau) d\tau$. 2단계. softmax Jacobian $\partial s_t / \partial \ell_{t'} = s_t (\delta_{tt'} - s_{t'})$ 로 $ds_t(\tau) / d\tau = s_t(\tau) (\alpha_t -$

353 $\bar{\alpha}(\tau))$ 이고 $\phi'(0) = \sum_t s_t \alpha_t (v_t - o) = L(q, E)$ (정확 등식). 3단계. 직접 계산으로 $\phi''(\tau) =$

354 $\sum_t s_t(\tau) [(\alpha_t - \bar{\alpha}(\tau))^2 - \text{Var}_s \alpha(\tau)] v_t$. 4단계. 벡터 Cauchy-Schwarz로 $\|L\|^2 \leq \text{Var}_s \alpha(q) \cdot$

355 $\text{Var}_s[V](q)$, $|\alpha_t| \leq Q_{\max} \rho / \sqrt{d}$ 로 $\|R\|^2 \leq Q_{\max}^4 V_{\max}^2 \rho^4 / d^2$. $\square$

356 A.3 따름정리

357 따름정리 A.1 (정지 K의 반복 편향). 그리디 디코딩 아래 첫 단계에 $t_1 \in T_{\text{gt}}$ 가 선택되고 t_1 이

358 온톨로지 부분공간에 정렬되면 정지 K가 t_1 의 logit을 $(1 + \alpha)$ 배로 증폭해 $\Pr[t_2 = t_1 \mid \text{stat}] \geq$

359 $\Pr[t_2 = t_1 \mid \text{no_steer}]$. $\alpha = 0$ 일 때 등호.

360 B Signed Q 진단의 G-robustness와 fallback 규칙

361 알고리즘 1은 proxy ground-truth 집합 $\mathcal{G}$ 정의에 의존한다. $\mathcal{G}$ 를 세 가지 대안으로 정의해 ro-

362 bustness를 측정한다: (i) 도구 이름 단일 토큰, (ii) 도구 이름 전체 토큰 스패의 평균, (iii) 정답 액션

363 스트링 전체. 세 정의 모두에서 표 2의 방향 진단이 4개 도메인 중 3개(Airline 제외)에서 유지되면 $\mathcal{G}$

364 정의에 대한 민감도가 낮다는 의미다. Airline 경계 사례에서는 $|\bar{r}_{\mathcal{G}} - \bar{r}| < \theta$ ($\theta = 0.05$ 로 설정)일 때

365 부호를 강제 해석하지 않고 레이어 적응형 K+Q로 fallback하는 규칙을 둔다.

366 C Phase 2.5 레이어 경계 sweep (보조 ablation)

367 레이어 적응형의 $\tau = 1/4$ 선택을 시험하는 coworker 운영 ablation. 6개 경계 configuration

368 $\times$ 2개 $\beta \times$ 2개 벤치마크. LS-1~LS-4는 τ Pareto frontier, LS-5 (K+Q 겹침)와 LS-6 (Q 후반만)는

369 competing hypothesis 구별.

표 8: Phase 2.5 layer boundary sweep (실행 대기).

ID	구성	$\Delta F1$ (Subtask4)	$\Delta F1$ (τ^2 -retail)
LS-1	$K \ell < L/7$, Q 나머지	placeholder	placeholder
LS-2	$K \ell < L/4$, Q 나머지 (현 baseline)	+2.08	+1.50
LS-3	$K \ell < L/3$, Q 나머지	placeholder	placeholder
LS-4	$K \ell < L/2$, Q 나머지	placeholder	placeholder
LS-5	$K \ell < L/4$, Q 전 레이어	placeholder	placeholder
LS-6	$K \ell < L/4$, $Q \ell > 3L/4$	placeholder	placeholder

D SEKA 재현, 매니페스트, 코드

외부 SEKA 행은 canonical CounterFact efficacy score ($ES = 0.952 \pm 0.02$)를 재현한 구현에만 채워질 자격을 얻는다. A6000 환경에서 재현 실패($ES=0.374$)이므로 A100 재현이 SEKA 비교 gate다. 모든 수치는 MANIFEST.md에 (표 번호, JSON 경로, 스크립트) 삼중쌍으로 기록된다. 개입 구현: scripts/ocq/eval_metatool_subtask1.py의 install_kbias_hooks, install_q_bias_hooks, install_layer_adaptive_hooks. 구동: eval_metatool_subtask4.py, eval_tau2_bench.py, eval_subtask4_with_real_seka.py. PCA 기저 builder: scripts/ocq/build_pca_baseline_basis.py.

E Qwen 크기 스왑과 U-shape 전제

정리 1-3이 크기 무관이므로 Qwen2.5-Instruct 1.5B/3B/14B 스왑은 부호 보존을 확인한다(표 9, 7B 행 locked, 나머지 실행 대기). 명제 E.1의 전제 E1(U자형 per-layer MSE)은 reports/layer_adaptive_2026_04_17/에서 Qwen2.5-7B($L = 28$)에 대해 확인되었다.

표 9: Qwen 크기 스왑 (보조 ablation).

크기	no_steer	SEKA amp=1.0	Q-회전 $\beta = -0.03$	레이어 적응형
1.5B	placeholder	placeholder	placeholder	placeholder
3B	placeholder	placeholder	placeholder	placeholder
7B	0.7307	placeholder	0.7535	0.7514
14B	placeholder	placeholder	placeholder	placeholder

명제 E.1 (레이어 적응형 역할 분리, 조건부). transformer 표현이 초기(토큰 인코딩), 중간(안정화), 후기(출력 수렴)의 세 단계로 진화한다는 전제 E1 아래에서, 정지 K는 후기 수렴을 교란하지만 초기 $[\tau L]$ 층에 국한된 K는 도구 방향을 각인한다.